6. sprawozdanie z laboratorium Hurtownie Danych

Mikołaj Kubś, 272662 $4~\mathrm{maja}~2025$

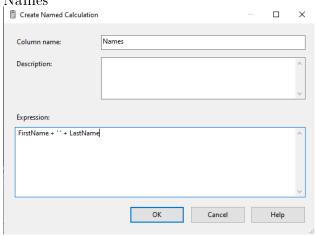
1 Zad. 1. Modyfikacja wymiarów i tabeli faktów

Bazując na kostce utworzonej przy realizacji listy 4, należy:

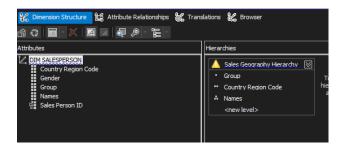
1.1 Podpunkt a

Zmodyfikować definicję wymiarów tak, aby:

1. W wymiarach CUSTOMER i SALESPERSON nie można było korzystać z atrybutów FirstName oraz LastName. W zamian dodać atrybut Names



2. W wymiarze SALESPERSON pojawiła się hierarchia Group - Country Region
Code - Names



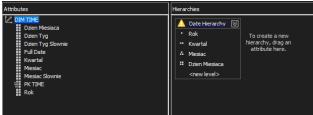
3. W wymiarze CUSTOMER pojawiła się hierarchia Group - Country Region
Code - Names



4. W wymiarze PRODUCT pojawiła się hierarchia Category Name - Sub-Category Name - Name



5. W wymiarze TIME pojawiła się hierarchia Rok - Kwartał - Miesiąc - Dzień miesiąca



1.2 Podpunkt b

Dla każdego atrybutu kluczowego wymiaru, którego wartościami są liczby całkowite, zmodyfikować właściwości (Properties). Zmodyfikować parametr NameColumn, tak aby nazwy kolejnych elementów wymiaru nie były liczbami. (Przykładowo dla wymiaru dotyczącego Produktu można wykorzystać atrybut Name).



Rysunek 1: Widok Properties dla DIM Salesperson



Rysunek 2: Widok Properties dla DIM Customer



Rysunek 3: Widok Properties dla DIM Product

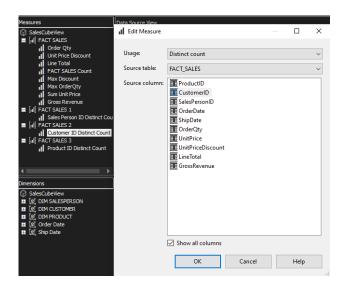


Rysunek 4: Widok Properties dla DIM Time

1.3 Podpunkt c

Utworzyć nowe miary, które będą odzwierciedlać:

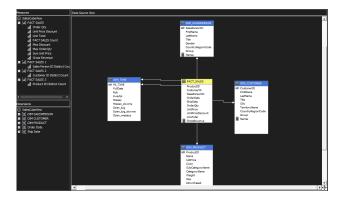
- Liczbę różnych klientów (aggregatedFunction: distinct count)
- Liczbę różnych produktów
- Maksymalną wartość rabatu (aggregatedFunction: max)
- Maksymalną liczbę zamówionych produktów
- Liczbę różnych sprzedawców realizujących zamówienia



Rysunek 5: Miara dotycząca liczby różnych klientów

1.4 Podpunkt d

Wdrożyć i przeprocesować kostkę.



Rysunek 6: Widok przeprocesowanej kostki

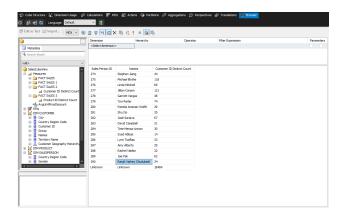
2 Zad. 2. Przegląd danych i tworzenie zestawień

Przy użyciu zakładki Browser:

2.1 Podpunkt a

Sprawdzić, czy dane zapisane w kostce zgadzają się z danymi zapisanymi w tabelach, przeciągając za pomocą myszy:

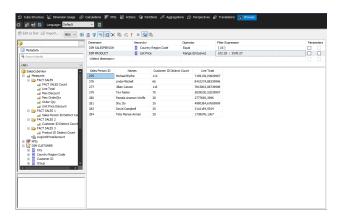
- atrybuty wymiarów w region wierszy
- miary w część centralną widoku



Rysunek 7: Widok przykładowej kwerendy w Browser

2.2 Podpunkt b

Przetestować możliwości przeglądarki (Browser) - operator wyboru danych (Operator), wyrażenia filtrujące dane (Filter Expression) itp.

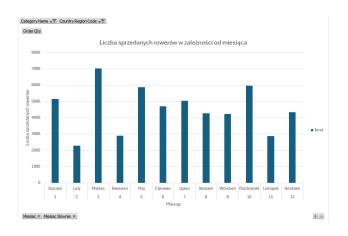


Rysunek 8: Widok przykładowej kwerendy z dwoma różnymi rodzajami filtrów (Operator i Filter Expression)

2.3 Podpunkt c

Przygotować przykładowe tabele i wykresy przestawne oraz zinterpretować uzyskane wyniki (proszę zapisać wnioski!)

${\bf 2.3.1}$ Liczba sprzedanych rowerów w zależności od miesiąca w USA

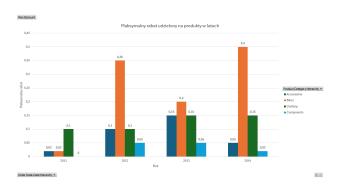


Rysunek 9: Wykres

Na wykres nałożone są 2 filtry - kategoria jest limitowna do rowerów, a kod regionu państwa do USA. Wykres jest posortowane po osi x, czyli związanej z miesiącami, agregując liczbę sprzedanych rowerów dla wszystkich lat naraz.

Generalnie widać trend wzrostu aktywności kupowania w miesiącach letnich. Mimo to, widać również wysokie wartości dla niektórych miesięcy poza sezonem - październik, grudzień, styczeń. Być może np. grudzień jest powiązany ze wzrostem sprzedaży w związku z Bożym Narodzeniem, a październik z potencjalnymi wyprzedażami po sezonie. Marzec osiąga najwiekszą sprzedaż, zaczynając większą sprzedaż sklepu do października. Najmniejsza sprzedaż jest w lutym - raczej popularniejsze są wtedy sporty zimowe.

2.3.2 Maksymalny rabat udzielony na produkty w latach od kategorii



Rysunek 10: Wykres

Na wykresie widać, że najwyższe rabaty udzielane są na rowery. Wartość maksymalnego rabatu w latach 2012-2014 była najwyższa właśnie dla rowerów. Zarówno w 2012, jak i w 2014, ta wartość była bardzo wysoka, około 2 razy wyższa, niż 3. najlepszy wynik (należący do rowerów w 2013 roku). W 2014 roku był udzielony najwyższy rabat ogółem - aż 40% zniżki dla szczęśliwego klienta. Ale w 2011, rabaty udzielane dla rowerów były niskie, podobnie jak dla innych kategorii.

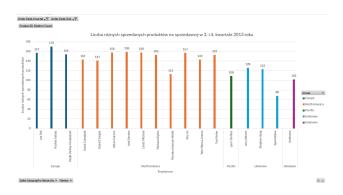
Akcesoria - wartość maksymalnego rabatu powoli rosła, z bardzo niskiego poziomu w 2011 do 4. najwyższego ogółem w 2013. Potem w 2014 znowu spadł do niskiego poziomu.

Ubrania - były najbardziej przeceniane w 2011 roku. Były przeceniane na podobnym poziomie w 2012, ale wtedy to rowery je prześcignęły. W 2013 urosły, utrzymując jeden z najwyższych poziomów również w 2014.

Kompnenty - bardzo niskie maksymalne rabaty, zerowe w 2011. W 2012 i 2013 podobne, ale najniższe w zestawieniach, w 2014 znowu spadek do bardzo niskiego poziomu.

Sklep wydaje się mieć dość chaotyczną politykę udzielania rabatów. Należałoby ją lepiej uściślić. Oczywiście, każda kategoria powinna mieć osobną politykę.

2.3.3 Liczba różnych sprzedanych produktów na sprzedawcę w 3. i 4. kwartale 2013 roku



Rysunek 11: Wykres

Wykres został arbitralnie ograniczony do 3. i 4. kwartału 2013 roku - mogło by być tak, że menadżer analizuje sytuację w poprzednim roku, czekając na nadejście 3. i 4. kwartału w 2014 roku w bazie danych.

Sprzedawcy utrzymują dość podobny poziom sprzedaży różnych produktów. Bardzo wielu osiąga wysoki poziom 160, zwłaszcza w Europie i w Północnej Ameryce. W rejonie pacyfiku poziom jest niższy, podobny do najniższego poziomu w poprzednich grupach - osiągniętego przez Lindę Mitchell.

Aż 3 sprzedawców nie jest przypisanych do regionu - osiągają oni jedne z niższych wyników sprzedaży różnych produktów.

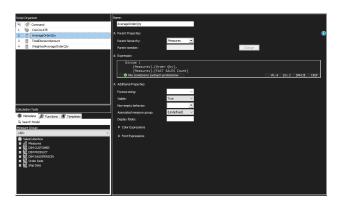
Wszystkim sprzedawcom osiągającym słabsze wyniki należy przyjrzeć się w celu ewentualnych szkoleń. Jeśli z innych analiz, np. analizy rynku, w którym pracują, ogólnej sprzedaży itd. wyszły również słabe wyniki, byliby to kandydaci do potencjalnych redukcji. Nalezy również koniecznie przypisać sprzedawców bez regionów do regionów - ułatwi to analizę.

3 Zad. 3. Miary kalkulowane

W zakładce Calculations dodać dwie miary kalkulowane (ang. calculated members):

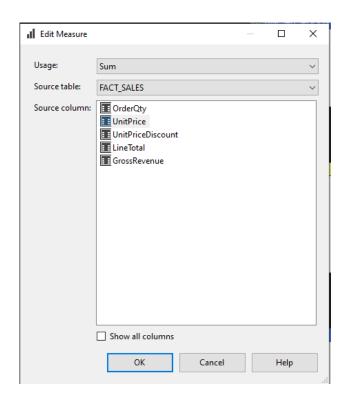
- średnią liczbę zamówionych towarów na zamówienie
- średnią ważoną liczbę towarów na zamówienie. Jako wagę należy wybrać cenę danego produktu.

Wskazówka: w celu utworzenia wyżej wymienionej średniej ważonej można posłużyć się nową kolumną zdefiniowaną w widoku źródła danych (lub w tabeli). Kolumna ta powinna definiować miarę pomocniczą, która pozwoli uzyskać fragment wyrażenia odpowiadającego średniej ważonej.

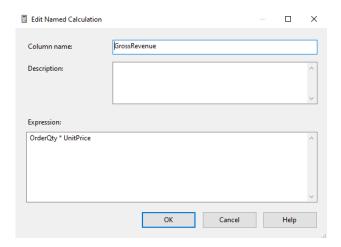


Rysunek 12: Sposób obliczania miary ze zwykłą średnią

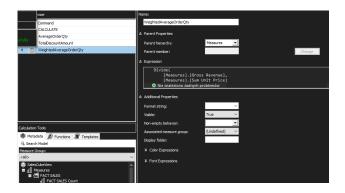
Do obliczenia średniej ważonej należało dodać miarę obliczającą sumę ceny jednostkowej i drugą miarę, będącą iloczynem ceny jednostkowej i liczby zamówionego produktu (LineTotal prawie to spełniał, ale miał w sobie czasem zniżkę).



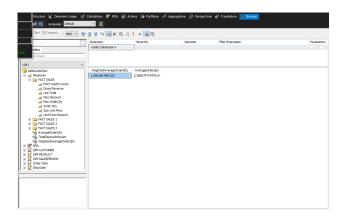
Rysunek 13: Sposób obliczania miary z sumą ceny jednostkowej



Rysunek 14: Sposób obliczania miary zysku brutto



Rysunek 15: Sposób obliczania miary średniej ważonej



Rysunek 16: Wynik średnich dla całego zbioru danych

4 Zad. 4. Partycje

Podzielić zawartość kostki na partycje (zakładka Partitions). Każda partycja powinna odzwierciedlać jeden rok. Istnieją dwa podstawowe sposoby podziału partycjonowania kostek:

- dane do zasilania poszczególnych partycji znajdują się w osobnych tabelach
- dane do zasilania poszczególnych partycji znajdują się w tej samej tabeli, zaś każda z partycji ma przypisanie zapytanie SQL, którego wynik służy do jej zasilenia.

Proszę przygotować partycje na dwa sposoby i znaleźć uzasadnienie dla każdej opcji.

4.1 Sposób pierwszy

Ta metoda wymagała utworzenia w bazie SQL Server osobnych tabel dla każdego roku (np. 'FACT_SALES_2011', 'FACT_SALES_2012', itd.) o strukturze identycznej jak oryginalna tabela faktów, a następnie wypełnienia ich danymi z odpowiednich lat.

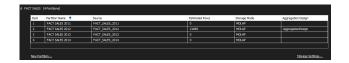
```
CREATE TABLE Kubs.FACT_SALES_2011 (
     ProductID INT FOREIGN KEY REFERENCES Kubs.DIM_PRODUCT(ProductID),
2
       CustomerID INT FOREIGN KEY REFERENCES Kubs.DIM_CUSTOMER(
3
       SalesPersonID INT FOREIGN KEY REFERENCES Kubs.DIM_SALESPERSON(
       SalesPersonID),
       OrderDate INT NOT NULL,
5
       ShipDate INT NULL,
6
       OrderQty SMALLINT NOT NULL,
       UnitPrice MONEY NOT NULL,
       UnitPriceDiscount DECIMAL(8, 4) NOT NULL,
       LineTotal DECIMAL(19, 4) NOT NULL
   );
11
12
   CREATE TABLE Kubs.FACT_SALES_2012 (
13
     ProductID INT FOREIGN KEY REFERENCES Kubs.DIM_PRODUCT(ProductID),
14
       CustomerID INT FOREIGN KEY REFERENCES Kubs.DIM_CUSTOMER(
15
       CustomerID),
       SalesPersonID INT FOREIGN KEY REFERENCES Kubs.DIM_SALESPERSON(
16
       SalesPersonID),
       OrderDate INT NOT NULL,
17
       ShipDate INT NULL,
18
       OrderQty SMALLINT NOT NULL,
       UnitPrice MONEY NOT NULL,
20
       UnitPriceDiscount DECIMAL(8, 4) NOT NULL,
^{21}
       LineTotal DECIMAL(19, 4) NOT NULL
22
   );
23
24
   CREATE TABLE Kubs.FACT_SALES_2013 (
     ProductID INT FOREIGN KEY REFERENCES Kubs.DIM_PRODUCT(ProductID),
26
       CustomerID INT FOREIGN KEY REFERENCES Kubs.DIM_CUSTOMER(
27
       CustomerID),
       SalesPersonID INT FOREIGN KEY REFERENCES Kubs.DIM_SALESPERSON(
28
       SalesPersonID),
       OrderDate INT NOT NULL,
29
       ShipDate INT NULL,
30
       OrderQty SMALLINT NOT NULL,
31
```

```
UnitPrice MONEY NOT NULL,
32
       UnitPriceDiscount DECIMAL(8, 4) NOT NULL,
33
       LineTotal DECIMAL(19, 4) NOT NULL
   );
35
36
   CREATE TABLE Kubs.FACT_SALES_2014 (
37
     ProductID INT FOREIGN KEY REFERENCES Kubs.DIM_PRODUCT(ProductID),
38
       CustomerID INT FOREIGN KEY REFERENCES Kubs.DIM_CUSTOMER(
39
       CustomerID),
       SalesPersonID INT FOREIGN KEY REFERENCES Kubs.DIM_SALESPERSON(
40
       SalesPersonID),
       OrderDate INT NOT NULL,
41
       ShipDate INT NULL,
42
       OrderQty SMALLINT NOT NULL,
43
       UnitPrice MONEY NOT NULL,
       UnitPriceDiscount DECIMAL(8, 4) NOT NULL,
45
       LineTotal DECIMAL(19, 4) NOT NULL
46
   );
47
48
   with Sales1 AS (
49
     SELECT
50
       Kubs.FACT_SALES.ProductID,
51
       Kubs.FACT_SALES.CustomerID,
52
       Kubs.FACT_SALES.SalesPersonID,
53
       Kubs.FACT_SALES.OrderDate,
54
       Kubs.FACT_SALES.ShipDate,
55
       Kubs.FACT_SALES.OrderQty,
       Kubs.FACT_SALES.UnitPrice,
57
       Kubs.FACT_SALES.UnitPriceDiscount,
58
       Kubs.FACT_SALES.LineTotal
59
     FROM Kubs.FACT_SALES
60
     WHERE OrderDate >= 20110101 AND OrderDate < 20120000
61
62
   INSERT INTO Kubs.FACT_SALES_2011
63
64
   with Sales2 AS (
65
     SELECT
66
       Kubs.FACT_SALES.ProductID,
67
       Kubs.FACT_SALES.CustomerID,
68
       Kubs.FACT_SALES.SalesPersonID,
69
       Kubs.FACT_SALES.OrderDate,
70
       Kubs.FACT_SALES.ShipDate,
71
       Kubs.FACT_SALES.OrderQty,
72
```

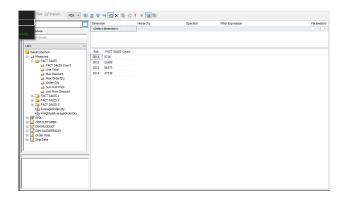
```
Kubs.FACT_SALES.UnitPrice,
73
        Kubs.FACT_SALES.UnitPriceDiscount,
74
        Kubs.FACT_SALES.LineTotal
      FROM Kubs.FACT_SALES
      WHERE OrderDate >= 20120101 AND OrderDate < 20130000
77
78
    INSERT INTO Kubs.FACT_SALES_2012
79
80
    with Sales3 AS (
81
      SELECT
82
        Kubs.FACT_SALES.ProductID,
83
        Kubs.FACT_SALES.CustomerID,
84
        Kubs.FACT_SALES.SalesPersonID,
85
        Kubs.FACT_SALES.OrderDate,
86
        Kubs.FACT_SALES.ShipDate,
87
        Kubs.FACT_SALES.OrderQty,
        Kubs.FACT_SALES.UnitPrice,
89
        Kubs.FACT_SALES.UnitPriceDiscount,
90
        Kubs.FACT_SALES.LineTotal
91
      FROM Kubs.FACT_SALES
92
      WHERE OrderDate >= 20130101 AND OrderDate < 20140000
94
   INSERT INTO Kubs.FACT_SALES_2013
95
96
    with Sales4 AS (
97
      SELECT
98
        Kubs.FACT_SALES.ProductID,
99
        Kubs.FACT_SALES.CustomerID,
100
        Kubs.FACT_SALES.SalesPersonID,
101
        Kubs.FACT_SALES.OrderDate,
102
        Kubs.FACT_SALES.ShipDate,
103
        Kubs.FACT_SALES.OrderQty,
104
        Kubs.FACT_SALES.UnitPrice,
105
        Kubs.FACT_SALES.UnitPriceDiscount,
106
        Kubs.FACT_SALES.LineTotal
107
      FROM Kubs.FACT_SALES
108
      WHERE OrderDate >= 20140101
109
110
   INSERT INTO Kubs.FACT_SALES_2014
```

Listing 1: Tworzenie i wypełnianie tabeli DIM TIME.

Następnie należało dodać każdą z tabel do projektu, a potem do partycji w kostce.



Rysunek 17: Dodane partycje

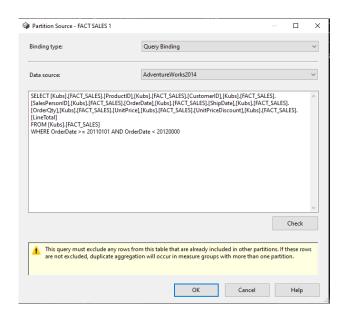


Rysunek 18: Wynik

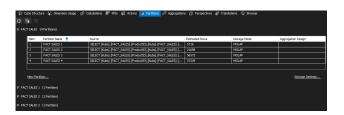
Uzasadnienie: Lepsza izolacja danych, potencjalnie szybsze przetwarzanie partycji (odczyt z mniejszych tabel), zgodność z procesami ETL ładującymi dane rocznie, większa możliwość automatyzacji procesu, zwłaszcza dla zmieniających się danych - tak jak tutaj, dla lat.

4.2 Sposób drugi

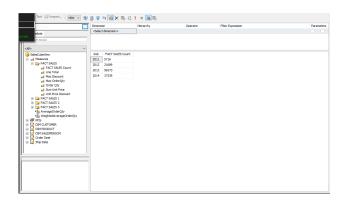
W tej metodzie wszystkie dane pozostają w oryginalnej tabeli 'FACT_SALES'. Partycje tworzone są przez zdefiniowanie zapytania SQL (query binding) dla każdej z nich, które wybiera dane tylko dla konkretnego roku za pomocą klauzuli 'WHERE'



Rysunek 19: Zmieniony kod SQL w partycji - dodana klauzula WHERE ograniczająca daty



Rysunek 20: Dodane partycje



Rysunek 21: Wynik

Uzasadnienie: Brak konieczności tworzenia dodatkowych tabel w bazie SQL, prostsze zarządzanie bazą danych, łatwiejsza zmiana kryteriów partycjonowania (modyfikacja zapytań).

5 Zad. 5. * Definiowanie KPI

5.1 Prosty wskaźnik KPI

Przygotować wskaźnik KPI (zakładka KPI), która umożliwi podział klientów na dobrych i lepszych w zależności od liczby sztuk zamówionych produktów.

Tworząc nowy wskaźnik należy podać jego nazwę, wybrać (przeciągnąć) miarę, na podstawie której będzie dokonany podział zbioru, wybrać odpowiedni status (np. *Shapes*) i podać warunek:

```
iif([Measures].[OrderQty] < \eta, -1 /*czerwony*/, 1 /*zielony*/)
```

Należy uzasadnić wybór wartości progowej η .

Po przeprocesowaniu kostki, należy zobrazować działanie wskaźnika dla wybranych atrybutów w raporcie w Excelu.

Postanowiono przyjąć KPI dzielące klientów na 2 grupy - około top 20% "elitarnych"klientów i całą resztę.

```
SELECT TOP 20 PERCENT OrderQty
FROM Kubs.FACT_SALES
ORDER BY OrderQty DESC;
```

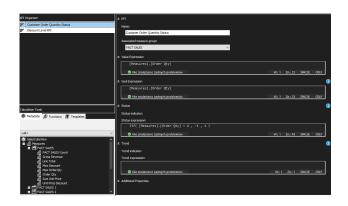
Listing 2: Kwerenda znajdująca dane do wyliczenia KPI

Po krótkiej analizie wyników okazało się, że wartość progową η można wyznaczyć jako 4. Tak więc kliencie, którzy kupili co najmniej 4 przedmioty, są elitarni.

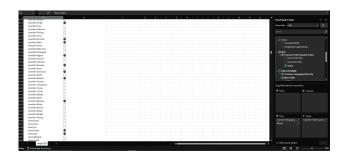
Wybór wartości granicznej równej 20% wynika z konceptu "krzywej wieloryba" (ang. whale curve), gdzie:

- Top 20% klientów generuje ponad 100% zysku,
- Środkowe 60% klientów przynosi niewielki zysk lub bilansuje się,
- Najsłabsze 20% klientów generuje straty, przez co łączny zysk netto wraca do poziomu poniżej 100%.

Koncepcja ta pomaga zrozumieć, że niewielka część klientów odpowiada za większość rentowności firmy, co uzasadnia przyjęcie progu 20% w konstrukcji KPI. [1]



Rysunek 22: Sposób obliczenia KPI



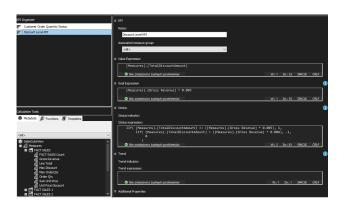
Rysunek 23: Tabela przestawna z widokiem na wartości KPI

5.2 KPI na podstawie kalkulowanej miary

Zaproponować własną miarę w zakładce $Calculation \rightarrow New \ Calculated \ Member,$ (np. zysk z uwzględnieniem rabatu i frachtu), na podstawie której zostanie zdefiniowany odpowiedni wskaźnik KPI. Należy przeanalizować status opracowanego wskaźnika oraz jego trend. Wynik należy zaprezentować w wybranym kontekście.

Zdefiniowano własną miarę kalkulowaną 'Total Discount Amount' (Całkowita Wartość Rabatu) jako różnicę między przychodem brutto (wymagało użycia dodanej wcześniej miary 'Gross Revenue') a przychodem netto ('Line Total').

Na podstawie tej miary stworzono 'Discount Level KPI', który ocenia poziom rabatu względem przychodu brutto (cel: <=.5%, źle: >.8%) oraz pokazuje trend porównując wartość rabatu do roku poprzedniego.



Rysunek 24: Sposób obliczenia KPI

Row Labels 🔻	Gross Revenue	TotalDiscountAmount	Discount Level KPI Goal	Discount Level KPI Status
 Accessories 	1278760,912	6688,0528	6393,804562	0
Bikes	95145813,35	494640,6947	475729,0668	0
Clothing	2141507,024	20964,5468	10707,53512	0
Components	11807808,02	5214,742	59039,04012	
■ Unknown				
Grand Total	110373889,3	527508,0363	551869,4466	•

Rysunek 25: Tabela przestawna z widokiem na wartości KPI



Rysunek 26: Tabela przestawna z widokiem na wartości KPI z trendami

6 Wnioski

Realizacja laboratorium pozwoliła na pogłębienie wiedzy na temat zaawansowanych funkcji SSAS.

Modyfikacja wymiarów i tworzenie hierarchii znacząco poprawia czytelność i możliwości analizy danych w kostce OLAP, umożliwiając drążenie danych.

Miary kalkulowane pozwalają na definiowanie bardziej złożonych wskaźników biznesowych bezpośrednio w kostce przy użyciu MDX, bez konieczności modyfikacji źródła danych.

Różnica między średnią arytmetyczną a ważoną może być znacząca w zależności od kontekstu biznesowego. W tym biznesie raczej większe znaczenie będzie miała dobra średnia ważone, gdyż przekazuje ona więcej informacji o znaczeniu biznesowym.

Partycjonowanie tabel faktów jest kluczową techniką optymalizacyjną, szczególnie dla dużych hurtowni danych, przyspieszając przetwarzanie i potencjalnie zapytania. Wybór metody partycjonowania (osobne tabele vs zapytania) zależy od specyfiki systemu źródłowego i procesów ETL.

Definiowanie KPI umożliwia szybką wizualną ocenę kluczowych wskaźników biznesowych oraz ich trendów, co jest niezwykle przydatne w raportowaniu i analizie menedżerskiej. Z drugiej strony, trzeba uważać na złe KPI stworzona w drugim podpunkcie KPI może wprowadzić w błąd trendem ujemnym. W tym przypadku po głębszej analizie okazuje się, że ponieważ zyski sklepu i jego popularność rosną, to zwiększyła się liczba zniżek. Można by ulepszyć KPI, by trend brał pod uwagę zmiany w sprzedaży ogólnie aktualnie tego nie robi.

Bibliografia

[1] Baker Tilly. Visualizing Customer Profitability with the Whale Curve. Accessed: 2025-05-04. 2021. URL: https://www.bakertilly.com/insights/visualizing-customer-profitability-with-the-whale-curve.