

Model skarbcza danych - Uczelnia (Data Vault)

Mikołaj Kubś

1 Model i opisy wygenerowane przez sztuczną inteligencję - ChatGPT, model 4o

1.1 Dziedzina

Uczelnia wyższa - model dotyczy danych operacyjnych związanych ze studentami, prowadzącymi oraz kursami.

1.2 Huby (klucze biznesowe)

HUB_Student

- **Student_ID** - np. numer indeksu
- Atrybuty biznesowe: brak (wszystkie zmienne w satelitach)

HUB_Prowadzacy

- **Prowadzacy_ID** - np. PESEL lub ID uczelniane
- Atrybuty biznesowe: brak

HUB_Kurs

- **Kurs_ID** - np. kod kursu
- Atrybuty biznesowe: brak

1.3 Linki (relacje biznesowe)

LINK_Student_Kurs

- Student_ID
- Kurs_ID
- Relacja: student zapisany na kurs

LINK_Kurs_Prowadzacy

- Kurs_ID
- Prowadzacy_ID
- Relacja: prowadzący przypisany do kursu

LINK_Egzamin

- Student_ID
- Kurs_ID
- Data_Egzaminu
- Relacja: podejście studenta do egzaminu

1.4 Satelity (miary i wymiary)

SAT_Student_Dane

- Student_ID, Imię, Nazwisko, Email
- Data_Wejscia, Data_Wyjscia

SAT_Prowadzacy_Dane

- Prowadzacy_ID, Imię, Nazwisko, Tytuł, Email
- Data_Wejscia, Data_Wyjscia


SAT_Kurs_Dane

- Kurs_ID, Nazwa, ECTS, Semestr
- Data_Wejscia, Data_Wyjscia

SAT_Oceny

- Student_ID, Kurs_ID, Data_Egzaminu
- Ocena, Poprawka (boolean)
- Data_Wejscia, Data_Wyjscia

1.5 Schemat (opis tekstowy)



1.6 Potencjalne rozszerzenie modelu

Nowy HUB: Grupa_zajeciowa

- Grupa_ID (np. ID grupy)

LINK_Student_Grupa

- Student_ID, Grupa_ID

LINK_Prowadzacy_Grupa

- Prowadzacy_ID, Grupa_ID

LINK_Grupa_Sala

- Grupa_ID, Sala_ID

SAT_Grupa_Dane

- Grupa_ID, Typ_zajec, Dzień_tygodnia, Godzina
- Data_Wejscia, Data_Wyjscia

1.7 Odpowiedzi na pytania dodatkowe

- **Gdzie są przechowywane zmiany (np. nazwiska)?**

W satelitach *SAT_Student_Dane*, *SAT_Prowadzacy_Dane* - każda zmiana to nowy rekord z nową datą wejścia.

- **Gdzie są informacje o ocenie z egzaminu poprawkowego?**

W *SAT_Oceny* - nowy rekord z tą samą kombinacją student-kurs, ale z nową datą i flagą *Poprawka = True*.

- **Jak oddzielić dane wrażliwe?**

Umieścić je w osobnych satelitach (np. *SAT_Student_Prywatne*) i zabezpieczyć dostęp na poziomie bazy.


- **Jak obsłużyć rozszerzenie modelu o grupy?**

Dodać *HUB_Grupa_zajeciowa* i powiązane linki - Data Vault umożliwia łatwe rozszerzanie bez naruszenia istniejącej struktury.

2 Ocena i poprawki modelu wygenerowanego przez sztuczną inteligencję

ChatGPT nie poradził sobie najgorzej i nawet stworzył piękny diagram przedstawiający relacje. Ale popełnił oczywiście różne błędy.

- Nie jest to szeroko znany fakt, ale jak poruszono na wykładzie, PESEL nie powinien nigdy być unikatowym kluczem z racji występowania niewielu duplikatów w historii jego nadawania. Zdecydowanie lepiej użyć klucza zastępczego.
- Generalnie idea hubów poprawna - nie wspomniał, że huby mają klucz biznesowy i główny (często hash biznesowego czy numeru sekwencyjnego). Kluczem biznesowym może być jak najbardziej np. numer indeksu. Oczywiście trzeba byłoby być pewnym, że ID uczelniane, kod kursu czy numer indeksu są unikalne i stabilne. Każdy hub powinien mieć też datę załadowania rekordu (Load_Date) i źródło rekordu (Record_Source).
- Generalnie linki dobrze. Jak wyżej, każdy link musi mieć datę załadowania i źródło. Mógł dodać, że kluczem linku jest (unikatowy) hash kluczy biznesowych, z którymi jest połączony (link łączy huby). LINK_Egzamin potem jest używany przez SAT_Oceny i jednym z kluczy jest Data_Egzaminu, co prowadzi do tego, że nie dałoby się rozróżnić dwóch egzaminów z tego samego kursu dla tego samego studenta w tym samym dniu. Tak więc Data_Egzaminu musi być unikalna. Kolejnym problemem jest sama data jako klucz - jest to niepoprawne, LINK musi być połączeniem między hubami. Żeby nie było niejasności, najlepiej stworzyć z egzaminu HUB z danymi, czy jest poprawką, datą i godziną.
- Satelita powinna mieć tylko jednego rodzica - SAT_Oceny ma dwóch. Powinien więc być przyłączony do linku egzaminu. Ale ogólnie jest problem z tą satelitą - z wielu kursów ocenę ma się bez egzaminu - np. przepis czy inna zasada. Tak więc ta satelita dobrze określa ocenę z konkretnego egzaminu, ale LINK_Student_Kurs powinien mieć osobną satelitę z oceną finalną (która mogłaby być potem zmieniona, gdyby zaszła taka potrzeba). Data_Wejscia, Data_Wyjscia = Load_Date, Load_End_Date => OK.
- Schemat wyszedł oczywiście fatalnie. Nie ma połączenia linku LINK_Student_Kurs a HUB_Kurs. Połączenia prowadzący źle. Brak link egzamin. Satelita student dane połączony z hubem i linkiem naraz. Na końcu raportu przedstawiono poprawiony diagram. Tutaj jeszcze próba wygenerowania obrazka schematu przez ChatGPT:




Rysunek 1: Schemat wygenerowany przez sztuczną inteligencję - jeszcze gorszy

- Potencjalne rozszerzenia: pomysł z grupą ok. Ale grupa zajęciowa powinna być połączona z kursem, a prowadzący wtedy zamiast z kursem mógłby być połączony z grupą. Jeśli miałyby być link grupa - sale, sala też mogłaby być hubem (mogłaby być SAT_Sala_Dane - budynek, numer sali, informacje

czy jest apteczka albo gaśnica). Sama grupa może mieć limit miejsc, dzień tygodnia, godzinę i regularność (normalna, parzyste, nieparzyste). Dodatkowo: w aktualnych czasach zdarzają się zajęcia zdalne. Politechnika rozwiązała problem sal dla zajęć zdalnych, tworząc sztuczne "sale" wirtualne. Nie jest to najgorsze rozwiązanie, Data Vault raczej nie zezwala na bardzo elastyczne struktury danych.

- Odpowiedzi na pytania dodatkowe poprawne.

Schemat, który powinien poprawić większość błędów:



Rysunek 2: Schemat wygenerowany przez moją inteligencję