

Model skarbcza danych - Uczelnia (Data Vault)

Mikołaj Kubś

1 Model wygenerowany przez sztuczną inteligencję - ChatGPT

1.1 Dziedzina

Uczelnia wyższa - model dotyczy danych operacyjnych związanych ze studentami, prowadzącymi oraz kursami.

1.2 Huby (klucze biznesowe)

HUB_Student

- **Student_ID** - np. numer indeksu
- Atrybuty biznesowe: brak (wszystkie zmienne w satelitach)

HUB_Prowadzacy

- **Prowadzacy_ID** - np. PESEL lub ID uczelniane
- Atrybuty biznesowe: brak

HUB_Kurs

- **Kurs_ID** - np. kod kursu
- Atrybuty biznesowe: brak

1.3 Linki (relacje biznesowe)

LINK_Student_Kurs

- Student_ID
- Kurs_ID
- Relacja: student zapisany na kurs

LINK_Kurs_Prowadzacy

- Kurs_ID
- Prowadzacy_ID
- Relacja: prowadzący przypisany do kursu

LINK_Egzamin

- Student_ID
- Kurs_ID
- Data_Egzaminu
- Relacja: podejście studenta do egzaminu

1.4 Satelity (miary i wymiary)

SAT_Student_Dane

- Student_ID, Imię, Nazwisko, Email
- Data_Wejscia, Data_Wyjscia

SAT_Prowadzacy_Dane

- Prowadzacy_ID, Imię, Nazwisko, Tytuł, Email
- Data_Wejscia, Data_Wyjscia


SAT_Kurs_Dane

- Kurs_ID, Nazwa, ECTS, Semestr
- Data_Wejscia, Data_Wyjscia

SAT_Oceny

- Student_ID, Kurs_ID, Data_Egzaminu
- Ocena, Poprawka (boolean)
- Data_Wejscia, Data_Wyjscia

1.5 Schemat (opis tekstowy)



1.6 Potencjalne rozszerzenie modelu

Nowy HUB: Grupa_zajeciowa

- Grupa_ID (np. ID grupy)

LINK_Student_Grupa

- Student_ID, Grupa_ID

LINK_Prowadzacy_Grupa

- Prowadzacy_ID, Grupa_ID

LINK_Grupa_Sala

- Grupa_ID, Sala_ID

SAT_Grupa_Dane

- Grupa_ID, Typ_zajec, Dzień_tygodnia, Godzina
- Data_Wejscia, Data_Wyjscia

1.7 Odpowiedzi na pytania dodatkowe

- **Gdzie są przechowywane zmiany (np. nazwiska)?**

W satelitach *SAT_Student_Dane*, *SAT_Prowadzacy_Dane* - każda zmiana to nowy rekord z nową datą wejścia.

- **Gdzie są informacje o ocenie z egzaminu poprawkowego?**

W *SAT_Oceny* - nowy rekord z tą samą kombinacją student-kurs, ale z nową datą i flagą *Poprawka = True*.

- **Jak oddzielić dane wrażliwe?**

Umieścić je w osobnych satelitach (np. *SAT_Student_Prywatne*) i zabezpieczyć dostęp na poziomie bazy.


- **Jak obsłużyć rozszerzenie modelu o grupy?**

Dodać *HUB_Grupa_zajeciowa* i powiązane linki - Data Vault umożliwia łatwe rozszerzanie bez naruszenia istniejącej struktury.

2 Ocena modelu wygenerowanego przez sztuczną inteligencję

ChatGPT nie poradził sobie najgorzej i nawet stworzył diagram przedstawiający relacje. Ale popełnił oczywiście różne błędy.

- Nie jest to szeroko znany fakt, ale jak poruszono na wykładzie, PESEL nie powinien nigdy być unikatowym kluczem z racji występowania niewielu duplikatów w historii jego nadawania. Zdecydowanie lepiej użyć klucza zastępczego.
- Generalnie idea hubów poprawna - nie wspomniał, że huby mają klucz biznesowy i primary (często hash biznesowego czy numeru sekwencyjnego). Oczywiście trzeba byłoby być pewnym, że ID uczelniane, kod kursu czy numer indeksu są unikalne i stabilne. Każdy hub powinien mieć też datę załadowania (Load_Date) i źródło (Record_Source).
- Generalnie linki dobrze. Jak wyżej, każdy link musi mieć datę załadowania i źródło. Mógł dodać, że kluczem linku jest hash kluczy biznesowych. LINK_Egzamin potem jest używany przez SAT_Oceny i jednym z kluczy jest Data_Egzaminu, co prowadzi do tego, że nie dałoby się rozróżnić dwóch egzaminów z tego samego kursu dla tego samego studenta w tym samym dniu. Tak więc Data_Egzaminu musi być unikalna. Kolejnym problemem jest sama data jako klucz - jest to niepoprawne, LINK musi być połączeniem między hubami. Pewnym rozwiązaniem byłoby dodanie HUB z datami - rozwiązuje to problem ich unikalności.
- Satelita powinna mieć tylko jednego rodzica - SAT_Oceny ma dwóch. Powinien więc być przyłączony do linku egzaminu. Ale ogólnie jest problem z tą satelitą - z wielu kursów ocenę ma się bez egzaminu - np. przepis czy inna zasada. Tak więc ta satelita dobrze określa ocenę z konkretnego egzaminu, ale LINK_Student_Kurs powinien mieć osobną satelitę z oceną finalną (która mogłaby być potem zmieniona, gdyby zaszła taka potrzeba). Data_Wejscia, Data_Wyjscia = Load_Date, Load_End_Date => OK.
- Schemat wyszedł oczywiście fatalnie. Nie ma połączenia linku LINK_Student_Kurs a HUB_Kurs. Połączenia prowadzący źle. Brak link egzamin. Satelita student dane połączony z hubem i linkiem naraz. Na końcu raportu przedstawiono poprawiony diagram. Tutaj jeszcze próba wygenerowania obrazka schematu przez ChatGPT:




Rysunek 1: Schemat wygenerowany przez sztuczną inteligencję - jeszcze gorszy

- Potencjalne rozszerzenia: pomysł z grupą ok. Ale grupa zajęciowa powinna być połączona z kursem, a prowadzący wtedy zamiast z kursem mógłby być połączony z grupą. Grupa też nie musi być hubem - mogłaby być linkiem łączącym studentów, kurs i prowadzącego. Jeśli miałyby być link grupa - sala, sala też musiałaby być hubem oczywiście (mogłaby być SAT_Sala_Dane - budynek, numer sali, informacje czy jest apteczka albo gaśnica).

- Odpowiedzi na pytania dodatkowe chyba poprawne.

Schemat, który powinien poprawić większość błędów:



Rysunek 2: Schemat wygenerowany przez moją inteligencję