

Data Mining w praktyce: przewidywanie zachowań klientów AdventureWorks z użyciem Pythona

Mikołaj Kubś 272662

Data mining – podstawy

- Data Mining (eksploracja danych / knowledge discovery in databases - KDD) polega na znalezieniu nieoczywistych wzorców, trendów i zależności istniejących w dużym zbiorze danych.
- Może albo pomóc opisać zbiór danych, albo przewidzieć rezultat na podstawie algorytmów uczenia maszynowego czy nawet sztucznej inteligencji.
- Firmy wykorzystują te relacje do podejmowania mądrzejszych decyzji – od prognozowania sprzedaży po dogłębne zrozumienie zachowań klientów.

Zyski

- Data mining bierze surowe dane i znajduje w nich pewien porządek. To może pomóc podejmować decyzje w wielu różnych korporacyjnych i przemysłowych działach, jak reklamowanie/marketing, finanse, sektor publiczny, sektor zdrowotny, HR, produkcja, sprzedaż czy zarządzanie łańcuchem dostaw (SCM)
- Oszczędności: dzięki analizie danych o wydajności z wielu źródeł, można zidentyfikować problemy w procesach biznesowych. Dzięki takiej identyfikacji łatwiej będzie się ich pozbyć i zwiększyć wydajność i szybkość takich procesów.
- Data mining to wszechstronne narzędzie - każdy dział, który zbiera i analizuje dane, może z niego skorzystać.

Wyzwania

- Złożoność - data mining wymaga wiedzy z wielu dziedzin IT - data engineering, data analysis i machine learning. Przyda się solidna wiedza z Pythona/R i SQLa. Bez dobrej znajomości machine learningu czy popełnienia błędów na poprzednich krokach, łatwo wytworzyć analizy oparte na kompletnie nieprawdziwych danych. Trzeba też uważać na nieujawnianie danych osobowych.
- Wymóg szerokiego i szczegółowego zbioru danych - trudne, zwłaszcza w dużych, starszych firmach, gdzie dane mogą być nieuporządkowane i niskiej jakości. Data mining wymaga czystego i dużego zbioru danych - najlepiej na podstawie Data Warehouse, którego zbudowanie będzie trudne, zwłaszcza z różnymi data pipelines łączące bardzo różne źródła danych.
- Niepewność - nawet dobrze przeprowadzona próba data mining może nie przynieść żadnych wartościowych rezultatów. Gorzej, jeśli zwróci rezultaty niezgodne z prawdą na podstawie różnych błędów w tym skomplikowanym procesie. Trzeba też pamiętać, że korelacja nie oznacza związku przyczynowego. Dobra, krytyczna analiza jest tu, jak zawsze, ważna.

Nowoczesne narzędzia

❗ Important

Data mining was deprecated in SQL Server 2017 (14.x) Analysis Services and now discontinued in SQL Server 2022 (16.x) Analysis Services. Documentation is not updated for deprecated and discontinued features. To learn more, see [Analysis Services backward compatibility](#).

- Niestety jak widać, należy używać starszej wersji SQL Server Analysis Services, aby wykonać data mining właśnie w Analysis Services. Dlatego skorzystałem z nowoczesnego narzędzia jakim jest Python, szeroko używanym do Machine Learningu i data engineering dzięki jego prostocie i bogactwie bibliotek. Innym językiem programowania często używanym w data science jest R. Przyda się też wiedza z SQL, którego używa się na każdym kroku w prawie każdej firmie zbierającej i analizującej swoje dane.

Analiza w praktyce

- Zajmijmy się praktycznym przykładem Data mining dla dobrze znanego nam zbioru danych - AdventureWorks, a dokładniej jego Data Warehouse odpowiednika - AdventureWorksDW2014. Wybrałem wersję Data Warehouse, bo przechowuje czyste i zintegrowane dane, np. view o nazwie dbo.vTargetMail
- Postaramy się dowiedzieć, co sprawia, że dany klient kupi rower? Jako cech użyjemy różnych danych demograficznych, jakie zbiera firma.
- Aby dojść do odpowiedzi, skorzystamy z potężnego i intuicyjnego algorytmu klasyfikacyjnego - Decision Tree / Drzewo Decyzyjne. Decision Tree działa jak schemat blokowy, zadając serię pytań, aby dojść do ostatecznej decyzji. Wynik można też łatwo zwizualizować i zrozumieć.

Analiza w praktyce

- Przejdźmy do notebooka Jupyter, gdzie łatwiej będzie przeprowadzić resztę prezentacji