

Hurtownie danych

Architektury danych

dr inż. Bernadetta Maleszka


Architektura

- ▶ Ogólnie:
- ▶ Zbiór zasad i struktur będących szkieletem ogólnego projektu systemu lub produktu
- ▶ Struktura hurtowni danych - kolejne warstwy danych, przy czym każda następna warstwa stanowi przetworzenie poprzedniej:
 - ▶ **źródła danych**, czyli zastane bazy danych - rozproszone, niejednorodne, często niespójne
 - ▶ centralna hurtownia danych - podstawowe miejsce przechowywania nieulotnej informacji
 - ▶ hurtownie tematyczne, lokalne
 - ▶ aplikacje użytkowników
 - ▶ dodatkowo: baza metadanych

Cechy architektury danych dla hurtowni danych

- ▶ dane pochodzą z systemów źródłowych, baz danych lub plików
- ▶ dane z systemów źródłowych podlegają procesom ETL przed wprowadzeniem ich do hurtowni
- ▶ trwała analityczna baza danych jest przystosowana do przetwarzania wspomagającego podejmowanie decyzji
- ▶ użytkownicy mają dostęp do hurtowni przez specjalnie zaprojektowane narzędzia

Hurtownia danych



Rozwinięcia architektury ogólnej

- ▶ Konkretnie wdrożenia rozwijają poszczególne komponenty architektury ogólnej
- ▶ Zwykle dąży się do integracji architektury HD z architekturą aktualnie działającego systemu
- ▶ Przykłady rozwinięć:
 - ▶ wyodrębnienie hurtowni tematycznych jako element pośredni pomiędzy centralną hurtownią a aplikacjami użytkownika
 - ▶ hurtownia tematyczna zbudowana bezpośrednio po integracji danych
 - ▶ zintegrowana relacyjna baza danych jako element pośredni pomiędzy fazą integracji danych a HD

Typowe modele hurtowni danych

- ▶ Architektura zcentralizowana
 - ▶ materialna centralna hurtownia danych
- ▶ Architektura federacyjna
 - ▶ wirtualna centralna hurtownia danych jako niematerializowana perspektywa o wspólnym schemacie logicznym i pojęciowym
 - ▶ dane fizycznie przechowywane w magazynach danych operacyjnych
 - ▶ spadek wydajności ze względu na możliwość rozproszenia magazynów danych operacyjnych
- ▶ Architektura warstwowa
 - ▶ wiele warstw hurtowni tematycznych zawierających coraz wyższe stopnie agregacji danych
 - ▶ wszystkie warstwy zmaterializowane (wydajność)
 - ▶ optymalizacja wielkości danych w hurtowniach tematycznych


Dane
Źródłowe

Zbieranie
Danych


Składowanie
Danych

Dostarczanie
informacji

Scentralizowana
(ang. centralized)



Scentralizowana z
zależnymi
Hurtowniami Tematycznymi
(ang. Hub-and-Spoke)




Niezależne
Hurtownie Tematyczne
(ang. Independent Data Marts)



Unia Hurtowni
Tematycznych
(ang. Data-Mart Bus)



Federacyjna
(ang. Federated)



Infrastruktura hurtowni danych

- ▶ Ściśle powiązana z architekturą
- ▶ Wszelkie techniki, systemy, platformy, bazy danych, bramy i itp. niezbędne do zrealizowania wybranej architektury
- ▶ Cechy architektur BI:
 - ▶ skalowalność
 - ▶ dostępność
 - ▶ bezpieczeństwo
 - ▶ zarządzanie
 - ▶ współdziałanie

Infrastruktura hurtowni danych

- ▶ Dane źródłowe:
 - ▶ format danych
 - ▶ sposób udostępnienia (dysk, sieć, protokół, itp.)
 - ▶ schemat zależności pomiędzy systemami
 - ▶ szkolenia dotyczące układów danych poszczególnych systemów źródłowych
- ▶ Integracja danych
 - ▶ narzędzia konwersji danych
 - ▶ narzędzia klasy ETL
 - ▶ sprzęt i oprogramowanie bazy danych
 - ▶ sieć i bramy łączące źródła danych z bazą

Infrastruktura hurtowni danych

- ▶ Hurtownia danych
 - ▶ sprzęt i oprogramowanie hurtowni
 - ▶ technologia przechowywania agregacji
 - ▶ harmonogramowanie zadań
 - ▶ kompetencje administratora
- ▶ Narzędzia użytkownika
 - ▶ szkolenia dla użytkowników
 - ▶ metadane
 - ▶ narzędzia nawigacji po metadanych
 - ▶ osobiste narzędzia analityczne i raportujące
 - ▶ repozytoria raportów

Ewolucja potrzeb

- ▶ rozmiar danych (petabajty -> setki petabajtów)
- ▶ przechowywanie danych
- ▶ sieć
- ▶ możliwości obliczeniowe
 - ▶ wiarygodność
 - ▶ integracja
 - ▶ efektywne zarządzanie
- ▶ architektura danych


Ewolucja architektur danych


- ▶ Relacyjne hurtownie danych
- ▶ Jezioro danych (kałuża danych -> staw danych -> jezioro danych -> ocean danych)
 - ▶ ang. *data puddle* -> *data pond* -> *data lake* -> *data ocean*
- ▶ Wirtualizacja danych
- ▶ Nowoczesne hurtownie danych
- ▶ Tkanina danych (ang. *data fabric*)
- ▶ Platforma danych (ang. *data platform*)
- ▶ Repozytorium danych (ang. *data lakehouse*)
- ▶ Siatka (sieć) danych (ang. *data mesh*)

Jezioro danych

- ▶ Dixon, 2011
- ▶ ujednolicone repozytorium dla wszystkich danych z różnych źródeł
- ▶ scentralizowane przechowywanie danych oddzielone od przetwarzania
- ▶ początek: niedrogie i skalowalne rozwiązania np. Apache Hadoop Distributed File System (HDFS)
- ▶ dziś: rozproszone magazyny obiektów w chmurze
- ▶ strefy - logiczna izolacja -> niezależne rozwijanie, wdrażanie i rozszerzanie:
 - ▶ strefa surowa - natywny format, wiele wersji, ograniczony dostęp biznesu
 - ▶ strefa czysta - wspomaga pobieranie danych, zachowując jednocześnie ich integralność i ograniczając dostęp do nich oraz ich transformację przez użytkowników biznesowych
 - ▶ strefa rafinowana - zaufane dane, zamaskowane informacje poufne, po transformacji
 - ▶ strefa eksploracji - produkty danych biznesowych i analitycznych, które przeszły transformacje specyficzne dla domeny, optymalizacja modelu, selekcja wg potrzeb

Jezioro danych - etapy dojrzałości





Jezioro danych


Korzyści

- ▶ efektywność kosztowa
- ▶ elastyczność
- ▶ elastyczność schematu
- ▶ zarządzanie jakością danych


Wyzwania

- ▶ pochodzenie danych
- ▶ selektywny dostęp do surowych danych
- ▶ ograniczenia zwinności
- ▶ dane jako zasób, nie produkt
- ▶ wyzwania operacyjne


Na terenie firmy



W chmurze




Logiczne jezioro danych



Wirtualizacja danych/federacja

- ▶ logiczna warstwa danych, która umożliwia aplikacjom pobieranie i manipulowanie danymi bez konieczności szczegółowej wiedzy na temat systemów bazowych
- ▶ umożliwia dostęp w czasie rzeczywistym do danych bezpośrednio ze źródła, eliminując potrzebę przenoszenia lub replikowania danych
- ▶ nie narzuca pojedynczego modelu danych, ale zamiast tego zarządza ujednoliconymi danymi, aby zapewnić scentralizowane bezpieczeństwo i zarządzanie

Wirtualizacja danych/federacja



Możliwości oprogramowania do wirtualizacji danych

- ▶ **Abstrakcja:** uniezależnienie od systemów bazowych, ich lokalizacji, struktury pamięci masowej, API, języka dostępu
- **Wirtualny dostęp do danych:** wspólny logiczny model danych; umożliwia łączenie z różnymi źródłami danych, w tym bazami danych, magazynami danych, aplikacjami w chmurze, repozytoriami dużych zbiorów danych, a nawet plikami programu Excel
- **Transformacja i federacja danych:** jednolite widoki danych po przekształceniach, poprawie jakości danych, agregacjach czy połączeniu widoków biznesowych
- **Dostarczanie danych w czasie rzeczywistym:** informacje aktualne

Wirtualizacja danych/federacja

Korzyści

- ▶ ochrona systemów źródłowych
- ▶ dostęp do danych w czasie rzeczywistym
- ▶ zoptymalizowane przetwarzanie zapytań
- ▶ samoobsługowy dostęp do danych
- ▶ centralne zarządzanie i bezpieczeństwo
- ▶ wydajność zasobów programistycznych


Wyzwania

- ▶ wpływ na systemy operacyjne
- ▶ brak zarządzania danymi historycznymi
- ▶ złożoność zarządzania zmianami
- ▶ niezgodność ze złożonymi zapytaniami analitycznymi
- ▶ konflikt o zasoby
- ▶ obliczenia kontra koszty przechowywania
- ▶ obawy dotyczące wysokiej dostępności

Nowoczesne hurtownie danych

- ▶ Jezioro danych - przechowywanie i przygotowanie danych -> data scientists
- ▶ Hurtownia danych - bezpieczeństwo, obsługa, zgodność -> użytkownicy biznesowi

Nowoczesne hurtownie danych



Nowoczesne hurtownie danych

Korzyści

- ▶ wszechstronność w obsłudze danych
- ▶ lepsza wydajność raportowania i analizy biznesowej
- ▶ elastyczna skalowalność
- ▶ analityka w czasie rzeczywistym
- ▶ lepsza wydajność przetwarzania danych
- ▶ elastyczne modelowanie danych
- ▶ efektywność kosztowa
- ▶ większe bezpieczeństwo danych

Wyzwania

- ▶ Zwiększona złożoność
- ▶ Duplikacja i zarządzanie danymi
- ▶ Wyzwania zgodności

Tkanina danych

- ▶ Data fabric to termin używany do opisu architektury polegającej na wzięciu rozbieżnych systemów i spleceniu ich razem, jak tkanina, w celu stworzenia spójnej warstwy na wierzchu danych organizacji
- ▶ Pomagają głównemu oficerowi danych i zespołowi ds. zarządzania danymi zarządzać dostępem do połączonych źródeł danych niezależnie od tego, gdzie są przechowywane - w tym hurtowni danych, jezior danych, systemów plików i aplikacji SaaS
- ▶ Architektura data fabric może skutecznie dostarczać rozszerzone spostrzeżenia i analitykę oraz wspiera połączoną naturę danych z rozbieżnych źródeł

Tkanina danych

- ▶ Struktura danych
 - ▶ rozszerzony katalog danych
 - ▶ graf wiedzy (semantyka)
 - ▶ aktywacja metadanych i silnik rekomendacji
 - ▶ przygotowanie i dostarczanie danych
 - ▶ orkiestracja i DataOps

Tkanina danych

Korzyści

- ▶ Ulepszona integracja i łączność danych
- ▶ Przyspieszone samodzielne wyszukiwanie danych
- ▶ Analityka i spostrzeżenia w czasie rzeczywistym
- ▶ Niższe koszty zarządzania danymi
- ▶ Zautomatyzowana orkiestracja i skalowanie
- ▶ Wzbogacone zasoby danych

Wyzwania

- ▶ Dojrzałość technologiczna
- ▶ Jakość metadanych
- ▶ Sztywne modele metadanych
- ▶ Ograniczenia regulacyjne
- ▶ Złożoność pozyskiwania wiedzy

Centrum/Platforma danych

- ▶ koncentruje się na integrowaniu danych i obsłudze zaawansowanej analityki na dużą skalę
- ▶ zintegrowany zespół usług niezależnych od domeny, które obsługują pobieranie, integrację, transformację, zarządzanie i dostarczanie danych
- ▶ modułowość, elastyczność, opłacalność
- ▶ dane jako produkt
- ▶ zdecentralizowane zarządzanie zorientowane dziedzinowo
- ▶ samoobsługa i usługi wspólne (środowisko eksploracyjne, katalogi zasobów danych, ramy jakości danych, orkiestrację procesów, przetwarzanie zdarzeń, zarządzanie ontologią i wspólnym słownictwem, audyt i monitorowanie, ochronę danych, wspólne ramy przetwarzania danych oraz wsparcie dla operacji związanych z danymi i rozwojem)
- ▶ rozwój przyrostowy

Centrum/Platforma danych

► Podstawowe moduły:

- magazynowanie
- pobieranie danych
- transformacja danych
- udostępnianie danych
- wspólne usługi uzupełniające (sieć, przetwarzanie, bezpieczeństwo, monitorowanie i zarządzanie)

Centrum/Platforma danych

Korzyści

- ▶ ramy programistyczne
- ▶ katalog danych
- ▶ podsystem przetwarzania zdarzeń i powiadomień
- ▶ orkiestracja procesów
- ▶ środowisko eksploracyjne
- ▶ audyt i monitorowanie
- ▶ ochrona danych
- ▶ jakość i zarządzanie
- ▶ zarządzanie danymi ontologicznymi i referencyjnymi

Wyzwania

- ▶ złożoność
- ▶ koszt
- ▶ zarządzanie ludźmi i zmianą

Repozytorium danych

- infrastruktura analityczna + skalowalność i opłacalność



Data Warehouse




Data Lake



Data Lakehouse

<https://www.oracle.com/pl/big-data/what-is-data-lakehouse/>

Repozytorium danych



Repozytorium danych

- ▶ Wykorzystaj istniejącą infrastrukturę jeziora danych
- ▶ Zapewnij spójność danych dzięki transakcjom ACID
- ▶ Obsługa egzekwowania schematu i jego ewolucji
- ▶ Wdrażaj mechanizmy zarządzania i audytu
- ▶ Oddzielenie zasobów pamięci masowej od zasobów obliczeniowych
- ▶ Zapewnij bezpośredni dostęp do danych
- ▶ Obsługa interfejsów API innych niż SQL do przetwarzania danych
- ▶ Korzystaj z otwartych formatów danych i interfejsów API
- ▶ Włącz strumieniowanie danych i analizę online

Repozytorium danych


► Wyzwania:

- Skupienie się na technologii
- Ograniczona uwaga poświęcona silosom danych i dopasowaniu biznesowemu
- Centralne zarządzanie kontra zwinność
- Niewystarczające rozwiązywanie problemów z integracją danych


Data Warehouse



Data Lake



Data Lakehouse



Siatka danych

- ▶ Siatka danych to zdecentralizowane podejście do zarządzania danymi, w którym wiele zespołów w firmie jest odpowiedzialnych za własne dane, promując współpracę i elastyczność

Steven Lin, product marketing manager w Semarchy

- ▶ Wykorzystywanie danych do analityki i poprawiania jakości danych
- ▶ Decentralizacja
- ▶ Zespół - właściciel swoich danych odpowiedzialny za cały cykl życia danych

Siatka danych


- ▶ Podejście socjotechniczne do udostępniania, uzyskiwania dostępu i zarządzania danymi analitycznymi w złożonych środowiskach na dużą skalę
- ▶ Zmiany:
 - ▶ organizacyjna
 - ▶ architektoniczna
 - ▶ technologiczna
 - ▶ operacyjna
 - ▶ systemu wartości

Siatka danych

► Zasady projektowania:

- Zorientowana na domenę zdecentralizowana własność danych
- Dane jako produkt - dane te są możliwe do odnalezienia, zrozumiałe, adresowalne, godne zaufania, bezpieczne, interoperacyjne, dostępne i wartościowe
- Samoobsługowa infrastruktura danych
- Rozproszona odpowiedzialność za jakość danych

Siatka danych



Siatka danych

Korzyści

- ▶ Dostosowane produkty danych
- ▶ Skalowalność dzięki decentralizacji
- ▶ Większa zwinność
- ▶ Elastyczny model zarządzania

Wyzwania

- ▶ Ludzie i zmiany kulturowe:
 - ▶ Większa odpowiedzialność
 - ▶ Braki umiejętności
 - ▶ Zdecentralizowana dynamika zespołu
 - ▶ Dopasowanie kulturowe
- ▶ Proces i struktura organizacyjna:
 - ▶ Granice domeny i własność
 - ▶ Zarządzanie i współpraca
 - ▶ Zarządzanie zmianą
- ▶ Technologia i infrastruktura:
 - ▶ Infrastruktura samoobsługowa
 - ▶ Integracja starszych systemów
 - ▶ Implementacja obliczeniowych zasad
 - ▶ Koszt i złożoność

Porównanie

Cechy	Relacyjna HD	Jezioro danych	Nowoczesna HD	Tkanina danych	Repozytorium danych	Siatka danych
Rok	1984	2010	2011	2016	2020	2019
Centralizacja	tak	tak	tak	tak	tak	nie
Typ składowania	relacyjny	obiektowy	relacyjny / obiektowy	relacyjny / obiektowy	obiektowy	zależny od dziedziny
Schemat	schema-on- write	schema-on- read	schema-on- write and schema-on- read	schema-on- write and schema-on- read	schema-on- read	zależny od dziedziny
Bezpieczeństwo	duże	małe -> średnie	średnie -> duże	duże	średnie	zależne od dziedziny

Porównanie

Cechy	Relacyjna HD	Jezioro danych	Nowoczesna HD	Tkanina danych	Repozytorium danych	Siatka danych
Całkowity koszt	wysoki	niski	średni	średni -> wysoki	niski -> średni	wysoki
Czas dostępu do danych	krótki	długi	krótki -> długi	krótki -> długi	średni -> długi	zależny od dziedziny
Czas oczekiwania	średnie	krótki	krótki	krótki	krótki	długi
Poziom trudności rozwoju	niski	średni	średni	średni	średni	wysoki
Stopień dojrzałości technologii	wysoki	średni	średni -> wysoki	średni -> wysoki	średni -> wysoki	niski
Niezbędne kompetencje	małe	małe -> średnie	średnie	średnie -> duże	średnie -> duże	duże

Podsumowanie

- ▶ 1970 - algebra relacyjna -> relacyjne BD + SQL
- ▶ dziś - nowoczesne architektury danych bez spójnych podstaw teoretycznych
- ▶ Oczekiwane aspekty:
 - ▶ oddzielenie pamięci masowej od obliczeniowej
 - ▶ redundancja danych
 - ▶ zarządzanie danymi
 - ▶ dane jako produkt
 - ▶ usługi oparte na AI

Dziękuję za uwagę

