

# Hurtownie danych

Data Vault - Skarbiec danych

dr inż. Bernadetta Maleszka

# Skarbiec danych


## Data Vault 2.0

- dobrze się skaluje
- umożliwia przyrostowe budowanie systemu, bez konieczności przepisywania istniejącego kodu (zwinne metodyki projektowe)
- oddziela zupełnie aspekt ładowania danych z systemów źródłowych od reguł biznesowych
- umożliwia pełen audyt danych
- model budowany jest przy użyciu szablonów, co ułatwia automatyzację procesu tworzenia fizycznych struktur danych (kod DDL) i ładowania danych
- kompatybilny z podejściem „insert-only” oraz umożliwia równoległe ładowanie danych

# Model Data Vault

- ▶ Dan Linstedt, Building a Scalable Data Warehouse with Data Vault 2.0
- ▶ huby - klucze biznesowe
- ▶ linki - relacje między kluczami
- ▶ satelity - struktury przechowujące atrybuty - dane opisujące klucze biznesowe lub relacje pomiędzy kluczami - wraz z historią zmian
- ▶ opcjonalnie dane referencyjne

# Przykładowy model




# Składowe Data Vault

- ▶ Raw Data Vault - dane surowe wraz z pełną historią (tak jak w źródle, uporządkowane twardymi regułami)
- ▶ Business Vault - opcjonalny obszar zasilany z Raw DV, w skład którego wchodzi obiekty, np.:
  - ▶ dodatkowe Huby ze zdeduplikowanymi kluczami
  - ▶ dodatkowi Satelici z atrybutami wyliczonymi lub poprawionymi wg reguł biznesowych
  - ▶ dodatkowe Linki potrzebne do połączenia wyliczonych Hubów z resztą modelu lub np. Linki reprezentujące relacje nieistniejące explicite w systemie źródłowym, ale np. wykryte przez algorytmy eksploracyjne
  - ▶ Obiekty techniczne przyspieszające wykonywanie zapytań (np. tabele Point-in-Time / PIT czy Bridge)

# ETL czy ELT?

- ▶ ETL
- ▶ najpierw ładujemy dane i robimy ich historyzację w Raw Data Vault a dopiero potem aplikujemy wszelkie „miękkie” reguły biznesowe
- ▶ stosunkowo łatwa implementacja wszelkich zmian logiki biznesowej

# Architektura Data Vault



# Architektura Data Vault

- ▶ Staging, gdzie ładowane są dane surowe z innych systemów
  - ▶ zmniejszanie obciążenia
  - ▶ unikanie transformacji
  - ▶ odzwierciedla strukturę oryginalnych danych (z audytowalnymi metadanymi)
- ▶ Warstwa hurtowni danych (Enterprise Data Warehouse)
  - ▶ raw data vault
  - ▶ metrics vault
  - ▶ operational vault
  - ▶ business vault




# Architektura Data Vault


- ▶ Warstwa informacji (Information Delivery) - zawierająca Information Marts, zamodelowane w sposób zrozumiały dla użytkownika końcowego, np. wykorzystując modele wielowymiarowe
  - ▶ dane gotowe do raportowania
  - ▶ dane dedykowane dla danego obszaru biznesowego, wyczyszczone, przetransformowane z zastosowaniem reguł biznesowych (soft business rules) oraz potencjalnie zagregowane
  - ▶ Error Mart - informacje dotyczące błędów, odrzuconych rekordów, złamanych reguł biznesowych
  - ▶ Meta Mart - wszelkiego rodzaju metadane

# Przypomnienie


- Kimball: *The data warehouse is nothing more than the union of all data marts*



- Inmon: *You can catch all the minnows in the ocean and stack them together – they still do not make a whale*



# Porównanie architektur



# Modelowanie Data Vault

- ▶ identyfikacja kluczy biznesowych w danych źródłowych
  - ▶ zbiór kluczy w tabeli hub
- ▶ identyfikacja relacji biznesowych
  - ▶ tabele typu link, które łączą ze sobą dwa huby
- ▶ identyfikacja miar i wymiarów, opisujących dane obiekty czy relacje
  - ▶ do każdego *huba i linku* można dołączyć przypisane do nich tabele zwane *satelitami*
- ▶ tabela *pit (Point-In-Time)*
  - ▶ powiązana z jednym hubem lub linkiem i wskazuje na rekordy każdego z satelitów, które obowiązują w danym momencie czasowym

# Przykład 1

- ▶ Bank otwiera nową działalność maklerską:
  - ▶ trzeba utworzyć bazę klientów domu maklerskiego, ich akcji, obligacji, transakcji, wpłat, wypłat...)
  - ▶ bank prowadzi obligatoryjny projekt budowy bazy kredytów na potrzeby raportowania dla KNF
  - ▶ dodatkowo jest w trakcie fuzji z innym bankiem (integracja z innym systemem)


# Identyfikacja kluczy biznesowych

- ▶ HUB\_KLIENCI - importujemy dane klienta z systemów depozytowego, leasingowego i maklerskiego

| źródło  | Klucz biznesowy |
|---------|-----------------|
| Leasing | 89010112345     |
| Makler  | 89010112345     |
| Depozyt | 89010112345     |
| Depozyt | 72121200033     |


# Identyfikacja relacji biznesowych

- ▶ Klienci kupują Produkty
- ▶ dokonują za nie Płatności
- ▶ czasami Klient ma dedykowanego doradcę spośród Pracowników
- ▶ Pracownicy pracują w zespołach



# Identyfikacja miar i wymiarów

- ▶ satelity dla huba:



- ▶ satelity dla linków, np.

- ▶ Wniosek Kredytowy o kredyt hipoteczny, który przyjmuje jeden Pracownik, a decyzję kredytową podejmuje drugi. Wówczas może mieć sens utworzenie satelity do linku i trzymanie w niej informacji o funkcji, jaką pełnił każdy z pracowników podczas procesu kredytowego




# Przykład 2

- ▶ Dziedzina: instrumenty finansowe
- ▶ *Instrument* - obszar opisujący instrumenty finansowe,
- ▶ *Execution Venue* - obszar opisujący rynek finansowy,
- ▶ *Listing* - obszar opisujący Listing danego instrumentu, czyli występowanie danego instrumentu na rynku finansowym (np. na giełdzie)

# Składowe

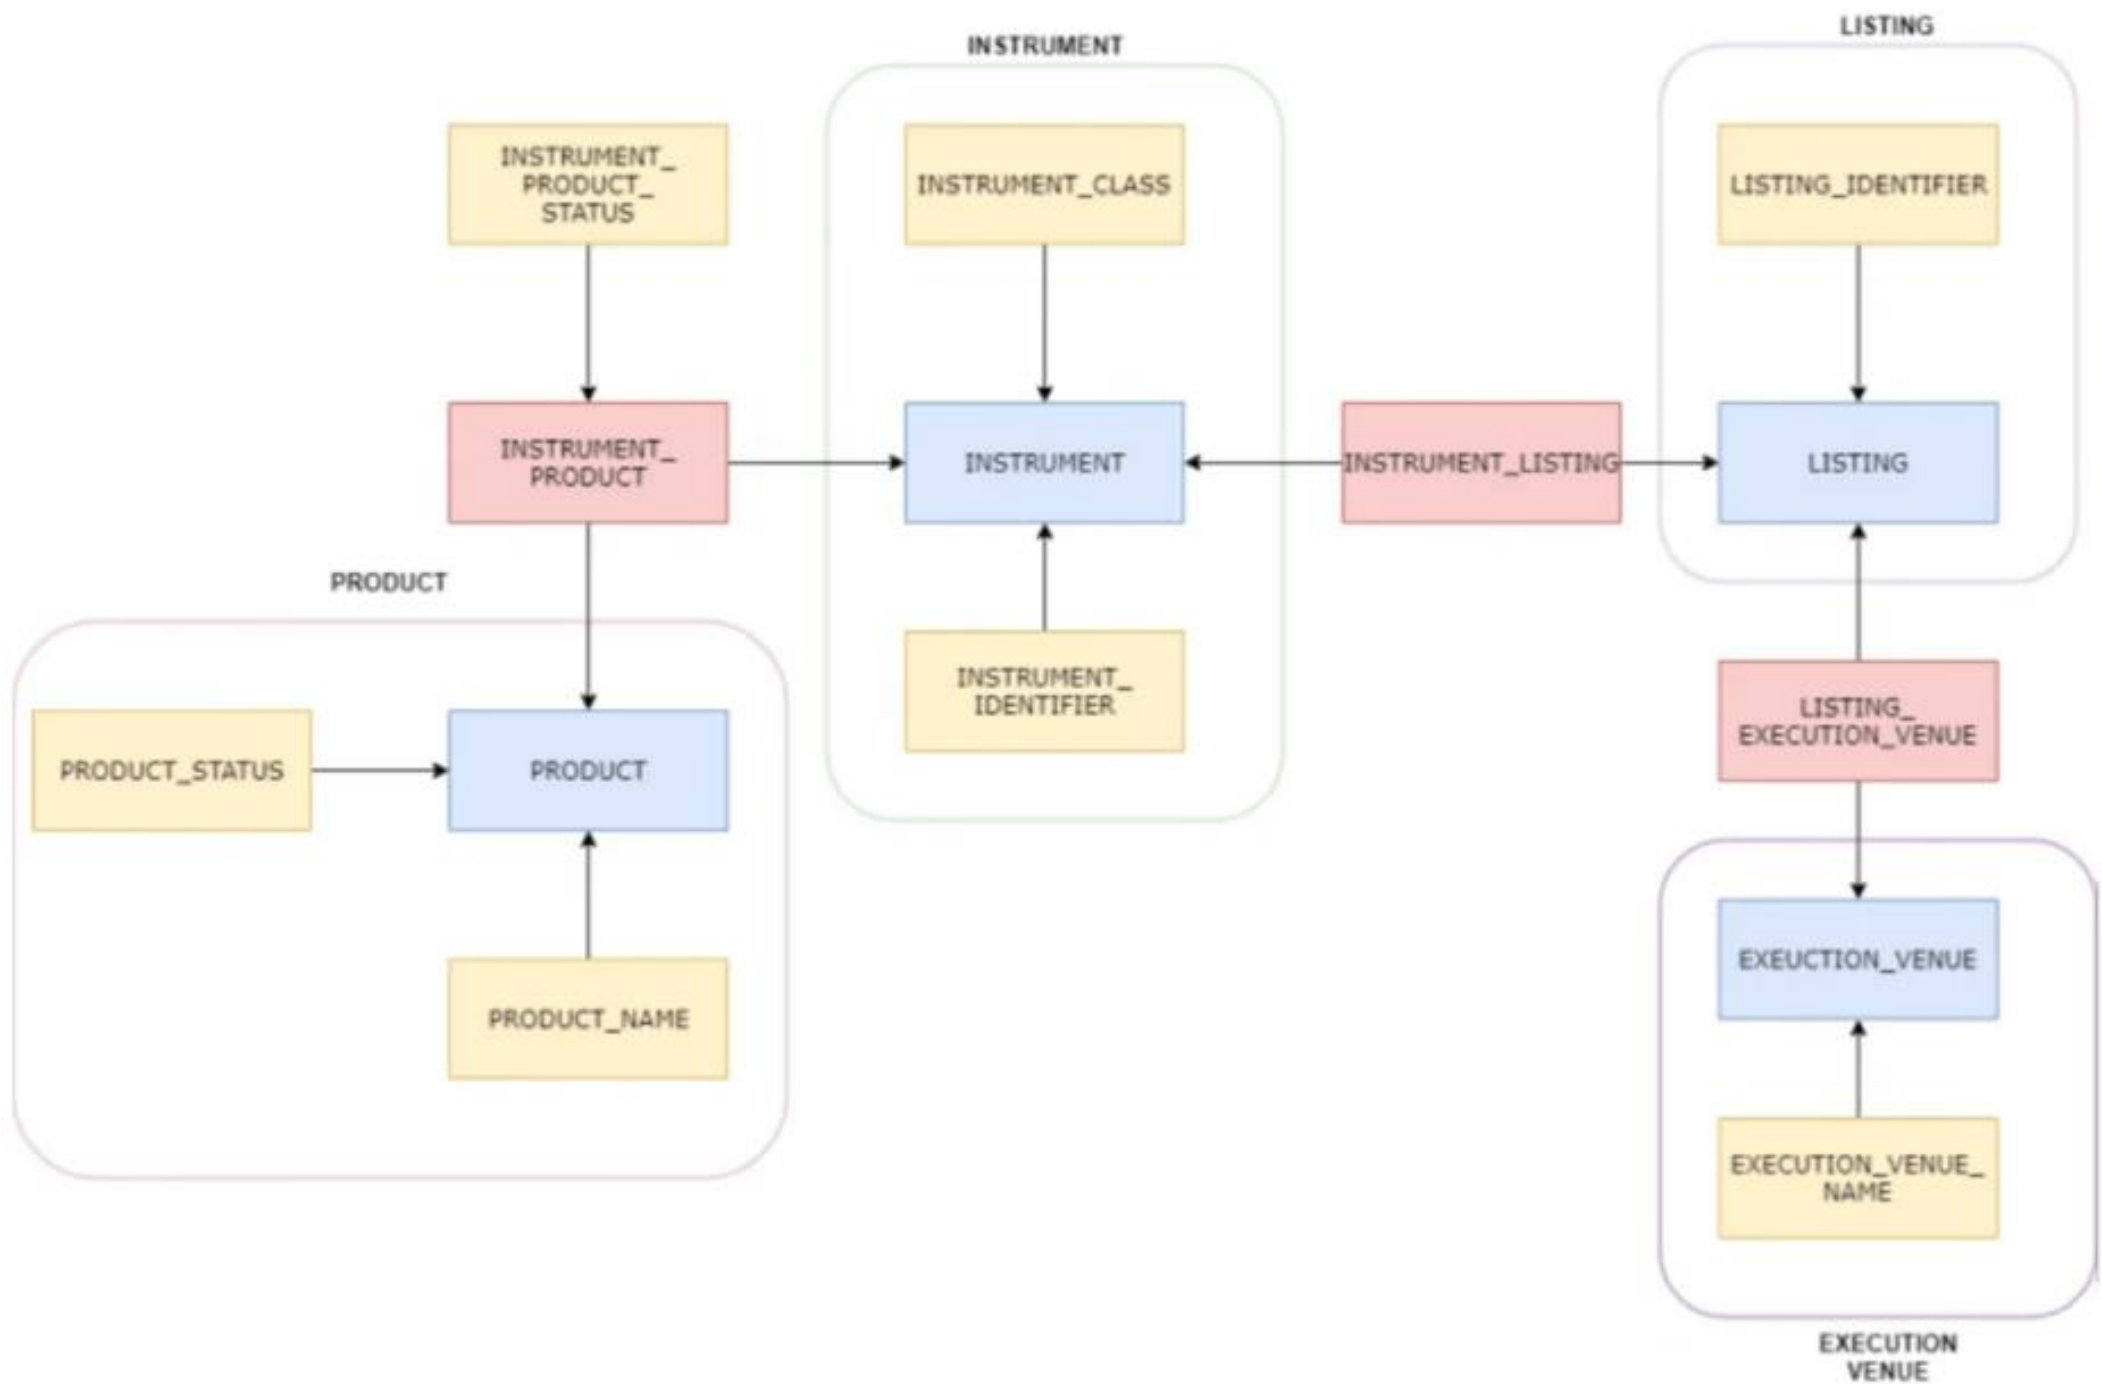
- ▶ INSTRUMENT - zawiera klucz biznesowy instrumentu - identyfikator
- ▶ INSTRUMENT\_IDENTIFIER - zawiera alternatywne identyfikatory instrumentów, np. ISIN, CUSIP
- ▶ INSTRUMENT\_CLASS - zawiera informacje o klasie, do której dany instrument należy (np. REIT)
- ▶ INSTRUMENT\_LISTING - łączy instrument z listingiem
- ▶ LISTING - zawiera klucz biznesowy listingu
- ▶ LISTING\_IDENTIFIER - identyfikator listingu (instrumentu na poziomie rynku), np. RIC, SEDOL
- ▶ LISTING\_EXECUTION\_VENUE - łączy informacje o listingu z rynkiem
- ▶ EXECUTION\_VENUE - zawiera klucz biznesowy rynku finansowego
- ▶ EXECUTION\_VENUE\_NAME - zawiera deskryptywną nazwę rynku finansowego

# Model



# Rozszerzanie modelu

- ▶ nowy obszar zawiera informacje o produktach finansowych
- ▶ dany produkt jest powiązany z instrumentem - obiekt typu Link (INSTRUMENT\_PRODUCT)
- ▶ Satelity mogą opisywać zarówno Huby jak i Linki
  - ▶ PRODUCT\_STATUS - dostarcza informacji o statusie danego produktu (produktu o danym kluczu biznesowym)
  - ▶ INSTRUMENT\_PRODUCT\_STATUS - relacja produktu z instrumentem (połączenia dwóch kluczy biznesowych)
  - ▶ Możliwe, że zarówno produkt jak i instrument jest aktywny, natomiast dany instrument nie jest już kojarzony z danym produktem



# Zalety

- ▶ łatwość historyzacji danych oraz minimalizacja redundancji
- ▶ staging może być bardzo ulotną warstwą, w której dane są przechowywane tylko przez określony czas, np. przez miesiąc czy rok
- ▶ RDV jest odzwierciedleniem systemów źródłowych, BDV zawiera już dane przyjazne w użyciu przez użytkowników posługujących się SQL-em, a nie znających konkretnych systemów źródłowych
- ▶ dane w *Information Marts* często są zagregowane, a same *Information Marts* mogą być zbudowane w innej strukturze niż *Data Vault*

# Zadanie

- ▶ Opracuj przykład skarbca danych:
  1. Zaproponuj dziedzinę
  2. Wyznacz i opisz klucze biznesowe (huby)
  3. Wyznacz i opisz relacje biznesowe pomiędzy nimi (linki)
  4. Określ miary i wymiary (satelity)
  5. Narysuj schemat proponowanego skarbca danych
  6. Opisz potencjalne rozszerzenie modelu

# Data vault dla uczelni

- ▶ HUBY: Studenci, Prowadzący, Kursy
- ▶ Określ LINKI (relacje pomiędzy hubami)
- ▶ Określ SATELITĘ np. zawierającą ocenę z kursu
- ▶ Narysuj schemat (z atrybutami)
  
- ▶ Pytania dodatkowe:
  - ▶ gdzie są przechowywane zmiany, np. zmiana nazwiska prowadzącego/studenta?
  - ▶ gdzie są informacje o ocenie z egzaminu poprawkowego?
  - ▶ jak oddzielić dane wrażliwe od pozostałych?
  - ▶ jak obsłużyć rozszerzenie modelu np. o tworzenie grup zajęciowych i przypisanie do nich studentów, prowadzących, sal, itp.?



# Dziękuję za uwagę



[https://img.freepik.com/premium-photo/golden-ingots-with-opened-bank-vault-3d-rendering\\_808337-7050.jpg?w=996](https://img.freepik.com/premium-photo/golden-ingots-with-opened-bank-vault-3d-rendering_808337-7050.jpg?w=996)