

Projekt hurtowni danych do analizy wyników i czynników wpływających na osiągnięcia kierowców Formuły 1 w latach 1950-2023

Mikołaj Kubś, 272662

18 maja 2025

Spis treści

1	Wprowadzenie do projektu	3
2	Charakterystyka dziedziny problemowej, krótki opis obszaru analizy, problemy i potrzeby	3
2.1	Dziedzina problemowa	3
2.2	Krótki opis obszaru analizy	3
2.3	Problemy i potrzeby	4
3	Cel przedsięwzięcia (oczekiwania) oraz zakres analizy - badane aspekty	4
3.1	Cel przedsięwzięcia	4
3.2	Oczekiwania	5
3.3	Zakres analizy - badane aspekty	5
4	Źródła danych (lokalizacja, format, dostępność), wstępna analiza źródeł danych	6
4.1	Wstępna analiza źródeł	6
5	Profilowanie danych (analiza jakości danych oraz ich przydatności w projekcie)	7
5.1	Plik: <code>circuits.csv</code>	7
5.2	Plik: <code>constructors.csv</code>	8
5.3	Plik: <code>drivers.csv</code>	8
5.4	Plik: <code>lap_times.csv</code>	9
5.5	Plik: <code>pit_stops.csv</code>	9

5.6	Plik: <code>rates.csv</code>	10
5.7	Plik: <code>results.csv</code>	10
5.8	Plik: <code>status.csv</code>	11
5.9	Plik: <code>weather.csv</code>	11
6	Definicja typów encji/klas, związków, diagram klas	12
6.1	Tabela Faktów: <code>Fact_Result</code>	12
6.2	Wymiary	13
6.3	Diagram Klas (Schemat Gwiazdy)	15
7	Min. 10 wielowymiarowych zestawień	15
8	Implementacja bazy danych (konceptualny model danych - DDL)	16
9	Wnioski	19
9.1	Główne korzyści	19
9.2	Potencjalne wyzwania	20

1 Wprowadzenie do projektu

Proces tworzenia hurtowni danych powinien być poprzedzony zrozumieniem „potrzeb biznesu” oraz rzeczywistości (dziedziny problemowej) reprezentowanej przez dostępne zasoby danych. Realizacja poniższego zadania ma uzmysłowić występujące problemy w określonym (wybranym) wycinku rzeczywistości, a następnie umożliwić zidentyfikowanie (określenie) potrzeb, celu i możliwości analiz biznesowych, by wspierać procesy decyzyjne (podejmowanie właściwych decyzji biznesowych).

Projekt końcowy powinien zawierać przynajmniej jedną kostkę Analysis Services, dotyczącą danych pochodzących z co najmniej dwóch źródeł danych (jeden zbiór danych ma być wybrany spośród przedstawionych na zajęciach laboratoryjnych, a drugi - dowolnie wybrany przez studenta).

Utworzona kostka powinna:

- zawierać przynajmniej 5 wymiarów, w tym co najmniej dwa o strukturze hierarchicznej (np. czas, miejsce, itp.);
- posiadać co najmniej 3 miary, w tym min. jedną nieaddytywną;
- odpowiadająca jej tabela faktów powinna posiadać co najmniej 10000 rekordów.

Niniejszy dokument stanowi propozycję tematu projektu hurtowni danych, opracowaną zgodnie ze specyfikacją Etapu I.

2 Charakterystyka dziedziny problemowej, krótki opis obszaru analizy, problemy i potrzeby

2.1 Dziedzina problemowa

Dziedziną problemową są Mistrzostwa Świata Formuły 1 - najbardziej prestiżowa seria wyścigów samochodowych na świecie, charakteryzująca się zaawansowaną technologią, rywalizacją na najwyższym poziomie oraz bogatą historią.

2.2 Krótki opis obszaru analizy

Analiza obejmuje historyczne dane dotyczące wyników kierowców i zespołów (konstruktorów) Formuły 1, począwszy od inauguracyjnego sezonu 1950 aż do końca sezonu 2023. Badane będą zarówno indywidualne osiągnięcia (pozycje, punkty, czasy), jak i dynamika zespołowa, strategie wyścigowe (np.

pit-stopy), wpływ charakterystyki torów oraz, dla wybranego okresu (2018-2023), wpływ warunków atmosferycznych na przebieg i rezultaty wyścigów.

2.3 Problemy i potrzeby

- **Zrozumienie czynników sukcesu:** Identyfikacja kluczowych elementów (np. pozycja startowa, niezawodność bolidu, skuteczność strategii, umiejętności kierowcy, osiągi zespołu) determinujących wyniki w F1.
- **Analiza trendów historycznych:** Obserwacja ewolucji sportu, okresów dominacji poszczególnych zespołów i kierowców, wpływu zmian technologicznych i regulaminowych na wyniki.
- **Ocena strategii wyścigowych:** Analiza skuteczności różnych strategii (np. liczba i moment pit-stopów) w zależności od toru, warunków pogodowych i sytuacji na torze.
- **Obiektywna ocena kierowców i zespołów:** Umożliwienie porównania osiągnięć kierowców, również w kontekście siły zespołu, dla którego startowali w różnych okresach.
- **Potrzeby analityczne dla fanów i ekspertów:** Dostarczenie narzędzia do głębszego zrozumienia sportu, weryfikacji hipotez, tworzenia rankingów i zaawansowanych porównań wykraczających poza standardowe tabele wyników.
- **Analiza wpływu czynników zewnętrznych:** Zbadanie, w jakim stopniu warunki pogodowe (temperatura, opady, wiatr) korelują z wynikami wyścigów, liczbą awarii, czy pojawianiem się nieoczekiwanych rezultatów ("niespodzianek").

3 Cel przedsięwzięcia (oczekiwania) oraz zakres analizy - badane aspekty

3.1 Cel przedsięwzięcia

Głównym celem przedsięwzięcia jest zaprojektowanie i implementacja funkcjonalnej hurtowni danych wraz z kostką OLAP, która umożliwi wielowymiarową analizę wyników wyścigów Formuły 1. Narzędzie to ma pozwolić na identyfikację wzorców, trendów oraz zależności między różnymi czynnikami (charakterystyka kierowcy, zespołu, toru, strategii, pogody) a osiągnięciami sportowymi.

3.2 Oczekiwania

Oczekuje się, że stworzona hurtownia danych pozwoli na efektywne i intuicyjne uzyskiwanie odpowiedzi na złożone pytania analityczne. Model danych powinien być zrozumiały dla użytkownika końcowego, umożliwiając elastyczne operacje analityczne takie jak drażenie danych (drill-down, roll-up) oraz krojenie i kostkowanie (slice and dice).

3.3 Zakres analizy - badane aspekty

- **Wyniki indywidualne i zespołowe:** Pozycje startowe (grid) i końcowe, zdobyte punkty, czasy ukończenia wyścigów, czasy poszczególnych okrążeń (w tym najszybsze okrążenie), status ukończenia wyścigu (np. ukończony, DNF, zdyskwalifikowany).
- **Kierowcy:** Dane demograficzne (narodowość, data urodzenia, wiek w momencie wyścigu), historia startów, przynależność zespołowa w poszczególnych wyścigach.
- **Zespoły (Konstruktorzy):** Narodowość, historia startów, sumaryczne wyniki w poszczególnych wyścigach i sezonach.
- **Wyścigi (Events):** Sezon (rok), numer rundy w sezonie, nazwa Grand Prix, data i godzina rozpoczęcia.
- **Tory wyścigowe:** Charakterystyka toru (nazwa, lokalizacja, kraj, długość, typ).
- **Strategia wyścigowa:** Liczba odbytych pit-stopów, okrążenia, na których miały miejsce, czas trwania postojów.
- **Warunki pogodowe (dla lat 2018-2023):** Agregowane dane dotyczące temperatury powietrza i toru, wilgotności, ciśnienia, występowania opadów, kierunku i siły wiatru podczas wyścigu.
- **Wpływ regulacji (pośrednio):** Analiza zmian w wynikach, strategiach czy dominacji zespołów na przestrzeni lat może pośrednio wskazywać na wpływ zmian regulaminowych, choć same regulacje nie będą modelowane jako bezpośredni wymiar.

4 Źródła danych (lokalizacja, format, dostępność), wstępna analiza źródeł danych

Tabela 1: Źródło danych: Formula 1 World Championship (1950-2023)

Plik	Format	Rekordy	Rozmiar	Opis
https://www.kaggle.com/datasets/rohanrao/formula-1-world-championship-1950-2020 (dane aktualizowane do 2023)				
circuits.csv	CSV	78	<0.1MB	Info o torach (ID, nazwa, kraj).
constructors.csv	CSV	212	<0.1MB	Info o konstr. (ID, nazwa).
constructor_results.csv	CSV	12625	0.2MB	Wyniki konstruktorów (punkty).
constructor_standings.csv	CSV	13391	0.3MB	Pozycja konstr. po wyścigu.
drivers.csv	CSV	861	0.1MB	Info o kierowcach (ID, nazwisko).
driver_standings.csv	CSV	34863	0.8MB	Pozycja kierowców po wyścigu.
lap_times.csv	CSV	589k	16.8MB	Czasy okrążeń.
pit_stops.csv	CSV	11371	0.4MB	Dane o pit-stopach.
qualifying.csv	CSV	10494	0.4MB	Wyniki kwalifikacji.
races.csv	CSV	1126	0.2MB	Dane o wyścigach (ID, rok, tor).
results.csv	CSV	26759	1.6MB	Szczegółowe wyniki kierowców.
sprint_results.csv	CSV	360	<0.1MB	Wyniki sprintów.
status.csv	CSV	139	<0.1MB	Opis statusu zakończenia.

Tabela 2: Źródło danych: Minute by Minute F1 Grand Prix Weather Data (2018-2023)

Plik	Format	Rekordy	Rozmiar	Opis
https://www.kaggle.com/datasets/quantumkaze/f1-weather-dataset-2018-2023				
F1 Weather(2018-2023).csv	CSV	18214	1.1MB	Minutowe dane pogodowe dla wyścigów GP F1 (2018-2023). Kolumny: Time, AirTemp, Humidity, Pressure, Rainfall, TrackTemp, WindDirection, WindSpeed, Round Number, Year.

Uwaga dotycząca danych pogodowych: Dane z pliku `F1 Weather(2018-2023).csv` są zbierane minuta po minucie. Do celów hurtowni danych, te szczegółowe dane będą agregowane (np. poprzez uśrednianie wartości temperatury, wilgotności, prędkości wiatru; określenie dominującego kierunku wiatru; sumowanie/oznaczanie wystąpienia opadów) do poziomu całego wyścigu, aby móc je powiązać z tabelą faktów wyników wyścigów.

4.1 Wstępna analiza źródeł

- **Pierwsze źródło (Formula 1 World Championship):** Jest to zbiór bardzo obszerny i szczegółowy, zawierający dane historyczne od 1950 roku. Kluczowe pliki dla budowy hurtowni to:
 - `results.csv`: Głównie źródło dla tabeli faktów, zawierające wyniki poszczególnych kierowców w wyścigach.
 - `races.csv`: Dane o poszczególnych wyścigach (rok, runda, data, tor), kluczowe do łączenia z wynikami i danymi pogodowymi.

- `drivers.csv`, `constructors.csv`, `circuits.csv`, `status.csv`: Podstawowe źródła dla odpowiednich wymiarów (Kierowcy, Konstruktorzy, Tory, Status Zakończenia).
- `lap_times.csv`, `pit_stops.csv`: Dostarczają dodatkowych miar lub atrybutów, które mogą być włączone do tabeli faktów lub analizowane w bardziej szczegółowych kontekstach (np. średni czas pitstopu, najszybsze okrążenie).

Dane w tym zbiorze są generalnie dobrze zidentyfikowane przez klucze numeryczne (np. `raceId`, `driverId`, `constructorId`), co ułatwi proces łączenia tabel w procesie ETL.

- **Drugie źródło (Minute by Minute F1 Grand Prix Weather Data):**

Ten zbiór dostarcza szczegółowych, minutowych danych pogodowych dla Grand Prix Formuły 1 w latach 2018-2023. Zawiera takie informacje jak temperatura powietrza i toru, wilgotność, ciśnienie, opady, kierunek i prędkość wiatru.

- **Kluczowe wyzwanie i podejście:** Ze względu na wysoką granulację czasową (minuta po minucie), dane te nie mogą być bezpośrednio połączone z tabelą faktów opisującą całościowy wynik kierowcy w wyścigu. Konieczna będzie **agregacja** tych danych do poziomu całego wyścigu (lub jego kluczowych faz). W procesie ETL obliczane będą wartości średnie, minimalne, maksymalne, sumaryczne (np. dla opadów) dla każdego wyścigu.
- **Łączenie po agregacji:** Zagregowane dane pogodowe dla danego wyścigu zostaną połączone z głównym zbiorem danych poprzez wspólne identyfikatory: rok (`Year`) i numer rundy (`Round Number`), które są obecne w obu zbiorach (w pierwszym zbiorze w pliku `races.csv`).

5 Profilowanie danych (analiza jakości danych oraz ich przydatności w projekcie)

Poniżej przedstawiono szczegółowe profilowanie danych dla każdego pliku CSV wykorzystywanego w projekcie. Analiza opiera się na raportach wygenerowanych przez bibliotekę ‘ydata-profiling’. Analizowane będą tylko (najprawdopodobniej) przydatne atrybuty.

5.1 Plik: `circuits.csv`

Tabela 3: Profilowanie danych dla `circuits.csv`

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'circuitId'	Numeric (Real)	Min: 1, Max: 80	Klucz główny. Unikalny, brak braków. Jakość wysoka.
2.	'circuitRef'	Text	Unikalne wartości	Tekstowy ID. Unikalny, brak braków. Jakość wysoka. Przydatny.
3.	'name'	Text	Unikalne wartości	Nazwa toru. Unikalny, brak braków. Jakość wysoka. Przydatny.
4.	'location'	Text	75 unikalnych (z 77)	Miasto. Brak braków. Jakość dobra. Przydatny.
5.	'country'	Categorical	35 unikalnych	Kraj. Brak braków. Jakość dobra. Kluczowy dla wymiaru geo.
6.	'lat'	Numeric (Real)	Min: -37.85, Max: 57.27	Szer. geogr. Unikalna, brak braków. Jakość wysoka. Przydatna.
7.	'lng'	Numeric (Real)	Min: -118.19, Max: 144.97	Dł. geogr. Unikalna, brak braków. Jakość wysoka. Przydatna.
8.	'alt'	Numeric (Real)	Min: -7, Max: 2227; 2.6% Zeros	Wysokość n.p.m. Brak braków. Jakość dobra.

5.2 Plik: `constructors.csv`

Tabela 4: Profilowanie danych dla `constructors.csv`

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'constructorId'	Numeric (Real)	Min: 1, Max: 215	Klucz główny. Unikalny, brak braków. Jakość wysoka.
2.	'constructorRef'	Text	Unikalne wartości	Tekstowy ID. Unikalny, brak braków. Jakość wysoka.
3.	'name'	Text	Unikalne wartości	Nazwa. Unikalny, brak braków. Jakość wysoka. Kluczowy atrybut.
4.	'nationality'	Categorical	24 unikalne	Narodowość. Brak braków. Jakość dobra. Ważny atrybut.

5.3 Plik: `drivers.csv`

Tabela 5: Profilowanie danych dla `drivers.csv`

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'driverId'	Numeric (Real)	Min: 1, Max: 862	Klucz główny. Unikalny, brak braków. Jakość wysoka.
2.	'driverRef'	Text	Unikalne wartości	Tekstowy ID. Unikalny, brak braków. Jakość wysoka.
3.	'number'	Numeric (Real)	Min: 2, Max: 99	Nr startowy. **93.1% braków!** Niska/średnia jakość.
Ciąg dalszy na następnej stronie				

Tabela 5 – ciąg dalszy

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
4.	'code'	Text	97 unikalnych	Kod kierowcy. **87.9% braków!** Niska/średnia jakość.
5.	'forename'	Text	478 unikalnych	Imię. Brak braków. Jakość wysoka. Kluczowy.
6.	'surname'	Text	802 unikalne	Nazwisko. Brak braków. Jakość wysoka. Kluczowy.
7.	'dob'	DateTime	Min: 1896, Max: 2005	Data urodzenia. Brak braków. Jakość wysoka. Kluczowy.
8.	'nationality'	Categorical	43 unikalne	Narodowość. Brak braków. Jakość dobra. Ważny atrybut.

5.4 Plik: lap_times.csv

Tabela 6: Profilowanie danych dla lap_times.csv

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'raceId'	Numeric (Real)	Min: 1, Max: 1144	Klucz obcy. Brak braków. Jakość wysoka.
2.	'driverId'	Numeric (Real)	Min: 1, Max: 862	Klucz obcy. Brak braków. Jakość wysoka.
3.	'lap'	Numeric (Real)	Min: 1, Max: 87	Nr okrążenia. Brak braków. Jakość wysoka.
4.	'position'	Numeric (Real)	Min: 1, Max: 24	Pozycja na okrążeniu. Brak braków. Jakość wysoka.
5.	'time'	Text	np. "1:38.109"	Czas okr. (tekst). Brak braków. Wymaga parsowania. Jakość wysoka.
6.	'milliseconds'	Numeric (Real)	Min: 55404, Max: 7.5M	Czas okr. (ms). Brak braków. Jakość średnia. Kluczowa miara. Max wartość to anomalia.

5.5 Plik: pit_stops.csv

Tabela 7: Profilowanie danych dla pit_stops.csv

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'raceId'	Numeric (Real)	Min: 841, Max: 1144	Klucz obcy. Brak braków. Dane od raceId > 840. Jakość wysoka.
2.	'driverId'	Numeric (Real)	Min: 1, Max: 862	Klucz obcy. Brak braków. Jakość wysoka.
3.	'stop'	Numeric (Real)	Min: 1, Max: 70	Nr pit stopu. Brak braków. Max 70 to anomalia. Jakość ok.
Ciąg dalszy na następnej stronie				

Tabela 7 – ciąg dalszy

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
4.	'lap'	Numeric (Real)	Min: 1, Max: 78	Okrążenie pit stopu. Brak braków. Jakość wysoka.
5.	'time'	DateTime	HH:MM:SS	Godzina pit stopu z dodatkową datą. Wymaga parsowania. Dobra jakość.
6.	'duration'	Text	np. "26.898"	Czas trwania (tekst). Brak braków. Wymaga parsowania. Jakość dobra.
7.	'milliseconds'	Numeric (Real)	Min: 12.9k, Max: 3M	Czas trwania (ms). Brak braków. Jakość wysoka. Max wartość (51min) to anomalia.

5.6 Plik: races.csv

Tabela 8: Profilowanie danych dla races.csv

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'raceId'	Numeric (Real)	Min: 1, Max: 1144	Klucz główny. Unikalny, brak braków. Jakość wysoka.
2.	'year'	Numeric (Real)	Min: 1950, Max: 2024	Rok. Brak braków. Jakość wysoka. Kluczowy.
3.	'round'	Numeric (Real)	Min: 1, Max: 24	Runda. Brak braków. Jakość wysoka. Kluczowy.
4.	'circuitId'	Numeric (Real)	Min: 1, Max: 80	Klucz obcy. Brak braków. Jakość wysoka. Kluczowy.
5.	'name'	Text	54 unikalne	Nazwa GP. Brak braków. Jakość wysoka.
6.	'date'	DateTime	Min: 1950, Max: 2024	Data wyścigu. Unikalna, brak braków. Jakość wysoka. Kluczowa.
7.	'time'	DateTime	HH:MM:SS; Braki 65.0%	Godzina startu. Błędnie jako DateTime. Dużo braków - dane tylko od 2005 roku. Wymaga parsowania. Może być kluczowy do pogody.

5.7 Plik: results.csv

Tabela 9: Profilowanie danych dla results.csv

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'resultId'	Numeric (Real)	Min: 1, Max: 26764	Klucz główny. Unikalny, brak braków. Jakość wysoka.
2.	'raceId'	Numeric (Real)	Min: 1, Max: 1144	Klucz obcy. Brak braków. Jakość wysoka.
3.	'driverId'	Numeric (Real)	Min: 1, Max: 862	Klucz obcy. Brak braków. Jakość wysoka.
Ciąg dalszy na następnej stronie				

Tabela 9 – ciąg dalszy

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
4.	'constructorId'	Numeric (Real)	Min: 1, Max: 215	Klucz obcy. Brak braków. Jakość wysoka.
5.	'number'	Numeric (Real)	Min: 0, Max: 208; Braki <0.1%	Nr startowy. Bardzo małe braki. Jakość dobra.
6.	'grid'	Numeric (Real)	Min: 0, Max: 34; 6.1% to zera	Pozycja startowa. Brak braków. Jakość wysoka. Kluczowa miara. Dziwnie dużo 0.
7.	'position'	Numeric (Real)	Min: 1, Max: 33; Braki 40.9%	Pozycja końcowa. Dużo braków (DNF). 'positionOrder' lepsze.
9.	'positionOrder'	Numeric (Real)	Min: 1, Max: 39	Uporządkowana pozycja. Brak braków. Jakość wysoka. Lepsza do rankingu.
10.	'points'	Numeric (Real)	Min: 0, Max: 50; 69.5% to zera	Punkty. Brak braków. Jakość wysoka. Kluczowa miara.
11.	'laps'	Numeric (Real)	Min: 0, Max: 200; 9.5% Zeros	Ukończone okrążenia. Brak braków. Jakość wysoka. Miara.
12.	'time'	Text	np. "1:30:00", "+5s"; Braki 71.3%	Czas. Dużo braków. Wymaga parsowania. 'milliseconds' lepsze. Niska jakość.
13.	'milliseconds'	Numeric (Real)	Min: 526, Max: 15M; Braki 71.3%	Czas (ms). Dużo braków. Jakość wysoka (dla niepustych). Kluczowa miara.
14.	'fastestLap'	Numeric (Real)	Min: 1, Max: 85; Braki 69.2%	Nr najszybszego okrążenia. Dużo braków. Jakość średnia.
15.	'rank'	Numeric (Real)	Min: 0, Max: 24; Braki 68.2%	Ranking najszybszego okrążenia. Dużo braków. Jakość średnia.
16.	'fastestLapTime'	DateTime	MM:SS.mmm; Braki 69.2%	Czas najszybszego okrążenia. Błędnie jako DateTime. Wymaga parsowania. Dużo braków. Niska jakość.
17.	'fastestLapSpeed'	Numeric (Real)	Min: 89, Max: 257; Braki 69.2%	Prędkość najszybszego okrążenia. Dużo braków. Jakość średnia.
18.	'statusId'	Numeric (Real)	Min: 1, Max: 141	Klucz obcy do 'status.csv'. Brak braków. Jakość wysoka. Kluczowy.

5.8 Plik: status.csv

Tabela 10: Profilowanie danych dla status.csv

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'statusId'	Numeric (Real)	Min: 1, Max: 141	Klucz główny. Unikalny, brak braków. Jakość wysoka.
2.	'status'	Text	Unikalne wartości	Opis statusu. Unikalny, brak braków. Jakość wysoka. Kluczowy.

5.9 Plik: weather.csv

Tabela 11: Profilowanie danych dla `weather.csv`

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'Time'	Text	'timedelta'	Czas odniesienia. Brak braków. Wymaga parsowania - trzeba usunąć "0 days" z przodu. Jakość wysoka. Kluczowy.
2.	'AirTemp'	Numeric (Real)	Min: 8.9, Max: 37.2	Temperatura powietrza. Brak braków. Jakość wysoka. Kluczowa miara.
3.	'Humidity'	Numeric (Real)	Min: 5, Max: 97.5	Wilgotność. Brak braków. Jakość wysoka. Kluczowa miara.
4.	'Pressure'	Numeric (Real)	Min: 778.5, Max: 1023.5	Ciśnienie. Brak braków. Jakość wysoka. Miara.
5.	'Rainfall'	Boolean	True/False	Opady. Brak braków. Jakość wysoka. Kluczowa miara.
6.	'TrackTemp'	Numeric (Real)	Min: 13.8, Max: 67	Temp. toru. Brak braków. Jakość wysoka. Kluczowa miara.
7.	'WindDirection'	Numeric (Real)	Min: 0, Max: 359	Kier. wiatru. Brak braków. Jakość wysoka. Miara.
8.	'WindSpeed'	Numeric (Real)	Min: 0, Max: 10.1	Prędkość wiatru. Brak braków. Jakość wysoka. Kluczowa miara.
9.	'Round Number'	Numeric (Real)	Min: 1, Max: 22	Nr rundy. Brak braków. Jakość wysoka. Kluczowy do łączenia.
10.	'Year'	Numeric (Real)	Min: 2018, Max: 2023	Rok. Brak braków. Jakość wysoka. Kluczowy do łączenia.
Dodatkowa uwaga:				Raport wskazuje 3.2% zduplikowanych wierszy. Należy zbadać i usunąć przed agregacją.

6 Definicja typów encji/klas, związków, diagram klas

Projektowana hurtownia danych będzie oparta na schemacie gwiazdy, z centralną tabelą faktów `Fact_Result` oraz otaczającymi ją tabelami wymiarów.

6.1 Tabela Faktów: `Fact_Result`

- **Opis:** Reprezentuje pojedynczy, całościowy wynik kierowcy w danym wyścigu Grand Prix. Ziarnistość tabeli to jeden rekord per kierowca per wyścig.
- **Klucze obce (referencje do wymiarów):**
 - `RaceKey` (FK do `Dim_Race`)
 - `DriverKey` (FK do `Dim_Driver`)
 - `ConstructorKey` (FK do `Dim_Constructor`)

- `CircuitKey` (FK do `Dim_Circuit`)
- `DateKey` (FK do `Dim_Time` - data wyścigu)
- `WeatherKey` (FK do `Dim_Weather`, może być NULL dla wyścigów sprzed 2018)
- `StatusKey` (FK do `Dim_Status`)

• **Miary (przykładowe):**

- `PointsScored` (DECIMAL) - zdobyte punkty (addytywna)
- `LapsCompleted` (INT) - liczba ukończonych okrążeń (addytywna)
- `NumberOfPitStops` (INT, wyliczana z `pit_stops.csv`) - liczba pit-stopów (addytywna)
- `RaceTimeMilliseconds` (BIGINT, nullable) - czas ukończenia wyścigu w milisekundach (póładdytywna)
- `GridPosition` (INT) - pozycja startowa (nieaddytywna)
- `FinalPositionOrder` (INT) - numeryczna pozycja na mecie (nieaddytywna)
- `PositionOrderChange` (INT) - różnica między pozycją startową a finalną (nieaddytywna)
- `FastestLapTimeMilliseconds` (BIGINT, nullable) - czas najszybszego okrążenia kierowcy w wyścigu (nieaddytywna)
- `RankFastestLap` (INT, nullable) - ranking najszybszego okrążenia kierowcy w wyścigu (nieaddytywna)
- `FastestLapTopSpeed` (DECIMAL, nullable) - szyb (nieaddytywna)

6.2 Wymiary

1. `Dim_Driver`

- Klucze: `DriverKey` (PK, klucz zastępczy), `DriverID_NK` (klucz naturalny z `drivers.csv`), `DriverRef`
- Atrybuty: `FirstName`, `LastName`, `FullName`, `DateOfBirth`, `Nationality`, `Continent`
- Hierarchie: `Continent` → `Nationality` → `DriverKey`.

2. `Dim_Constructor`

- Klucze: `ConstructorKey` (PK), `ConstructorID_NK`, `ConstructorRef`

- Atrybuty: Name, Nationality, Continent
- Hierarchie: Continent → Nationality → ConstructorKey.

3. Dim_Race

- Klucze: RaceKey (PK), RaceID_NK
- Atrybuty: YearSeason, RoundNumberInSeason, RaceNameOfficial
- Hierarchie: YearSeason → RoundNumberInSeason → RaceKey.

4. Dim_Circuit

- Klucze: CircuitKey (PK), CircuitID_NK, CircuitRef
- Atrybuty: CircuitName, LocationCity, CountryName, Latitude, Longitude, Altitude
- Hierarchie: CountryName → LocationCity → CircuitName.

5. Dim_Time

- Klucze: DateKey (PK: YYYYMMDD)
- Atrybuty: FullDate (DATE), Year, Quarter, Month, MonthName, DayOfMonth, DayOfWeekName
- Hierarchie: Year → Quarter → Month → DayOfMonth

6. Dim_Weather


- Klucze: WeatherKey (PK)
- Atrybuty: AvgAirTempCelsius, MinAirTempCelsius, MaxAirTempCelsius, AvgTrackTempCelsius, AvgHumidityPercent, DidRainOccur (Boolean), AvgWindSpeedKmph, MaxWindSpeedKmph, AvgWindDirection

7. Dim_Status (opisuje sposób zakończenia wyścigu przez kierowcę)

- Klucze: StatusKey (PK)
- Atrybuty: StatusDescription (np. "Finished", "+1 Lap", "Engine", "Collision"), StatusCategory (np. "Finished", "Malfunction", "Accident")
- Hierarchie: StatusCategory → StatusDescription.

6.3 Diagram Klas (Schemat Gwiazdy)

Centralna tabela faktów `Fact_Result` będzie połączona z wymienionymi powyżej tabelami wymiarów.



Rysunek 1: Proponowany schemat gwiazdy dla hurtowni danych F1.

7 Min. 10 wielowymiarowych zestawień

Poniżej przedstawiono przykładowe wielowymiarowe zestawienia, które będzie można utworzyć po wdrożeniu kostki OLAP:

1. **Wpływ pozycji startowej na wynik:** Średnia pozycja na mecie i procent zwycięstw dla każdej pozycji startowej (grid), z możliwością filtrowania wg toru/sezonu.
2. **Stabilność kierowców:** Średnie punkty na wyścig, liczba miejsc na podium i zwycięstw na sezon dla wybranych kierowców na przestrzeni ich kariery.
3. **"Gwiazdy w słabych zespołach":** Identyfikacja kierowców, którzy regularnie zdobywali punkty lub wysokie pozycje dla zespołów z końca stawki (np. porównanie wyników kierowcy ze średnią zespołu).
4. **Ewolucja strategii pit-stopów:** Średnia liczba pit-stopów na wyścig i ich wpływ na wynik, analizowana wg toru, sezonu i warunków pogodowych.

5. **Dominacja zespołów:** Procent wygranych wyścigów i zdobytych punktów przez poszczególne zespoły w sezonach.
6. **Trendy narodowościowe:** Liczba kierowców, zwycięzców i mistrzów świata z podziałem na narodowości, na przestrzeni dekad.
7. **Pogoda a niezawodność:** Korelacja między zagregowanymi warunkami pogodowymi (np. wysokie/niskie temperatury, opady deszczu) a liczbą nieukończonych wyścigów (DNF) z powodu awarii lub wypadków.
8. **Pogoda a nieoczekiwane wyniki:** Analiza, czy deszczowe lub zmienne warunki pogodowe częściej przynoszą nieoczekiwane wyniki (np. zwycięzcy spoza czołowych zespołów, kierowcy z dalszych pozycji na podium).
9. **Pojedynki zespołowe (team-mate battles):** Porównanie wyników (punkty, pozycje w kwalifikacjach i wyścigach) kierowców startujących w tym samym zespole w danym sezonie.
10. **Charakterystyka torów a wyniki:** Jak zmieniały się czasy ukończenia torów z biegiem lat? Które tory generują najwięcej/najmniej wyprzedzeń (analiza zmiany pozycji start-meta)?
11. **Analiza DNF (Did Not Finish):** Najczęstsze przyczyny nieukończenia wyścigu (na podstawie Dim_Status) dla poszczególnych zespołów i na przestrzeni sezonów, z uwzględnieniem wpływu pogody.
12. **Wpływ wieku kierowcy na osiągnięcia:** Korelacja między wiekiem kierowcy a jego wynikami (np. średnia liczba punktów na sezon, częstotliwość błędów, szybkość na pojedynczym okrążeniu).

8 Implementacja bazy danych (konceptualny model danych - DDL)

Poniżej przedstawiono skrypt SQL tworzący strukturę tabel wymiarów i faktów zgodnie z zaproponowanym modelem. Klucze obce, więzy integralności i nawet indeksy są zdefiniowane.

```
1 CREATE TABLE Dim_Driver (  
2     DriverKey INT PRIMARY KEY,  
3     DriverID_NK INT UNIQUE,  
4     DriverRef VARCHAR(255) UNIQUE,  
5     FirstName VARCHAR(255),  
6     LastName VARCHAR(255),
```

```

7      FullName VARCHAR(510),
8      DateOfBirth DATE,
9      Nationality VARCHAR(255),
10     Continent VARCHAR(255)
11 );
12
13 CREATE TABLE Dim_Constructor (
14     ConstructorKey INT PRIMARY KEY,
15     ConstructorID_NK INT UNIQUE,
16     ConstructorRef VARCHAR(255) UNIQUE,
17     Name VARCHAR(255),
18     Nationality VARCHAR(255),
19     Continent VARCHAR(255)
20 );
21
22 CREATE TABLE Dim_Race (
23     RaceKey INT PRIMARY KEY,
24     RaceID_NK INT UNIQUE,
25     YearSeason INT,
26     RoundNumberInSeason INT,
27     RaceNameOfficial VARCHAR(255)
28 );
29
30 CREATE TABLE Dim_Circuit (
31     CircuitKey INT PRIMARY KEY,
32     CircuitID_NK INT UNIQUE,
33     CircuitRef VARCHAR(255) UNIQUE,
34     CircuitName VARCHAR(255),
35     LocationCity VARCHAR(255),
36     CountryName VARCHAR(255),
37     Latitude DECIMAL(9,6),
38     Longitude DECIMAL(9,6),
39     Altitude INT
40 );
41
42 CREATE TABLE Dim_Time (
43     DateKey INT PRIMARY KEY,
44     FullDate DATE UNIQUE,
45     Year INT,
46     Quarter INT,
47     Month INT,
48     MonthName VARCHAR(50),
49     DayOfMonth INT,

```

```

50     DayOfWeekName VARCHAR(50),
51     WeekOfYear INT
52 );
53
54 CREATE TABLE Dim_Weather (
55     WeatherKey INT PRIMARY KEY,
56     AvgAirTempCelsius DECIMAL(5,2),
57     MinAirTempCelsius DECIMAL(5,2),
58     MaxAirTempCelsius DECIMAL(5,2),
59     AvgTrackTempCelsius DECIMAL(5,2),
60     AvgHumidityPercent DECIMAL(5,2),
61     DidRainOccur BIT,           -- 0 lub 1
62     TotalRainfallMM DECIMAL(6,2),
63     AvgWindSpeedKmph DECIMAL(5,2),
64     MaxWindSpeedKmph DECIMAL(5,2),
65     DominantWindDirection VARCHAR(50), -- Np. N, NW, S (kategoria)
66 );
67
68 CREATE TABLE Dim_Status (
69     StatusKey INT PRIMARY KEY,
70     StatusID_NK INT UNIQUE,
71     StatusDescription VARCHAR(255),
72     StatusCategory VARCHAR(100)      -- Np. Finished, Accident,
73     Failure
74 );
75
76 CREATE TABLE Fact_Result (
77     RaceKey INT,
78     DriverKey INT,
79     ConstructorKey INT,
80     CircuitKey INT,
81     DateKey INT,
82     WeatherKey INT NULL,
83     StatusKey INT,
84     -- Miary
85     PointsScored DECIMAL(5,1),
86     LapsCompleted INT,
87     NumberOfPitStops INT NULL,
88     RaceTimeMilliseconds BIGINT NULL,
89     GridPosition INT,
90     FinalPositionOrder INT,
91     PositionOrderChange INT,      -- (GridPosition -

```

```

92     FinalPositionOrder)
93     FastestLapTimeMilliseconds BIGINT NULL,
94     RankFastestLap INT NULL,
95     FastestLapTopSpeed DECIMAL(6,2) NULL,
96     AgeAtRace DECIMAL(5,3) NULL,
97
98     FOREIGN KEY (RaceKey) REFERENCES Dim_Race(RaceKey),
99     FOREIGN KEY (DriverKey) REFERENCES Dim_Driver(DriverKey),
100    FOREIGN KEY (ConstructorKey) REFERENCES Dim_Constructor(
101    ConstructorKey),
102    FOREIGN KEY (CircuitKey) REFERENCES Dim_Circuit(CircuitKey),
103    FOREIGN KEY (DateKey) REFERENCES Dim_Time(DateKey),
104    FOREIGN KEY (WeatherKey) REFERENCES Dim_Weather_Aggregated(
105    WeatherKey),
106    FOREIGN KEY (StatusKey) REFERENCES Dim_Status(StatusKey)
107 );
108
109 CREATE INDEX idx_fact_race ON Fact_Result(RaceKey);
110 CREATE INDEX idx_fact_driver ON Fact_Result(DriverKey);
111 CREATE INDEX idx_fact_constructor ON Fact_Result(ConstructorKey);
112 CREATE INDEX idx_fact_date ON Fact_Result(DateKey);

```

Listing 1: Konceptualny DDL dla hurtowni danych F1

9 Wnioski

Proponowany projekt hurtowni danych dla wyników Formuły 1 w latach 1950-2023 ma na celu stworzenie kompleksowego narzędzia analitycznego. Wykorzystanie dwóch głównych źródeł danych - szczegółowych wyników historycznych oraz minutowych danych pogodowych (agregowanych do poziomu wyścigu) dla ostatnich sezonów - pozwoli na przeprowadzenie wielowymiarowych analiz, które mogą odkryć interesujące wzorce, trendy i zależności.

9.1 Główne korzyści

- Umożliwienie odpowiedzi na szeroki zakres pytań analitycznych dotyczących strategii, osiągnięć kierowców i zespołów oraz wpływu czynników zewnętrznych, w tym pogody.
- Dostarczenie spójnego i zintegrowanego zbioru danych, ułatwiającego analizy porównawcze na przestrzeni lat i między różnymi aspektami wyścigów.

- **Możliwość wizualizacji i eksploracji danych F1** w sposób bardziej zaawansowany niż standardowe tabele wyników, wspierając podejmowanie decyzji i głębsze zrozumienie sportu.

9.2 Potencjalne wyzwania

- **Agregacja i integracja danych pogodowych:** Precyzyjne zdefiniowanie logiki agregacji minutowych danych pogodowych oraz zapewnienie poprawnego określenia zakresu czasowego wyścigu dla tej agregacji.
- **Jakość danych źródłowych:** Obsługa brakujących wartości (NULL), niespójności formatów (np. czasów) oraz potencjalnych wartości odstających w obu zbiorach danych.
- **Zakres danych pogodowych:** Analizy wykorzystujące szczegółowe dane pogodowe będą ograniczone do sezonów 2018-2023. Można by za pomocą API pozyskać brakujące dane (poza temperaturą nawierzchni). Ciekawą alternatywą byłoby też użycie prostej estymacji temperatury nawierzchni z danych pogodowych - mało danych treningowych, ale wysoce prawdopodobne jest to, że temperatura nawierzchni jest bardzo powiązana z np. temperaturą z ostatnich x godzin z coraz mniejszymi wagami, plus uwzględnienie wilgotności / deszczu.
- **Interpretacja historyczna i zmiany regulaminowe:** Uwzględnienie znaczących zmian w regulaminach F1 (np. systemy punktacji, aerodynamika, specyfikacje opon) przy interpretacji wyników i trendów z różnych epok sportu.
- **Obsługa stref czasowych:** Zapewnienie spójności w przetwarzaniu danych czasowych, szczególnie przy łączeniu 'timedelta' z danych pogodowych z czasem startu wyścigu.