

Projekt hurtowni danych do analizy wyników i czynników wpływających na osiągnięcia kierowców Formuły 1 w latach 1950-2023

Mikołaj Kubś, 272662

14 maja 2025

Spis treści

1	Wprowadzenie do projektu	2
2	Charakterystyka dziedziny problemowej, krótki opis obszaru analizy, problemy i potrzeby	2
2.1	Dziedzina problemowa	2
2.2	Krótki opis obszaru analizy	2
2.3	Problemy i potrzeby	2
3	Cel przedsięwzięcia (oczekiwania) oraz zakres analizy – badane aspekty	3
3.1	Cel przedsięwzięcia	3
3.2	Oczekiwania	3
3.3	Zakres analizy – badane aspekty	3
4	Źródła danych (lokalizacja, format, dostępność), wstępna analiza źródeł danych	4
4.1	Wstępna analiza źródeł	5
5	Min. 10 wielowymiarowych zestawień	6
6	Implementacja bazy danych (konceptualny model danych - DDL)	7
7	Wnioski	9
7.1	Główne korzyści	9
7.2	Potencjalne wyzwania	9

1 Wprowadzenie do projektu

Proces tworzenia hurtowni danych powinien być poprzedzony zrozumieniem „potrzeb biznesu” oraz rzeczywistości (dziedziny problemowej) reprezentowanej przez dostępne zasoby danych. Realizacja poniższego zadania ma uzmysłowić występujące problemy w określonym (wybranym) wycinku rzeczywistości, a następnie umożliwić zidentyfikowanie (określenie) potrzeb, celu i możliwości analiz biznesowych, by wspierać procesy decyzyjne (podejmowanie właściwych decyzji biznesowych).

Projekt końcowy powinien zawierać przynajmniej jedną kostkę Analysis Services, dotyczącą danych pochodzących z co najmniej dwóch źródeł danych. Utworzona kostka powinna zawierać przynajmniej 5 wymiarów (w tym co najmniej dwa o strukturze hierarchicznej), posiadać co najmniej 3 miary (w tym min. jedną nieaddytywną), a odpowiadająca jej tabela faktów powinna posiadać co najmniej 10000 rekordów.

Niniejszy dokument stanowi propozycję tematu projektu hurtowni danych zgodnie ze specyfikacją Etapu I.

2 Charakterystyka dziedziny problemowej, krótki opis obszaru analizy, problemy i potrzeby

2.1 Dziedzina problemowa

Sporty motorowe, ze szczególnym uwzględnieniem Mistrzostw Świata Formuły 1, najbardziej prestiżowej serii wyścigów samochodowych na świecie.

2.2 Krótki opis obszaru analizy

Analiza obejmuje historyczne dane dotyczące wyników kierowców i zespołów (konstruktorów) Formuły 1, począwszy od inauguracyjnego sezonu 1950 aż do końca sezonu 2023. Badane będą zarówno indywidualne osiągnięcia, jak i dynamika zespołowa, strategie wyścigowe (np. pit-stopy), wpływ charakterystyki torów oraz, dla wybranego okresu (2018-2023), wpływ warunków atmosferycznych na przebieg i rezultaty wyścigów.

2.3 Problemy i potrzeby

- **Zrozumienie czynników sukcesu:** Identyfikacja kluczowych elementów (np. pozycja startowa, niezawodność, strategia, umiejętności kierowcy, osiągi bolidu) determinujących wyniki w F1.

- **Analiza trendów historycznych:** Obserwacja ewolucji sportu, okresów dominacji poszczególnych zespołów, wpływu zmian technologicznych i regulaminowych na wyniki.
- **Ocena strategii:** Analiza skuteczności różnych strategii wyścigowych, takich jak liczba i timing pit-stopów, w zależności od toru i warunków.
- **Ocena kierowców i zespołów:** Umożliwienie obiektywnej oceny osiągnięć kierowców, również w kontekście siły zespołu, dla którego startowali.
- **Potrzeby analityczne (dla fanów, ekspertów, mediów):** Dostarczenie narzędzia do głębszego zrozumienia sportu, weryfikacji hipotez, tworzenia rankingów i porównań, które wykraczają poza proste tabele wyników.
- **Wpływ czynników zewnętrznych:** Zbadanie, w jakim stopniu warunki pogodowe (temperatura, opady, wiatr) korelują z wynikami wyścigów, liczbą awarii czy "niespodziankami" na torze.

3 Cel przedsięwzięcia (oczekiwania) oraz zakres analizy – badane aspekty

3.1 Cel przedsięwzięcia

Stworzenie funkcjonalnej hurtowni danych wraz z kostką OLAP, która umożliwi wielowymiarową analizę wyników wyścigów Formuły 1. Celem jest dostarczenie narzędzia pozwalającego na identyfikację wzorców, trendów, zależności między różnymi czynnikami (charakterystyka kierowcy, zespołu, toru, strategii, pogody) a osiągnięciami sportowymi.

3.2 Oczekiwania

Hurtownia danych powinna pozwolić na efektywne uzyskiwanie odpowiedzi na złożone pytania analityczne, które zostaną przedstawione w punkcie 5. Oczekuje się, że model danych będzie intuicyjny dla użytkownika końcowego i pozwoli na elastyczne drażenie danych (drill-down, roll-up) oraz ich krojenie i kostkowanie (slice and dice).

3.3 Zakres analizy – badane aspekty

- **Wyniki:** Pozycje startowe i końcowe, zdobyte punkty, czasy wyścigów, czasy okrążeń (w tym najszybsze), status ukończenia wyścigu.

- **Kierowcy:** Dane demograficzne (narodowość, data urodzenia → wiek), historia startów, przynależność zespołowa.
- **Zespoły (Konstruktorzy):** Narodowość, historia startów, sumaryczne wyniki.
- **Wyścigi (Events):** Sezon, runda, konkretny wyścig (Grand Prix), data.
- **Tory:** Charakterystyka toru (nazwa, lokalizacja, kraj).
- **Strategia:** Liczba i dane dotyczące pit-stopów.
- **Warunki pogodowe (dla lat 2018-2023):** Temperatura powietrza i toru, wilgotność, opady, siła wiatru.
- **Regulacje (pośrednio):** Analiza zmian w wynikach/strategiach na przestrzeni lat może wskazywać na wpływ zmian regulaminowych (choć samych regulacji nie modelujemy jako wymiaru).

4 Źródła danych (lokalizacja, format, dostępność), wstępna analiza źródeł danych

Tabela 1: Zestawienie źródeł danych

Lp.	Plik/Zbiór Danych	Typ/Forma	Liczba rekordów (szac.)	Rozmiar [MB] (szac.)	Opis / Lokalizacja
1.	Formula 1 World Championship (1950-2023)	CSV			Zbiór 14 plików CSV. https://www.kaggle.com/datasets/rohanrao/formula-1-world-championship-1950-2020 (dane aktualizowane do 2023)
	circuits.csv	CSV	79	< 0.1	Info o torach (ID, nazwa, kraj).
	constructor_results.csv	CSV	12626	0.5	Wyniki konstruktorów (punkty).
	constructor_standings.csv	CSV	13392	0.6	Pozycja konstruktorów po wyścigu.
	constructors.csv	CSV	215	< 0.1	Info o konstruktorach (ID, nazwa).

Ciąg dalszy na następnej stronie

Tabela 1 – ciąg dalszy

Lp.	Plik/Zbiór Danych	Typ/Forma	Liczba rekordów (szac.)	Rozmiar [MB] (szac.)	Opis / Lokalizacja
	driver_standings.csv	CSV	34864	1.5	Pozycja kierowców po wyścigu.
	drivers.csv	CSV	862	< 0.1	Info o kierowcach (ID, nazwisko).
	lap_times.csv	CSV	589k	25	Czasy okrążeń.
	pit_stops.csv	CSV	11372	0.5	Dane o pit-stopach.
	qualifying.csv	CSV	10551	0.5	Wyniki kwalifikacji.
	races.csv	CSV	1144	0.1	Dane o wyścigach (ID, rok, tor).
	results.csv	CSV	26760	1.5	Szczegółowe wyniki kierowców.
	seasons.csv	CSV	76	< 0.1	Info o sezonach.
	sprint_results.csv	CSV	360	< 0.1	Wyniki sprintów.
	status.csv	CSV	140	< 0.1	Opis statusu zakończenia.
2.	F1 Weather Dataset (2018-2023)	CSV			Dane pogodowe. https://www.kaggle.com/datasets/quantumkaze/f1-weather-dataset-2018-2023
	weather.csv	CSV	478	< 0.1	Szczegółowe dane pogodowe.

Uwaga: Liczba rekordów dla `weather.csv` jest niewielka, ale dotyczy sesji (nie tylko wyścigów), więc po agregacji do poziomu wyścigu będzie mniej unikalnych wpisów pogodowych per wyścig. Całkowity rozmiar plików CSV: ok. 30-35 MB.

4.1 Wstępna analiza źródeł

- **Pierwsze źródło (F1 World Championship):** Jest bardzo obszerne i szczegółowe. Kluczowe pliki dla budowy hurtowni to `results.csv` (dla faktów), `races.csv`, `drivers.csv`, `constructors.csv`, `circuits.csv`, `status.csv` (dla wymiarów). Pliki `lap_times.csv` i `pit_stops.csv` dostarczają dodatkowych miar lub atrybutów. Dane są dobrze zidentyfikowane przez klucze (np. `raceId`, `driverId`).
- **Drugie źródło (F1 Weather Dataset):** Zawiera dane pogodowe, które

wzbogacą analizę dla nowszych sezonów. Kluczowe będzie połączenie tych danych z głównym zbiorem poprzez `season`, `round` i `circuit_id`. `circuit_id` w tym zbiorze jest tekstowe (np. "bahrain"), podczas gdy w `circuits.csv` mamy numeryczny `circuitId` oraz tekstowy `circuitRef`. Należy zapewnić spójne mapowanie (prawdopodobnie przez `circuitRef`).

5 Min. 10 wielowymiarowych zestawień

Poniżej przedstawiono przykładowe wielowymiarowe zestawienia, które będzie można utworzyć po wdrożeniu kostki OLAP:

1. **Wpływ pozycji startowej na wynik:** Średnia pozycja na mecie i procent zwycięstw dla każdej pozycji startowej (grid), z możliwością filtrowania wg toru/sezonu.
2. **Stabilność kierowców:** Średnie punkty na wyścig, liczba miejsc na podium i zwycięstw na sezon dla wybranych kierowców na przestrzeni ich kariery.
3. **"Gwiazdy w słabych zespołach":** Identyfikacja kierowców, którzy regularnie zdobywali punkty lub wysokie pozycje dla zespołów z końca stawki.
4. **Ewolucja strategii pit-stopów:** Średnia liczba pit-stopów na wyścig i ich wpływ na wynik, analizowana wg toru, sezonu i warunków pogodowych.
5. **Dominacja zespołów:** Procent wygranych wyścigów i zdobytych punktów przez poszczególne zespoły w sezonach.
6. **Trendy narodowościowe:** Liczba kierowców, zwycięzców i mistrzów świata z podziałem na narodowości, na przestrzeni dekad.
7. **Pogoda a niezawodność (2018-2023):** Korelacja między wysokimi/niskimi temperaturami, opadami deszczu a liczbą nieukończonych wyścigów (DNF).
8. **Pogoda a "niespodzianki"(2018-2023):** Analiza, czy deszczowe wyścigi częściej przynoszą nieoczekiwane wyniki.
9. **Pojedynki zespołowe:** Porównanie wyników kierowców startujących w tym samym zespole w danym sezonie.
10. **Charakterystyka torów a wyniki:** Które tory generują najwięcej/najmniej wyprzedzeń?

11. **Analiza DNF:** Najczęstsze przyczyny nieukończenia wyścigu (wg Dim_Status) dla zespołów i sezonów.

12. **Wpływ wieku kierowcy:** Korelacja między wiekiem kierowcy a jego osiągnięciami.

6 Implementacja bazy danych (konceptualny model danych - DDL)

Poniżej przedstawiono fragmenty skryptu SQL (Data Definition Language) tworzącego strukturę tabel wymiarów i faktów zgodnie z zaproponowanym modelem.

```
1 CREATE TABLE Dim_Driver (  
2     DriverKey INT PRIMARY KEY,  
3     DriverID_NK INT, -- Natural Key from drivers.csv  
4     DriverRef VARCHAR(255),  
5     Forename VARCHAR(255),  
6     Surname VARCHAR(255),  
7     FullName VARCHAR(511) GENERATED ALWAYS AS (Forename || ' ' ||  
8     Surname) STORED,  
9     DateOfBirth DATE,  
10    Nationality VARCHAR(255)  
11    -- Można dodać atrybuty dla SCD Type 2 np. ValidFrom, ValidTo,  
12    IsCurrent  
13 );
```

Listing 1: Fragment DDL dla tabeli Dim_Driver

```
1 CREATE TABLE Dim_Circuit (  
2     CircuitKey INT PRIMARY KEY,  
3     CircuitID_NK INT, -- Natural Key from circuits.csv  
4     CircuitRef VARCHAR(255),  
5     CircuitName VARCHAR(255),  
6     Location VARCHAR(255),  
7     Country VARCHAR(255),  
8     Latitude DECIMAL(9,6),  
9     Longitude DECIMAL(9,6)  
10 );
```

Listing 2: Fragment DDL dla tabeli Dim_Circuit

```

1 CREATE TABLE Dim_Time (
2     DateKey INT PRIMARY KEY, -- Format YYYYMMDD
3     FullDate DATE UNIQUE,
4     Year INT,
5     Quarter INT,
6     Month INT,
7     MonthName VARCHAR(50),
8     DayOfMonth INT,
9     DayOfWeekName VARCHAR(50),
10    WeekOfYear INT
11 );

```

Listing 3: Fragment DDL dla tabeli Dim_Time

```

1 CREATE TABLE Fact_DriverRaceResult (
2     -- Klucze obce do wymiarów
3     RaceKey INT,
4     DriverKey INT,
5     ConstructorKey INT,
6     DateKey INT, -- Data wyścigu, FK do Dim_Time
7     WeatherKey INT, -- Może być NULL, FK do Dim_Weather
8     StatusKey INT, -- FK do Dim_Status
9
10    -- Miary
11    GridPosition INT,
12    FinalPosition INT, -- Pozycja końcowa numeryczna
13    PointsScored DECIMAL(5,2),
14    RaceTimeMilliseconds BIGINT, -- Czas wyścigu w ms
15    LapsCompleted INT,
16    NumberOfPitStops INT,
17    FastestLapTimeMilliseconds BIGINT,
18    IsFastestLap BOOLEAN,
19    IsFinished BOOLEAN, -- Na podstawie StatusKey
20    RankInRace INT, -- Pozycja w ramach ukończonych kierowców
21
22    -- Klucz główny tabeli faktów
23    PRIMARY KEY (RaceKey, DriverKey),
24
25    -- Definicje kluczy obcych
26    FOREIGN KEY (RaceKey) REFERENCES Dim_Race(RaceKey),
27    FOREIGN KEY (DriverKey) REFERENCES Dim_Driver(DriverKey),
28    FOREIGN KEY (ConstructorKey) REFERENCES Dim_Constructor(
ConstructorKey),

```

```

29 FOREIGN KEY (DateKey) REFERENCES Dim_Time(DateKey),
30 FOREIGN KEY (WeatherKey) REFERENCES Dim_Weather(WeatherKey),
31 FOREIGN KEY (StatusKey) REFERENCES Dim_Status(StatusKey)
32 );

```

Listing 4: Fragment DDL dla tabeli Fact_DriverRaceResult

Uwaga: Pełny skrypt DDL dla wszystkich tabel zostanie przygotowany w dalszych etapach projektu.

7 Wnioski

Proponowany projekt hurtowni danych dla wyników Formuły 1 w latach 1950-2023 ma na celu stworzenie kompleksowego narzędzia analitycznego. Wykorzystanie dwóch głównych źródeł danych – szczegółowych wyników historycznych oraz danych pogodowych dla ostatnich sezonów – pozwoli na przeprowadzenie wielowymiarowych analiz, które mogą odkryć interesujące wzorce, trendy i zależności.

7.1 Główne korzyści

- Umożliwienie odpowiedzi na szeroki zakres pytań analitycznych dotyczących strategii, osiągnięć kierowców i zespołów oraz wpływu czynników zewnętrznych.
- Dostarczenie spójnego i zintegrowanego zbioru danych, ułatwiającego analizy porównawcze na przestrzeni lat.
- Wizualizacja i eksploracja danych F1 w sposób bardziej zaawansowany niż standardowe tabele wyników.

7.2 Potencjalne wyzwania

- **Integracja danych:** Zapewnienie poprawnego mapowania identyfikatorów torów między dwoma źródłami danych.
- **Jakość danych:** Obsługa brakujących wartości (NULL) oraz transformacja danych tekstowych (np. czasy, pozycje) do spójnych formatów numerycznych.
- **Zakres danych pogodowych:** Ograniczenie analiz pogodowych do lat 2018-2023.

- **Interpretacja historyczna:** Uwzględnienie zmian w regulaminach F1 (np. systemy punktacji) przy interpretacji wyników z różnych epok.

Projekt spełnia podstawowe wymagania dotyczące liczby źródeł danych, planowanej liczby wymiarów (7 zdefiniowanych, co najmniej 5 będzie w finalnej kostce), miar oraz przewidywanej dużej liczby rekordów w tabeli faktów (ponad 26 000 na podstawie `results.csv`). Zaproponowana struktura hurtowni danych stanowi solidną podstawę do dalszych prac implementacyjnych (ETL, budowa kostki OLAP).