

Projekt hurtowni danych do analizy wyników i czynników wpływających na osiągnięcia kierowców Formuły 1 w latach 1950-2023

Mikołaj Kubś, 272662

14 maja 2025

Spis treści

1	Wprowadzenie do projektu	2
2	Charakterystyka dziedziny problemowej, krótki opis obszaru analizy, problemy i potrzeby	2
2.1	Dziedzina problemowa	2
2.2	Krótki opis obszaru analizy	2
2.3	Problemy i potrzeby	3
3	Cel przedsięwzięcia (oczekiwania) oraz zakres analizy - badane aspekty	3
3.1	Cel przedsięwzięcia	3
3.2	Oczekiwania	3
3.3	Zakres analizy - badane aspekty	4
4	Źródła danych (lokalizacja, format, dostępność), wstępna analiza źródeł danych	4
4.1	Wstępna analiza źródeł	5
5	Min. 10 wielowymiarowych zestawień	6
6	Implementacja bazy danych (konceptualny model danych - DDL)	7
7	Wnioski	9
7.1	Główne korzyści	9
7.2	Potencjalne wyzwania	10

1 Wprowadzenie do projektu

Proces tworzenia hurtowni danych powinien być poprzedzony zrozumieniem „potrzeb biznesu” oraz rzeczywistości (dziedziny problemowej) reprezentowanej przez dostępne zasoby danych. Realizacja poniższego zadania ma uzmysłowić występujące problemy w określonym (wybranym) wycinku rzeczywistości, a następnie umożliwić zidentyfikowanie (określenie) potrzeb, celu i możliwości analiz biznesowych, by wspierać procesy decyzyjne (podejmowanie właściwych decyzji biznesowych).

Projekt końcowy powinien zawierać przynajmniej jedną kostkę Analysis Services, dotyczącą danych pochodzących z co najmniej dwóch źródeł danych (jeden zbiór danych ma być wybrany spośród przedstawionych na zajęciach laboratoryjnych, a drugi - dowolnie wybrany przez studenta).

Utworzona kostka powinna:

1. zawierać przynajmniej 5 wymiarów, w tym co najmniej dwa o strukturze hierarchicznej (np. czas, miejsce, itp)
2. posiadać co najmniej 3 miary, w tym min. jedną nieaddytywną
3. odpowiadająca jej tabela faktów powinna posiadać co najmniej 10000 rekordów.

2 Charakterystyka dziedziny problemowej, krótki opis obszaru analizy, problemy i potrzeby

2.1 Dziedzina problemowa

Mistrzostwa Świata Formuły 1, czyli najbardziej prestiżowej serii wyścigów samochodowych na świecie.

2.2 Krótki opis obszaru analizy

Analiza obejmuje historyczne dane dotyczące wyników kierowców i zespołów (konstruktorów) Formuły 1, począwszy od inauguracyjnego sezonu 1950 aż do końca sezonu 2023. Badane będą zarówno indywidualne osiągnięcia, jak i dynamika zespołowa, strategie wyścigowe (np. pit-stopy), wpływ charakterystyki torów oraz, dla wybranego okresu (2018-2023), wpływ warunków atmosferycznych na przebieg i rezultaty wyścigów.

2.3 Problemy i potrzeby

- **Zrozumienie czynników sukcesu:** Identyfikacja kluczowych elementów (np. pozycja startowa, niezawodność, strategia, umiejętności kierowcy, osiągi bolidu) determinujących wyniki w F1.
- **Analiza trendów historycznych:** Obserwacja ewolucji sportu, okresów dominacji poszczególnych zespołów, wpływu zmian technologicznych i regulaminowych na wyniki.
- **Ocena strategii:** Analiza skuteczności różnych strategii wyścigowych, takich jak liczba i timing pit-stopów, w zależności od toru i warunków.
- **Ocena kierowców i zespołów:** Umożliwienie obiektywnej oceny osiągnięć kierowców, również w kontekście siły zespołu, dla którego startowali.
- **Potrzeby analityczne:** Dostarczenie narzędzia do głębszego zrozumienia sportu, weryfikacji hipotez, tworzenia rankingów i porównań, które wykraczają poza proste tabele wyników.
- **Wpływ czynników zewnętrznych:** Zbadanie, w jakim stopniu warunki pogodowe (temperatura, opady, wiatr) korelują z wynikami wyścigów, liczbą awarii czy "niespodziankami" na torze.

3 Cel przedsięwzięcia (oczekiwania) oraz zakres analizy - badane aspekty

3.1 Cel przedsięwzięcia

Stworzenie funkcjonalnej hurtowni danych wraz z kostką OLAP, która umożliwi wielowymiarową analizę wyników wyścigów Formuły 1. Celem jest dostarczenie narzędzia pozwalającego na identyfikację wzorców, trendów, zależności między różnymi czynnikami (charakterystyka kierowcy, zespołu, toru, strategii, pogody) a osiągnięciami sportowymi.

3.2 Oczekiwania

Hurtownia danych powinna pozwolić na efektywne uzyskiwanie odpowiedzi na złożone pytania analityczne, które zostaną przedstawione w punkcie 5. Oczekuje się, że model danych będzie intuicyjny dla użytkownika końcowego i pozwoli na elastyczne drążenie danych (drill-down, roll-up) oraz ich krojenie i kostkowanie (slice and dice).

3.3 Zakres analizy - badane aspekty

- **Wyniki:** Pozycje startowe i końcowe, zdobyte punkty, czasy wyścigów, czasy okrążeń (w tym najszybsze), status ukończenia wyścigu.
- **Kierowcy:** Dane demograficzne (narodowość, data urodzenia → wiek), historia startów, przynależność zespołowa.
- **Zespoły (Konstruktorzy):** Narodowość, historia startów, sumaryczne wyniki.
- **Wyścigi (Events):** Sezon, runda, konkretny wyścig (Grand Prix), data.
- **Tory:** Charakterystyka toru (nazwa, lokalizacja, kraj).
- **Strategia:** Liczba i dane dotyczące pit-stopów.
- **Warunki pogodowe (dla lat 2018-2023):** Temperatura powietrza i toru, wilgotność, opady, siła wiatru.
- **Regulacje (pośrednio):** Analiza zmian w wynikach/strategiach na przestrzeni lat może wskazywać na wpływ zmian regulaminowych (choć samych regulacji nie modelujemy jako wymiaru).

4 Źródła danych (lokalizacja, format, dostępność), wstępna analiza źródeł danych

Tabela 1: Źródło danych: Formula 1 World Championship (1950-2023)

Plik	Format	Rekordy	Rozmiar	Opis
https://www.kaggle.com/datasets/rohanrao/formula-1-world-championship-1950-2020 (dane aktualizowane do 2023)				
circuits.csv	CSV	78	<0.1MB	Info o torach (ID, nazwa, kraj).
constructors.csv	CSV	212	<0.1MB	Info o konstr. (ID, nazwa).
constructor_results.csv	CSV	12625	0.2MB	Wyniki konstruktorów (punkty).
constructor_standings.csv	CSV	13391	0.3MB	Pozycja konstr. po wyścigu.
drivers.csv	CSV	861	0.1MB	Info o kierowcach (ID, nazwisko).
driver_standings.csv	CSV	34863	0.8MB	Pozycja kierowców po wyścigu.
lap_times.csv	CSV	589k	16.8MB	Czasy okrążeń.
pit_stops.csv	CSV	11371	0.4MB	Dane o pit-stopach.
qualifying.csv	CSV	10494	0.4MB	Wyniki kwalifikacji.
races.csv	CSV	1126	0.2MB	Dane o wyścigach (ID, rok, tor).
results.csv	CSV	26759	1.6MB	Szczegółowe wyniki kierowców.
seasons.csv	CSV	75	<0.1MB	Info o sezonach.
sprint_results.csv	CSV	360	<0.1MB	Wyniki sprintów.
status.csv	CSV	139	<0.1MB	Opis statusu zakończenia.

Tabela 2: Źródło danych: F1 Weather Dataset (2018-2023)

Plik	Format	Rekordy	Rozmiar	Opis
https://www.kaggle.com/datasets/quantumkaze/f1-weather-dataset-2018-2023				
weather.csv	CSV	18214	1.1MB	Minutowe dane pogodowe dla wyścigów GP F1 (2018-2023). Kolumny: Time, AirTemp, Humidity, Pressure, Rainfall, TrackTemp, WindDirection, WindSpeed, Round Number, Year.

Uwaga dotycząca danych pogodowych: Dane z pliku `weather.csv` są zbierane minuta po minucie. Do celów hurtowni danych, te szczegółowe dane będą agregowane (np. poprzez uśrednianie wartości temperatury, wilgotności, prędkości wiatru; określenie dominującego kierunku wiatru; sumowanie/oznaczanie wystąpienia opadów) do poziomu całego wyścigu, aby móc je powiązać z tabelą faktów wyników wyścigów.

4.1 Wstępna analiza źródeł

- **Pierwsze źródło (Formula 1 World Championship):** Jest to zbiór bardzo obszerny i szczegółowy, zawierający dane historyczne od 1950 roku. Kluczowe pliki dla budowy hurtowni to:
 - `results.csv`: Główne źródło dla tabeli faktów, zawierające wyniki poszczególnych kierowców w wyścigach.
 - `races.csv`: Dane o poszczególnych wyścigach (rok, runda, data, tor), kluczowe do łączenia z wynikami i danymi pogodowymi.
 - `drivers.csv`, `constructors.csv`, `circuits.csv`, `status.csv`: Podstawowe źródła dla odpowiednich wymiarów (Kierowcy, Konstruktorzy, Tory, Status Zakończenia).
 - `lap_times.csv`, `pit_stops.csv`: Dostarczają dodatkowych miar lub atrybutów, które mogą być włączone do tabeli faktów lub analizowane w bardziej szczegółowych kontekstach (np. średni czas pitstopu, najszybsze okrążenie).

Dane w tym zbiorze są generalnie dobrze zidentyfikowane przez klucze numeryczne (np. `raceId`, `driverId`, `constructorId`), co ułatwi proces łączenia tabel w procesie ETL.

- **Drugie źródło (Minute by Minute F1 Grand Prix Weather Data):** Ten zbiór dostarcza szczegółowych, minutowych danych pogodowych dla Grand Prix Formuły 1 w latach 2018-2023. Zawiera takie informacje jak temperatura powietrza i toru, wilgotność, ciśnienie, opady, kierunek i prędkość wiatru.

- **Kluczowe wyzwanie i podejście:** Ze względu na wysoką granulację czasową (minuta po minucie), dane te nie mogą być bezpośrednio połączone z tabelą faktów opisującą całościowy wynik kierowcy w wyścigu. Konieczna będzie **agregacja** tych danych do poziomu całego wyścigu (lub jego kluczowych faz). W procesie ETL obliczane będą wartości średnie, minimalne, maksymalne, sumaryczne (np. dla opadów) dla każdego wyścigu.
- **Łączenie po agregacji:** Zagregowane dane pogodowe dla danego wyścigu zostaną połączone z głównym zbiorem danych poprzez wspólne identyfikatory: rok (**Year**) i numer rundy (**Round Number**), które są obecne w obu zbiorach (w pierwszym zbiorze w pliku `races.csv`).
- **Mapowanie torów (jeśli konieczne):** Wcześniejsza analiza wskazywała na potrzebę mapowania tekstowego `circuit_id` z danych pogodowych na numeryczny `circuitId` lub tekstowy `circuitRef` z pliku `circuits.csv`. Chociaż dane pogodowe zawierają **Year** i **Round Number**, co powinno wystarczyć do jednoznacznej identyfikacji wyścigu, spójność danych o torach między źródłami warto będzie zweryfikować. Jeśli dane pogodowe nie zawierają bezpośredniego identyfikatora toru zgodnego z pierwszym źródłem, mapowanie na podstawie nazwy toru lub lokalizacji może być potrzebne dla dodatkowej weryfikacji lub wzbogacenia wymiaru toru.

Ten zbiór danych znacząco wzbogaci możliwości analityczne dla nowszych sezonów, pozwalając na badanie korelacji między warunkami atmosferycznymi a wynikami czy strategiami.

5 Min. 10 wielowymiarowych zestawień

Poniżej przedstawiono przykładowe wielowymiarowe zestawienia, które będzie można utworzyć po wdrożeniu kostki OLAP:

1. **Wpływ pozycji startowej na wynik:** Średnia pozycja na mecie i procent zwycięstw dla każdej pozycji startowej (grid), z możliwością filtrowania wg toru/sezonu.
2. **Stabilność kierowców:** Średnie punkty na wyścig, liczba miejsc na podium i zwycięstw na sezon dla wybranych kierowców na przestrzeni ich kariery.
3. **"Gwiazdy w słabych zespołach":** Identyfikacja kierowców, którzy regularnie zdobywali punkty lub wysokie pozycje dla zespołów z końca stawki.

4. **Ewolucja strategii pit-stopów:** Średnia liczba pit-stopów na wyścig i ich wpływ na wynik, analizowana wg toru, sezonu i warunków pogodowych.
5. **Dominacja zespołów:** Procent wygranych wyścigów i zdobytych punktów przez poszczególne zespoły w sezonach.
6. **Trendy narodowościowe:** Liczba kierowców, zwycięzców i mistrzów świata z podziałem na narodowości, na przestrzeni dekad.
7. **Pogoda a niezawodność (2018-2023):** Korelacja między wysokimi/niskimi temperaturami, opadami deszczu a liczbą nieukończonych wyścigów (DNF).
8. **Pogoda a nieoczekiwane wyniki (2018-2023):** Analiza, czy deszczowe wyścigi częściej przynoszą nieoczekiwane wyniki.
9. **Pojedynki zespołowe:** Porównanie wyników kierowców startujących w tym samym zespole w danym sezonie.
10. **Charakterystyka torów a wyniki:** Które tory generują najwięcej/najmniej wyprzedzeń?
11. **Analiza DNF:** Najczęstsze przyczyny nieukończenia wyścigu (wg Dim_Status) dla zespołów i sezonów.
12. **Wpływ wieku kierowcy:** Korelacja między wiekiem kierowcy a jego osiągnięciami.

6 Implementacja bazy danych (konceptualny model danych - DDL)

Poniżej przedstawiono fragmenty skryptu SQL (Data Definition Language) tworzącego strukturę tabel wymiarów i faktów zgodnie z zaproponowanym modelem.

```
1 CREATE TABLE Dim_Driver (  
2     DriverKey INT PRIMARY KEY,  
3     DriverID_NK INT, -- Natural Key from drivers.csv  
4     DriverRef VARCHAR(255),  
5     Forename VARCHAR(255),  
6     Surname VARCHAR(255),  
7     FullName VARCHAR(511) GENERATED ALWAYS AS (Forename || ' ' ||  
     Surname) STORED,
```

```

8      DateOfBirth DATE,
9      Nationality VARCHAR(255)
10     -- Można dodać atrybuty dla SCD Type 2 np. ValidFrom, ValidTo,
11     IsCurrent
12 );

```

Listing 1: Fragment DDL dla tabeli Dim_Driver

```

1 CREATE TABLE Dim_Circuit (
2     CircuitKey INT PRIMARY KEY,
3     CircuitID_NK INT, -- Natural Key from circuits.csv
4     CircuitRef VARCHAR(255),
5     CircuitName VARCHAR(255),
6     Location VARCHAR(255),
7     Country VARCHAR(255),
8     Latitude DECIMAL(9,6),
9     Longitude DECIMAL(9,6)
10 );

```

Listing 2: Fragment DDL dla tabeli Dim_Circuit

```

1 CREATE TABLE Dim_Time (
2     DateKey INT PRIMARY KEY, -- Format YYYYMMDD
3     FullDate DATE UNIQUE,
4     Year INT,
5     Quarter INT,
6     Month INT,
7     MonthName VARCHAR(50),
8     DayOfMonth INT,
9     DayOfWeekName VARCHAR(50),
10    WeekOfYear INT
11 );

```

Listing 3: Fragment DDL dla tabeli Dim_Time

```

1 CREATE TABLE Fact_DriverRaceResult (
2     -- Klucze obce do wymiarów
3     RaceKey INT,
4     DriverKey INT,
5     ConstructorKey INT,
6     DateKey INT, -- Data wyścigu, FK do Dim_Time
7     WeatherKey INT, -- Może być NULL, FK do Dim_Weather
8     StatusKey INT, -- FK do Dim_Status
9
10    -- Miary

```



```

11     GridPosition INT,
12     FinalPosition INT, -- Pozycja końcowa numeryczna
13     PointsScored DECIMAL(5,2),
14     RaceTimeMilliseconds BIGINT, -- Czas wyścigu w ms
15     LapsCompleted INT,
16     NumberOfPitStops INT,
17     FastestLapTimeMilliseconds BIGINT,
18     IsFastestLap BOOLEAN,
19     IsFinished BOOLEAN, -- Na podstawie StatusKey
20     RankInRace INT, -- Pozycja w ramach ukończonych kierowców
21
22     -- Klucz główny tabeli faktów
23     PRIMARY KEY (RaceKey, DriverKey),
24
25     -- Definicje kluczy obcych
26     FOREIGN KEY (RaceKey) REFERENCES Dim_Race(RaceKey),
27     FOREIGN KEY (DriverKey) REFERENCES Dim_Driver(DriverKey),
28     FOREIGN KEY (ConstructorKey) REFERENCES Dim_Constructor(
29     ConstructorKey),
30     FOREIGN KEY (DateKey) REFERENCES Dim_Time(DateKey),
31     FOREIGN KEY (WeatherKey) REFERENCES Dim_Weather(WeatherKey),
32     FOREIGN KEY (StatusKey) REFERENCES Dim_Status(StatusKey)
33 );

```

Listing 4: Fragment DDL dla tabeli Fact_DriverRaceResult

Uwaga: Pełny skrypt DDL dla wszystkich tabel zostanie przygotowany w dalszych etapach projektu.

7 Wnioski

Proponowany projekt hurtowni danych dla wyników Formuły 1 w latach 1950-2023 ma na celu stworzenie kompleksowego narzędzia analitycznego. Wykorzystanie dwóch głównych źródeł danych - szczegółowych wyników historycznych oraz danych pogodowych dla ostatnich sezonów - pozwoli na przeprowadzenie wielowymiarowych analiz, które mogą odkryć interesujące wzorce, trendy i zależności.

7.1 Główne korzyści

- Umożliwienie odpowiedzi na szeroki zakres pytań analitycznych dotyczących strategii, osiągnięć kierowców i zespołów oraz wpływu czynników zewnętrznych.

- Dostarczenie spójnego i zintegrowanego zbioru danych, ułatwiającego analizy porównawcze na przestrzeni lat.
- Wizualizacja i eksploracja danych F1 w sposób bardziej zaawansowany niż standardowe tabele wyników.

7.2 Potencjalne wyzwania

- **Integracja danych:** Zapewnienie poprawnego mapowania identyfikatorów torów między dwoma źródłami danych.
- **Jakość danych:** Obsługa brakujących wartości (NULL) oraz transformacja danych tekstowych (np. czasy, pozycje) do spójnych formatów numerycznych.
- **Zakres danych pogodowych:** Ograniczenie analiz pogodowych do lat 2018-2023.
- **Interpretacja historyczna:** Uwzględnienie zmian w regulaminach F1 (np. systemy punktacji) przy interpretacji wyników z różnych epok.

Projekt spełnia podstawowe wymagania dotyczące liczby źródeł danych, planowanej liczby wymiarów (7 zdefiniowanych, co najmniej 5 będzie w finalnej kostce), miar oraz przewidywanej dużej liczby rekordów w tabeli faktów (ponad 26 000 na podstawie `results.csv`). Zaproponowana struktura hurtowni danych stanowi solidną podstawę do dalszych prac implementacyjnych (ETL, budowa kostki OLAP).