

Projekt hurtowni danych do analizy wyników i czynników  
wpływających na osiągnięcia kierowców Formuły 1 w latach  
1950-2023

Etap II: Proces ETL

Mikołaj Kubś, 272662

25 maja 2025

Spis treści

|          |                                                |           |
|----------|------------------------------------------------|-----------|
| <b>1</b> | <b>Wprowadzenie</b>                            | <b>2</b>  |
| <b>2</b> | <b>Architektura i Narzędzia Procesu ETL</b>    | <b>2</b>  |
| 2.1      | Struktura Procesu ETL . . . . .                | 2         |
| 2.2      | Mapa Logiczna ETL . . . . .                    | 2         |
| 2.2.1    | Mapowanie Atrybutów: Dim_Driver . . . . .      | 2         |
| 2.2.2    | Mapowanie Atrybutów: Dim_Constructor . . . . . | 3         |
| 2.2.3    | Mapowanie Atrybutów: Dim_Race . . . . .        | 3         |
| 2.2.4    | Mapowanie Atrybutów: Dim_Circuit . . . . .     | 3         |
| 2.2.5    | Mapowanie Atrybutów: Dim_Time . . . . .        | 4         |
| 2.2.6    | Mapowanie Atrybutów: Dim_Weather . . . . .     | 4         |
| 2.2.7    | Mapowanie Atrybutów: Dim_Status . . . . .      | 5         |
| 2.2.8    | Mapowanie Atrybutów: Fact_Result . . . . .     | 5         |
| 2.3      | Narzędzia . . . . .                            | 6         |
| <b>3</b> | <b>Implementacja Procesów ETL</b>              | <b>7</b>  |
| 3.1      | Ekstrakcja Danych (Extract) . . . . .          | 10        |
| 3.2      | Transformacja Danych (Transform) . . . . .     | 10        |
| 3.3      | Ładowanie Danych (Load) . . . . .              | 11        |
| 3.4      | Event handler . . . . .                        | 11        |
| 3.5      | Wyzwania i Rozwiązania . . . . .               | 11        |
| 3.6      | Przyrostowe Zasilanie (Planowane) . . . . .    | 11        |
| <b>4</b> | <b>Podsumowanie i Wnioski z Etapu ETL</b>      | <b>12</b> |

# 1 Wprowadzenie

Niniejszy dokument stanowi raport z realizacji drugiego etapu projektu hurtowni danych, koncentrującego się na procesie ETL (Extract, Transform, Load). Celem tego etapu było zasilenie zdefiniowanych w Etapie I tabel wymiarów i faktów danymi pochodzącymi z plików CSV, dotyczących wyników i czynników wpływających na osiągnięcia kierowców Formuły 1 w latach 1950-2023. Proces został zaimplementowany przy użyciu narzędzia SQL Server Integration Services (SSIS).

## 2 Architektura i Narzędzia Procesu ETL

### 2.1 Struktura Procesu ETL

Proces ETL został zorganizowany w ramach jednego projektu SSIS, zawierającego dedykowane pakiety dla ładowania poszczególnych tabel wymiarów oraz tabeli faktów. Dodatkowo, zaimplementowano pakiet główny (master package) koordynujący uruchamianie poszczególnych pakietów w odpowiedniej kolejności (najpierw wymiary, następnie fakty), aby zapewnić integralność referencyjną.

Struktura pakietów SSIS:

- `_Dim_Circuit.dtsx`
- `_Dim_Driver.dtsx`
- `_Dim_Constructor.dtsx`
- `_Dim_Race.dtsx`
- `_Dim_Status.dtsx`
- `_Dim_Weather.dtsx`
- `_Fact_Result.dtsx`
- `_Dim_Time.dtsx`

### 2.2 Mapa Logiczna ETL

#### 2.2.1 Mapowanie Atrybutów: Dim\_Driver

Tabela 1: Mapowanie ETL dla tabeli Dim\_Driver

| Atrybut     | Źródła       | Kolumna źródła    | Transformacje i uwagi                                           |
|-------------|--------------|-------------------|-----------------------------------------------------------------|
| DriverKey   | -            | -                 | SQL Server IDENTITY(1,1). Klucz zastępczy.                      |
| DriverID_NK | drivers.xlsx | driverId          | Bezpośrednio. Klucz naturalny ze źródła.                        |
| FirstName   | drivers.xlsx | forename          | Bezpośrednio.                                                   |
| LastName    | drivers.xlsx | surname           | Bezpośrednio.                                                   |
| FullName    | drivers.xlsx | forename, surname | Derived Column: forename + " " + surname. Pełne imię i nazwisko |
| DateOfBirth | drivers.xlsx | dob               | Bezpośrednio.                                                   |

Kontynuacja na następnej stronie

Tabela 1 – Kontynuacja z poprzedniej strony

| Atrybut     | Źródła                                 | Kolumna źródła                         | Transformacje i uwagi                                                      |
|-------------|----------------------------------------|----------------------------------------|----------------------------------------------------------------------------|
| CountryName | drivers.xlsx,<br>Helper_Nationality    | nationality                            | Lookup do Helper_NationalityCountries.                                     |
| Continent   | Helper_Nationality<br>Helper_Continent | CountryName<br>poprzednio<br>obliczone | Lookup do Helper_CountryContinents z<br>poprzednio obliczonego CountryName |

### 2.2.2 Mapowanie Atrybutów: Dim\_Constructor

Tabela 2: Mapowanie ETL dla tabeli Dim\_Constructor

| Atrybut          | Źródła                                                   | Kolumna źródła                        | Transformacje i uwagi                              |
|------------------|----------------------------------------------------------|---------------------------------------|----------------------------------------------------|
| ConstructorKey   | -                                                        | -                                     | SQL Server IDENTITY(1,1). Klucz zastępczy.         |
| ConstructorID_NK | constructors.xlsx                                        | constructorId                         | Bezpośrednio. Klucz naturalny.                     |
| Name             | constructors.xlsx                                        | name                                  | Bezpośrednio.                                      |
| CountryName      | constructors.xlsx,<br>Helper_NationalityCountries        | nationality                           | Lookup nationality do Helper_NationalityCountries. |
| Continent        | Helper_Continent,<br>poprzednio obliczone<br>CountryName | CountryName<br>wcześniej<br>obliczone | Lookup CountryName do Helper_CountryContinent      |

### 2.2.3 Mapowanie Atrybutów: Dim\_Race

Tabela 3: Mapowanie ETL dla tabeli Dim\_Race

| Atrybut             | Źródła     | Kolumna źródła | Transformacje i uwagi                      |
|---------------------|------------|----------------|--------------------------------------------|
| RaceKey             | -          | -              | SQL Server IDENTITY(1,1). Klucz zastępczy. |
| RaceID_NK           | races.xlsx | raceId         | Bezpośrednio. Klucz naturalny.             |
| CircuitID_NK        | races.xlsx | circuitId      | Bezpośrednio. NK obwodu dla tego wyścigu.  |
| YearSeason          | races.xlsx | year           | Bezpośrednio.                              |
| RoundNumberInSeason | races.xlsx | round          | Bezpośrednio.                              |
| RaceNameOfficial    | races.xlsx | name           | Bezpośrednio.                              |
| Date                | races.xlsx | date           | Bezpośrednio. Używana do DateKey w Fact.   |

### 2.2.4 Mapowanie Atrybutów: Dim\_Circuit

Tabela 4: Mapowanie ETL dla tabeli Dim\_Circuit

| Atrybut      | Źródła        | Kolumna źródła | Transformacje i uwagi                             |
|--------------|---------------|----------------|---------------------------------------------------|
| CircuitKey   | -             | -              | SQL Server IDENTITY(1,1). Klucz zastępczy.        |
| CircuitID_NK | circuits.xlsx | circuitId      | Mapa bezpośrednia + DC (do INT). Klucz naturalny. |
| CircuitName  | circuits.xlsx | name           | Mapa bezpośrednia + DC (do DT_WSTR).              |

Kontynuacja na następnej stronie

Tabela 4 – Kontynuacja z poprzedniej strony

| Atrybut      | Źródła        | Kolumna źródła | Transformacje i uwagi                |
|--------------|---------------|----------------|--------------------------------------|
| LocationCity | circuits.xlsx | location       | Mapa bezpośrednia + DC (do DT_WSTR). |
| CountryName  | circuits.xlsx | country        | Mapa bezpośrednia + DC (do DT_WSTR). |

### 2.2.5 Mapowanie Atrybutów: Dim\_Time

Tabela 5: Mapowanie ETL dla tabeli Dim\_Time

| Atrybut       | Źródło / Metoda                           | Kolumna(y)<br>Źródła / Logika | Transformacje i uwagi                                                                                    |
|---------------|-------------------------------------------|-------------------------------|----------------------------------------------------------------------------------------------------------|
| DateKey       | races.xlsx (distinct dates) LUB Generacja | date LUB iteracja             | Der. Col.: (YEAR(FullDate) * 10000) + (MONTH(FullDate) * 100) + DAY(FullDate). PK, YYYYMMDD INT.         |
| FullDate      | races.xlsx (distinct dates) LUB Generacja | date LUB iteracja             | Mapa bezp. LUB generacja + DC (do DT_DATE).                                                              |
| Year          | j.w.                                      | Bazuje na FullDate            | Der. Col.: YEAR(FullDate).                                                                               |
| Quarter       | j.w.                                      | Bazuje na FullDate            | Der. Col.: DATEPART("qq", FullDate).                                                                     |
| Month         | j.w.                                      | Bazuje na FullDate            | Der. Col.: MONTH(FullDate).                                                                              |
| MonthName     | j.w.<br>Helper_Months                     | Bazuje na numerze miesiąca    | Der. Col.: MONTH(FullDate);<br>LkUp na Helper_Months. Polska nazwa.                                      |
| DayOfMonth    | j.w.                                      | Bazuje na FullDate            | Der. Col.: DAY(FullDate).                                                                                |
| DayOfWeekName | j.w.<br>Helper_Weekdays                   | Bazuje na FullDate            | Der. Col.: DATEPART("dw", FullDate);<br>LkUp na Helper_Weekdays. Polska nazwa.<br>Weryfikacja DATEFIRST. |

### 2.2.6 Mapowanie Atrybutów: Dim\_Weather

Tabela 6: Mapowanie ETL dla tabeli Dim\_Weather

| Atrybut                          | Źródła                | Źródła                       | Transformacje i uwagi                                                                       |
|----------------------------------|-----------------------|------------------------------|---------------------------------------------------------------------------------------------|
| WeatherKey                       | -                     | -                            | SQL Server IDENTITY(1,1). Klucz zastępczy.                                                  |
| DidRainOccur                     | F1 Weather (...).xlsx | Rainfall (np. MAX flagi 0/1) | Agg.<br>Der. Col. (AggRain > 0 ? "Tak": "Nie"). "Tak"/"Nie".                                |
| WindSpeedCategory                | F1 Weather (...).xlsx | WindSpeed (np. AVG)          | Agg.<br>Der. Col. (Logika CASE dla kategorii: "Słaby", "Umiarkowany", "Silny").             |
| AirTempCategory                  | F1 Weather (...).xlsx | AirTemp (np. AVG)            | Agg.<br>Der. Col. (Logika CASE dla kategorii: "Zimno", "Umiarkowanie", "Ciepło", "Gorąco"). |
| TrackTempCategory                | F1 Weather (...).xlsx | TrackTemp (np. AVG)          | Agg.<br>Der. Col. (Logika CASE dla kategorii).                                              |
| Kontynuacja na następnej stronie |                       |                              |                                                                                             |

Tabela 6 – Kontynuacja z poprzedniej strony

| Atrybut                  | Źródła                | Źródła             | Transformacje i uwagi                                                        |
|--------------------------|-----------------------|--------------------|------------------------------------------------------------------------------|
| HumidityCategory         | F1 Weather (...).xlsx | Humidity (np. AVG) | Agg. Der. Col. (Logika CASE dla kategorii: "Niska", "Średnia", "Wysoka").    |
| PressureCategory         | F1 Weather (...).xlsx | Pressure (np. AVG) | Agg. Der. Col. (Logika CASE dla kategorii: "Niskie", "Normalne", "Wysokie"). |
| *(Implied)*<br>RaceID_NK | F1 Weather (...).xlsx | Year, Round Number | Agg. (Group by). Służy do połączenia z wyścigiem w Fact. Dla 2018-2023.      |

### 2.2.7 Mapowanie Atrybutów: Dim\_Status

Tabela 7: Mapowanie ETL dla tabeli Dim\_Status

| Atrybut           | Źródła                       | Kolumna źródła         | Transformacje i uwagi                                                                     |
|-------------------|------------------------------|------------------------|-------------------------------------------------------------------------------------------|
| StatusKey         | -                            | -                      | SQL Server IDENTITY(1,1). Klucz zastępczy.                                                |
| StatusID_NK       | status.xlsx                  | statusId               | Mapa bezpośrednia + DC (do INT). Klucz naturalny.                                         |
| StatusDescription | status.xlsx                  | status                 | Mapa bezpośrednia + DC (do DT_WSTR).                                                      |
| StatusCategory    | status.xlsx<br>Helper_Status | status (z status.xlsx) | LkUp na Helper_Status (status.status -> BroadCategory). Kategoria np. Finished, Accident. |

### 2.2.8 Mapowanie Atrybutów: Fact\_Result

Tabela 8: Mapowanie ETL dla tabeli Fact\_Result

| Atrybut        | Źródło CSV / Wymiar    | Kolumna(y) Źródła / Logika             | Transformacje i uwagi                                                                                             |
|----------------|------------------------|----------------------------------------|-------------------------------------------------------------------------------------------------------------------|
| RaceKey        | Dim_Race               | results.raceId (NK)                    | LkUp Dim_Race (res.raceId) -> RaceKey (SK). FK. HWM: results.xlsx filtrowane po resultId.                         |
| DriverKey      | Dim_Driver             | results.driverId (NK)                  | LkUp Dim_Driver (res.driverId) -> DriverKey (SK). FK.                                                             |
| ConstructorKey | Dim_Constructor        | results.constructorId (NK)             | LkUp Dim_Constr. (res.constructorId) -> ConstrKey (SK). FK.                                                       |
| CircuitKey     | Dim_Circuit            | races.circuitId (NK, z LkUp Dim_Race)  | LkUp Dim_Race -> CircuitID_NK; LkUp Dim_Circuit (CircuitID_NK) -> CircuitKey (SK). FK.                            |
| DateKey        | Dim_Race / Kalk.       | races.date (FullDate, z LkUp Dim_Race) | LkUp Dim_Race -> FullDate. Der.Col: (YEAR(FullDate)*10000) + (MONTH(FullDate)*100) + DAY(FullDate). INT YYYYMMDD. |
| WeatherKey     | Dim_Weather / Dim_Race | races.raceId LUB races.year            | LkUp Dim_Race -> RaceID_NK (lub Year, Round). LkUp Dim_Weather. Der.Col: NULL jeśli rok < 2018. FK.               |
| StatusKey      | Dim_Status             | results.statusId (NK)                  | LkUp Dim_Status (res.statusId) -> StatusKey (SK). FK.                                                             |

Kontynuacja na następnej stronie


Tabela 8 – Kontynuacja z poprzedniej strony

| Atrybut              | Źródło CSV / Wy-<br>miar | Kolumna(y)<br>Źródła / Logika | Transformacje i uwagi                                                                                                    |
|----------------------|--------------------------|-------------------------------|--------------------------------------------------------------------------------------------------------------------------|
| PointsScored         | results.xlsx             | points                        | Mapa bezp. + DC (do DT_DECIMAL).                                                                                         |
| LapsCompleted        | results.xlsx             | laps                          | Mapa bezp. + DC (do DT_I4).                                                                                              |
| NumberOfPitStops     | pit_stops.xlsx<br>(Agg.) | raceId, driverId              | Pod-przepływ: Agg. (COUNT(stop) jako stopsCount). Merge Join (Left Outer). Der.Col: ISNULL(stopsCount) ? 0 : stopsCount. |
| RaceTimeMilliseconds | results.xlsx             | milliseconds<br>LUB time      | Mapa bezp. LUB Der.Col (parsuj tekst time) + DC (do DT_I8). NULL jeśli DNF.                                              |
| GridPosition         | results.xlsx             | grid                          | Mapa bezp. + DC (do DT_I4). Obsługa 0 dla pit lane.                                                                      |
| FinalPositionOrder   | results.xlsx             | positionOrder<br>LUB position | Mapa bezp. + DC (do DT_I4).                                                                                              |
| PositionOrderChange  | results.xlsx             | grid,<br>positionOrder        | Der.Col: GridPosition - FinalPositionOrder.                                                                              |
| RankFastestLap       | results.xlsx             | rank (fast lap)               | Mapa bezp. + DC (do DT_I4). NULL jeśli brak.                                                                             |
| FastestLapTopSpeed   | results.xlsx             | fastestLapSpeed               | Mapa bezp. + DC (do DT_DECIMAL). NULL jeśli brak.                                                                        |
| AgeAtRace            | Dim_Driver,<br>Dim_Race  | drivers.dob,<br>races.date    | LkUp Dim_Driver (dob). LkUp Dim_Race (date). Der.Col: Kalkulacja wieku. NULL jeśli dob NULL.                             |


## 2.3 Narzędzia

Głównym narzędziem wykorzystanym do implementacji procesów ETL był SQL Server Integration Services (SSIS) wchodzący w skład Microsoft SQL Server. Pakiety SSIS zostały utworzone przy użyciu SQL Server Data Tools (SSDT) for Visual Studio. Dodatkowo do czyszczenia początkowych danych i zmiany formatu plików z danymi wykorzystano Python.


### 3 Implementacja Procesów ETL



Rysunek 1: Cały ETL.



Rysunek 2: ETL dla Fact\_Result.



Rysunek 3: ETL dla Dim\_Time.



SQLQuery1.sql - DE...GLE46P\Jantar (59))\*

```
SELECT COUNT(*) FROM Dim_Circuit
SELECT COUNT(*) FROM Dim_Constructor
SELECT COUNT(*) FROM Dim_Driver
SELECT COUNT(*) FROM Dim_Race
SELECT COUNT(*) FROM Dim_Status
SELECT COUNT(*) FROM Dim_Weather
SELECT COUNT(*) FROM Dim_Time
SELECT COUNT(*) FROM Fact_Result
```

100 %



Results



Messages

|   | (No column name) |
|---|------------------|
| 1 | 77               |

|   | (No column name) |
|---|------------------|
| 1 | 212              |

|   | (No column name) |
|---|------------------|
| 1 | 861              |

|   | (No column name) |
|---|------------------|
| 1 | 1125             |

### 3.1 Ekstrakcja Danych (Extract)

Dane źródłowe w formacie XLSX były wczytywane przy użyciu komponentu `Excel Source` w SSIS. Kluczowe aspekty konfiguracji tego etapu to:

- Poprzednia konwersja plików .csv to .xlsx za pomocą skryptu Python, aby pominąć błędy w kodowaniu.
- Użycie skryptu Python do usunięcia "/" w zbiorze danych.
- Poprawna identyfikacja separatorów kolumn, kwalifikatorów tekstu oraz obsługa wierszy nagłówkowych.
- Wstępne mapowanie typów danych na poziomie źródła, z uwzględnieniem późniejszych konwersji.

### 3.2 Transformacja Danych (Transform)

Etap transformacji obejmował szereg operacji mających na celu oczyszczenie, integrację i przygotowanie danych do załadowania do tabel docelowych. Przykładowo:

1. **Konwersja Typów Danych:** Komponent `Data Conversion` był wykorzystany do konwersji danych.
2. **Obliczenia Pochodne:** Komponent `Derived Column` służył do tworzenia nowych kolumn na podstawie istniejących, np.:
  - Obliczenie wieku kierowcy w momencie wyścigu (`AgeAtRace`).
  - Obliczenie zmiany pozycji (`PositionOrderChange`).
3. **Agregacja Danych:**
  - **Dane pogodowe (`Dim_Weather`):** Minutowe dane pogodowe z pliku `weather.xlsx` były agregowane do poziomu pojedynczego wyścigu (po `Year` i `RoundNumber`) przy użyciu komponentu `Aggregate`. Obliczano wartości średnie, minimalne, maksymalne oraz sumy (np. dla opadów).
  - **Dane o pit-stopach:** Informacje o liczbie i łącznym czasie pit-stopów dla każdego kierowcy w wyścigu były agregowane z pliku `pit_stops.xlsx` i dołączane podczas ładowania tabeli faktów (np. poprzez wcześniejszą agregację do tabeli stagingowej i lookup).
4. **Kategoryzacja Danych Pogodowych:** Po agregacji, zagregowane wartości liczbowe dla danych pogodowych (np. temperatura, wilgotność, prędkość wiatru) były przekształcane na predefiniowane kategorie tekstowe (np. "Zimno", "Umiarkowanie", "Gorąco") przy użyciu wyrażeń warunkowych w komponencie `Derived Column`, zgodnie z założeniami projektu. Te kategorie zostały następnie załadowane do `Dim_Weather`. Transformacja odbyła się w skrypcie C#.
5. **Fuzzy Lookup:** Do statusów dołączono ogólną kategorię statusu np. 'Mechanical Failure', 'Race Outcome' itd.


### 3.3 Ładowanie Danych (Load)

Przetransformowane dane były ładowane do docelowych tabel w hurtowni SQL Server przy użyciu komponentu OLE DB Destination.

- Wykorzystano tryb szybkiego ładowania (`Table or view - fast load`).
- Zapewniono poprawne mapowanie kolumn z przepływu danych SSIS do kolumn tabel docelowych.
- Kolejność ładowania (najpierw wymiary, potem fakty) była zarządzana przez pakiet główny.

### 3.4 Event handler

W przypadku błędu, wszystkie dane są usuwane. Wcześniej podczas developmentu dodatkowo tabele były populowane, ponieważ wtedy występował błąd w metadanych SSIS.



Rysunek 5: Error handler.

### 3.5 Wyzwania i Rozwiązania

Podczas implementacji napotkano typowe wyzwania związane z procesami ETL:

- **Niezgodność Stron Kodowych:** Początkowe problemy z konfliktem stron kodowych (np. 65001 z Flat File Source vs 1250 domyślne dla OLE DB Destination) zostały rozwiązane poprzez zmianę typu plików na Excel.
- **Synchronizacja Metadanych:** Zmiany w strukturze przepływu danych (np. po dodaniu Data Conversion) wymagały odświeżenia metadanych w komponencie OLE DB Destination i ponownego zmapowania kolumn.
- **Błędy Konwersji Danych w Źródle:** Błędy typu "Text was truncated or one or more characters had no match in the target code page" pojawiające się w Excel Source wskazywały na niepoprawną konfigurację strony kodowej dla pliku źródłowego. Trzeba było zmienić ręcznie w advanced editor dla źródła typy kolumn.

### 3.6 Przyrostowe Zasilanie (Planowane)

Nie zaimplementowano z braku czasu. Można by uruchomić dla tabeli faktów, za każdym razem usuwając wszystkie wymiary i klucze do wymiarów w fakcie, zapisanie jaki najnowszy id? w fakcie już był, a potem załadowanie wszystkich wymiarów i wierszy o id powyżej ostatniego id faktu.

## 4 Podsumowanie i Wnioski z Etapu ETL

Proces ETL został pomyślnie zaimplementowany, umożliwiając zasilenie hurtowni danych Formuły 1 przetworzonymi i zintegrowanymi danymi. Kluczowe było właściwe zarządzanie typami danych i stronami kodowymi oraz logiczne rozplanowanie transformacji, w tym agregacji i kategoryzacji danych pogodowych. Zastosowanie SSIS pozwoliło na zbudowanie modularnego i zarządzalnego przepływu danych. Rozwiązane problemy z konwersją danych podkreślają znaczenie dokładnej analizy danych źródłowych i właściwej konfiguracji narzędzi ETL.

Kolejnym etapem będzie budowa kostki OLAP na bazie przygotowanej hurtowni danych oraz przeprowadzenie analiz wielowymiarowych.