

Projekt hurtowni danych do analizy wyników i czynników wpływających na osiągnięcia kierowców Formuły 1 w latach 1950-2023

Etap II: Proces ETL

Mikołaj Kubś, 272662

26 maja 2025

Spis treści

1	Wprowadzenie	2
2	Architektura i Narzędzia Procesu ETL	2
2.1	Struktura Procesu ETL	2
2.2	Mapa Logiczna ETL (Uproszczona)	3
2.3	Narzędzia	3
3	Implementacja Procesów ETL	3
3.1	Ekstrakcja Danych (Extract)	3
3.2	Transformacja Danych (Transform)	4
3.3	Ładowanie Danych (Load)	5
3.4	Wyzwania i Rozwiązania	5
3.5	Przyrostowe Zasilanie (Planowane)	6
4	Podsumowanie i Wnioski z Etapu ETL	6

1 Wprowadzenie

Niniejszy dokument stanowi raport z realizacji drugiego etapu projektu hurtowni danych, koncentrującego się na procesie ETL (Extract, Transform, Load). Celem tego etapu było zasilenie zdefiniowanych w Etapie I tabel wymiarów i faktów danymi pochodzącymi z plików CSV, dotyczących wyników i czynników wpływających na osiągnięcia kierowców Formuły 1 w latach 1950-2023. Proces został zaimplementowany przy użyciu narzędzia SQL Server Integration Services (SSIS).

2 Architektura i Narzędzia Procesu ETL

2.1 Struktura Procesu ETL


Proces ETL został zorganizowany w ramach jednego projektu SSIS, zawierającego dedykowane pakiety dla ładowania poszczególnych tabel wymiarów oraz tabeli faktów. Dodatkowo, zaimplementowano pakiet główny (master package) koordynujący uruchamianie poszczególnych pakietów w odpowiedniej kolejności (najpierw wymiary, następnie fakty), aby zapewnić integralność referencyjną.

Struktura pakietów SSIS (przykładowa):

- `Load_Dim_Circuit.dtsx`
- `Load_Dim_Driver.dtsx`
- `Load_Dim_Constructor.dtsx`
- `Load_Dim_Race.dtsx`
- `Load_Dim_Time.dtsx`
- `Load_Dim_Status.dtsx`
- `Load_Dim_Weather.dtsx`
- `Load_Fact_Result.dtsx`
- `Master_F1_DWH_Load.dtsx`

2.2 Mapa Logiczna ETL (Uproszczona)

Poniżej przedstawiono uproszczoną mapę logiczną ilustrującą przepływ danych od plików źródłowych, przez transformacje, do tabel docelowych w hurtowni.



Rysunek 1: Uproszczona mapa logiczna procesu ETL.

(Uwaga: Pełna mapa logiczna powinna obejmować wszystkie źródła, kluczowe transformacje i tabele docelowe, w tym lookupy i agregacje.)

2.3 Narzędzia

Głównym narzędziem wykorzystanym do implementacji procesów ETL był SQL Server Integration Services (SSIS) wchodzący w skład Microsoft SQL Server. Pakiety SSIS zostały utworzone przy użyciu SQL Server Data Tools (SSDT) for Visual Studio.

3 Implementacja Procesów ETL

3.1 Ekstrakcja Danych (Extract)

Dane źródłowe w formacie CSV były wczytywane przy użyciu komponentu Flat File Source w SSIS. Kluczowe aspekty konfiguracji tego etapu to:

- Ustawienie strony kodowej na 65001 (UTF-8) dla wszystkich plików źródłowych, aby zapewnić poprawne odczytywanie znaków specjalnych.
- Poprawna identyfikacja separatorów kolumn, kwalifikatorów tekstu oraz obsługa wierszy nagłówkowych.
- Wstępne mapowanie typów danych na poziomie źródła, z uwzględnieniem późniejszych konwersji.

3.2 Transformacja Danych (Transform)

Etap transformacji obejmował szereg operacji mających na celu oczyszczenie, integrację i przygotowanie danych do załadowania do tabel docelowych.

1. **Konwersja Typów Danych:** Komponent `Data Conversion` był intensywnie wykorzystywany do jawnej konwersji typów danych z plików źródłowych (często tekstowych) na typy docelowe zdefiniowane w modelu hurtowni (np. `INT`, `DATE`, `DECIMAL`, `NVARCHAR` lub `VARCHAR` z odpowiednią stroną kodową). Szczególną uwagę zwrócono na konwersję:
 - Kolumn tekstowych (`string`) na `Unicode string [DT_WSTR]` w SSIS, co odpowiada typowi `NVARCHAR` w SQL Server, w celu uniknięcia problemów z różnymi stronami kodowymi i zapewnienia obsługi znaków międzynarodowych. Alternatywnie, dla kolumn docelowych `VARCHAR`, konwersja na `string [DT_STR]` z docelową stroną kodową (np. 1250).
 - Reprezentacji dat i czasów na odpowiednie typy (`DT_DATE`, `DT_DBTIME2`).
 - Wartości numerycznych.
2. **Obsługa Wartości NULL:** Wartości reprezentujące `NULL` w plikach CSV (np. ‘`N`’) były identyfikowane i konwertowane na rzeczywiste wartości `NULL` w przepływie danych przy użyciu komponentu `Derived Column`.
3. **Lookup’y Kluczy Zastępczych:** Podczas ładowania tabeli faktów (`Fact_Result`), komponent `Lookup Transformation` był używany do pobierania kluczy zastępczych (`surrogate keys`) z wcześniej załadowanych tabel wymiarów, bazując na kluczach naturalnych (np. `driverId`, `raceId`).
4. **Obliczenia Pochodne:** Komponent `Derived Column` służył do tworzenia nowych kolumn na podstawie istniejących, np.:

- Obliczenie wieku kierowcy w momencie wyścigu (`AgeAtRace`).
- Obliczenie zmiany pozycji (`PositionOrderChange`).

5. Agregacja Danych:

- **Dane pogodowe (`Dim_Weather`):** Minutowe dane pogodowe z pliku `F1_Weather (2023-2018).csv` były agregowane do poziomu pojedynczego wyścigu (po `Year` i `RoundNumber`) przy użyciu komponentu `Aggregate`. Obliczano wartości średnie, minimalne, maksymalne oraz sumy (np. dla opadów).
 - **Dane o pit-stopach:** Informacje o liczbie i łącznym czasie pit-stopów dla każdego kierowcy w wyścigu były agregowane z pliku `pit_stops.csv` i dołączane podczas ładowania tabeli faktów (np. poprzez wcześniejszą agregację do tabeli stagingowej i lookup).
6. **Kategoryzacja Danych Pogodowych:** Po agregacji, zagregowane wartości liczbowe dla danych pogodowych (np. temperatura, wilgotność, prędkość wiatru) były przekształcane na predefiniowane kategorie tekstowe (np. "Zimno", "Umiarkowanie", "Gorąco") przy użyciu wyrażeń warunkowych w komponencie `Derived Column`, zgodnie z założeniami projektu. Te kategorie zostały następnie załadowane do `Dim_Weather`.

3.3 Ładowanie Danych (Load)

Przetransformowane dane były ładowane do docelowych tabel w hurtowni SQL Server przy użyciu komponentu `OLE DB Destination`.

- Wykorzystano tryb szybkiego ładowania (`Table or view - fast load`).
- Zapewniono poprawne mapowanie kolumn z przepływu danych SSIS do kolumn tabel docelowych.
- Kolejność ładowania (najpierw wymiary, potem fakty) była zarządzana przez pakiet główny.

3.4 Wyzwania i Rozwiązania

Podczas implementacji napotkano typowe wyzwania związane z procesami ETL:

- **Niezgodność Stron Kodowych:** Początkowe problemy z konfliktem stron kodowych (np. 65001 z Flat File Source vs 1250 domyślne dla OLE DB Destination) zostały rozwiązane poprzez:
 1. Konsekwentne ustawienie kodowania 65001 (UTF-8) dla komponentów Flat File Source.
 2. Zastosowanie komponentu Data Conversion do jawnej konwersji kolumn tekstowych na typ Unicode string [DT_WSTR] (dla docelowych kolumn NVARCHAR) lub string [DT_STR] z określoną docelową stroną kodową (dla kolumn VARCHAR).
- **Synchronizacja Metadanych:** Zmiany w strukturze przepływu danych (np. po dodaniu Data Conversion) wymagały odświeżenia metadanych w komponencie OLE DB Destination i ponownego zmapowania kolumn.
- **Błędy Konwersji Danych w Źródle:** Błędy typu "Text was truncated or one or more characters had no match in the target code page" pojawiające się w Flat File Source wskazywały na niepoprawną konfigurację strony kodowej dla pliku źródłowego. Problem rozwiązano poprzez ustawienie strony kodowej na 65001 (UTF-8), co odpowiadało rzeczywistemu kodowaniu plików.

3.5 Przyrostowe Zasilanie (Planowane)

Dla tabeli faktów Fact_Result zaplanowano mechanizm przyrostowego zasilania. Polega on na przechowywaniu identyfikatora ostatnio załadowanego rekordu (np. resultId w tabeli kontrolnej) i ładowaniu w kolejnych uruchomieniach ETL tylko nowszych danych. *(Uwaga: Opisać, czy zostało to w pełni zaimplementowane, czy jest w planach na dalszy rozwój.)*

4 Podsumowanie i Wnioski z Etapu ETL

Proces ETL został pomyślnie zaimplementowany, umożliwiając zasilanie hurtowni danych Formuły 1 przetworzonymi i zintegrowanymi danymi. Kluczowe było właściwe zarządzanie typami danych i stronami kodowymi oraz logiczne rozplanowanie transformacji, w tym agregacji i kategoryzacji danych pogodowych. Zastosowanie SSIS pozwoliło na zbudowanie modularnego i zarządzalnego przepływu danych. Rozwiązane problemy z konwersją danych podkreślają znaczenie dokładnej analizy danych źródłowych i właściwej konfiguracji narzędzi ETL.

Kolejnym etapem będzie budowa kostki OLAP na bazie przygotowanej hurtowni danych oraz przeprowadzenie analiz wielowymiarowych.