

Projekt hurtowni danych do analizy wyników i czynników wpływających na osiągnięcia kierowców Formuły 1 w latach 1950-2023

Etap II: Proces ETL

Mikołaj Kubś, 272662

25 maja 2025

Spis treści

1	Wprowadzenie	2
2	Architektura i Narzędzia Procesu ETL	2
2.1	Struktura Procesu ETL	2
2.2	Mapa Logiczna ETL	2
2.2.1	Mapowanie Atrybutów: Dim_Driver	2
2.2.2	Mapowanie Atrybutów: Dim_Constructor	3
2.2.3	Mapowanie Atrybutów: Dim_Race	3
2.2.4	Mapowanie Atrybutów: Dim_Circuit	3
2.2.5	Mapowanie Atrybutów: Dim_Time	4
2.2.6	Mapowanie Atrybutów: Dim_Weather	4
2.2.7	Mapowanie Atrybutów: Dim_Status	4
2.2.8	Mapowanie Atrybutów: Fact_Result	5
2.3	Narzędzia	6
3	Implementacja Procesów ETL	6
3.1	Ekstrakcja Danych (Extract)	9
3.2	Transformacja Danych (Transform)	9
3.3	Ładowanie Danych (Load)	10
3.4	Event handler	10
3.5	Wyzwania i Rozwiązania	10
3.6	Przyrostowe Zasilanie (Planowane)	10
4	Podsumowanie i Wnioski z Etapu ETL	11

1 Wprowadzenie

Niniejszy dokument stanowi raport z realizacji drugiego etapu projektu hurtowni danych, koncentrującego się na procesie ETL (Extract, Transform, Load). Celem tego etapu było zasilenie zdefiniowanych w Etapie I tabel wymiarów i faktów danymi pochodzącymi z plików CSV, dotyczących wyników i czynników wpływających na osiągnięcia kierowców Formuły 1 w latach 1950-2023. Proces został zaimplementowany przy użyciu narzędzia SQL Server Integration Services (SSIS).

2 Architektura i Narzędzia Procesu ETL

2.1 Struktura Procesu ETL

Proces ETL został zorganizowany w ramach jednego projektu SSIS, zawierającego dedykowane pakiety dla ładowania poszczególnych tabel wymiarów oraz tabeli faktów. Dodatkowo, zaimplementowano pakiet główny (master package) koordynujący uruchamianie poszczególnych pakietów w odpowiedniej kolejności (najpierw wymiary, następnie fakty), aby zapewnić integralność referencyjną.

Struktura pakietów SSIS:

- _Dim_Circuit.dtsx
- _Dim_Driver.dtsx
- _Dim_Constructor.dtsx
- _Dim_Race.dtsx
- _Dim_Status.dtsx
- _Dim_Weather.dtsx
- _Fact_Result.dtsx
- _Dim_Time.dtsx

2.2 Mapa Logiczna ETL

2.2.1 Mapowanie Atrybutów: Dim_Driver

Tabela 1: Mapowanie ETL dla tabeli Dim_Driver

Atrybut	Źródła	Kolumna źródła	Transformacje i uwagi
DriverKey	-	-	SQL Server IDENTITY(1,1). Klucz zastępczy.
DriverID_NK	drivers.xlsx	driverId	Bezpośrednio. Klucz naturalny ze źródła.
FirstName	drivers.xlsx	forename	Bezpośrednio.
LastName	drivers.xlsx	surname	Bezpośrednio.
FullName	drivers.xlsx	forename, surname	Derived Column: forename + " " + surname. Pełne imię i nazwisko
DateOfBirth	drivers.xlsx	dob	Bezpośrednio.

Kontynuacja na następnej stronie

Tabela 1 – Kontynuacja z poprzedniej strony

Atrybut	Źródła	Kolumna źródła	Transformacje i uwagi
CountryName	drivers.xlsx, Helper_Nationality	nationality	Lookup do Helper_NationalityCountries.
Continent	Helper_Nationality Helper_Continent	CountryName poprzednio obliczone	Lookup do Helper_CountryContinents z poprzednio obliczonego CountryName

2.2.2 Mapowanie Atrybutów: Dim_Constructor

Tabela 2: Mapowanie ETL dla tabeli Dim_Constructor

Atrybut	Źródła	Kolumna źródła	Transformacje i uwagi
ConstructorKey	-	-	SQL Server IDENTITY(1,1). Klucz zastępczy.
ConstructorID_NK	constructors.xlsx	constructorId	Bezpośrednio. Klucz naturalny.
Name	constructors.xlsx	name	Bezpośrednio.
CountryName	constructors.xlsx Helper_Nationality	nationality	Lookup nationality do Helper_NationalityCountries.
Continent	Helper_Continent poprzednio obliczone CountryName	CountryName wcześniej obliczone	Lookup CountryName do Helper_CountryContinent

2.2.3 Mapowanie Atrybutów: Dim_Race

Tabela 3: Mapowanie ETL dla tabeli Dim_Race

Atrybut	Źródła	Kolumna źródła	Transformacje i uwagi
RaceKey	-	-	SQL Server IDENTITY(1,1). Klucz zastępczy.
RaceID_NK	races.xlsx	raceId	Bezpośrednio. Klucz naturalny.
CircuitID_NK	races.xlsx	circuitId	Bezpośrednio. NK obwodu dla tego wyścigu.
YearSeason	races.xlsx	year	Bezpośrednio.
RoundNumberInSeason	races.xlsx	round	Bezpośrednio.
RaceNameOfficial	races.xlsx	name	Bezpośrednio.
Date	races.xlsx	date	Bezpośrednio. Używana do DateKey w Fact.

2.2.4 Mapowanie Atrybutów: Dim_Circuit

Tabela 4: Mapowanie ETL dla tabeli Dim_Circuit

Atrybut	Źródła	Kolumna źródła	Transformacje i uwagi
CircuitKey	-	-	SQL Server IDENTITY(1,1). Klucz zastępczy.
CircuitID_NK	circuits.xlsx	circuitId	Bezpośrednio. Klucz naturalny.
CircuitName	circuits.xlsx	name	Bezpośrednio.
LocationCity	circuits.xlsx	location	Bezpośrednio.
CountryName	circuits.xlsx	country	Bezpośrednio.

2.2.5 Mapowanie Atrybutów: Dim_Time

Tabela 5: Mapowanie ETL dla tabeli Dim_Time

Atrybut	Źródła	Kolumna	Transformacje i uwagi
DateKey	Fact_Result	Distinct DateKey	Distinct z DateKey w Fact_Result. PK, YYYYMMDD INT.
FullDate	Dim_Time	DateKey wcześniej obliczone	Derived column: rok, miesiąc i dzień za pomocą modulo i dzielenia z DateKey.
Year	Dim_Time	FullDate wcześniej obliczone	Derived Column: DatePart YEAR z FullDate.
Quarter	Dim_Time	FullDate wcześniej obliczone	Derived Column: DatePart QUARTER z FullDate.
Month	Dim_Time	FullDate wcześniej obliczone	Derived Column: DatePart MONTH z FullDate.
MonthName	Dim_Time Helper_Months	Month wcześniej obliczone	Lookup na Helper_Months. Angielska nazwa.
DayOfMonth	Dim_Time	FullDate wcześniej obliczone	Derived Column: DatePart DAY z FullDate.
DayOfWeekName	Dim_Time Helper_Weekdays	Bazuje na FullDate	Derived Column: DatePart WEEKDAY - z tego Lookup na Helper_Weekdays. Angielska nazwa.

2.2.6 Mapowanie Atrybutów: Dim_Weather

Tabela 6: Mapowanie ETL dla tabeli Dim_Weather

Atrybut	Źródła	Źródła	Transformacje i uwagi
WeatherKey	weather.xlsx	RoundNumber, Year	Derived Column: Year * 100 + RoundNumber.
DidRainOccur	weather.xlsx	Rainfall	Najpierw Derived Column RainfallInt 1/0 -> Agregacja max z RainfallInt -> "Rain Occurred"/"No Rain".
WindSpeedCategory	weather.xlsx	WindSpeed	Agregacja AVG -> logika CASE dla kategorii: "Light Breeze", "Calm"...
AirTempCategory	weather.xlsx	AirTemp	Agregacja AVG -> logika CASE dla kategorii: "Cold", "Warm"...
TrackTempCategory	weather.xlsx	TrackTemp	Agregacja AVG -> logika CASE dla kategorii: "Optimal Track", "Very Hot Track"...
HumidityCategory	weather.xlsx	Humidity	Agregacja AVG -> logika CASE dla kategorii: "Dry", "Humid"...
PressureCategory	weather.xlsx	Pressure	Agregacja AVG -> logika CASE dla kategorii: "Very Low", "Normal"...

2.2.7 Mapowanie Atrybutów: Dim_Status

Tabela 7: Mapowanie ETL dla tabeli Dim_Status

Atrybut	Źródła	Kolumna źródła	Transformacje i uwagi
StatusKey	-	-	SQL Server IDENTITY(1,1). Klucz zastępczy.
StatusID_NK	status.xlsx	statusId	Bezpośrednio.
StatusDescription	status.xlsx	status	Bezpośrednio.
StatusCategory	status.xlsx Helper_Status	status	Fuzzy Lookup na status w Helper_StatusCategory -> BroadCategory. Kategoria np. Race Outcome, Mechanical Failure.

2.2.8 Mapowanie Atrybutów: Fact_Result

Tabela 8: Mapowanie ETL dla tabeli Fact_Result

Atrybut	Źródło CSV / Wymiar	Kolumna	Transformacje i uwagi
RaceKey	results.xlsx, Dim_Race	RaceKey	Lookup z Dim_Race.
DriverKey	results.xlsx, Dim_Driver	DriverKey	Lookup z Dim_Driver (res.driverId) -> DriverKey (SK). FK.
ConstructorKey	results.xlsx, Dim_Constructor	ConstructorKey	Lookup z Dim_Constr. (res.constructorId) -> ConstrKey (SK). FK.
CircuitKey	results.xlsx, Dim_Circuit	CircuitKey	Lookup z Dim_Circuit
DateKey	results.xlsx, Dim_Race	Date	Lookup z Dim_Race -> FullDate. Derived Column: (YEAR(FullDate)*10000) + (MONTH(FullDate)*100) + DAY(FullDate). INT YYYYMMDD.
WeatherKey	Dim_Weather / Dim_Race	races.raceId LUB races.year	Lookup z Dim_Race -> RaceID_NK (lub Year,Round). LkUp Dim_Weather. Der.Col: NULL jeśli rok < 2018. FK.
StatusKey	Dim_Status	results.statusId (NK)	Lookup z Dim_Status (res.statusId) -> StatusKey (SK). FK.
PointsScored	results.xlsx	points	Bezpośrednio.
LapsCompleted	results.xlsx	laps	Bezpośrednio.
NumberOfPitStops	pit_stops.xlsx	raceId, driverId	Pod-przepływ: Agg. (COUNT(stop) jako stopsCount). Merge Join (Left Outer). Der.Col: ISNULL(stopsCount) ? 0 : stopsCount.
RaceTimeMilliseconds	results.xlsx	milliseconds LUB time	Mapa bezp. LUB Der.Col (parsuj tekst time) + DC (do DT_I8). NULL jeśli DNF.
GridPosition	results.xlsx	grid	Mapa bezp. + DC (do DT_I4). Obsługa 0 dla pit lane.
FinalPositionOrder	results.xlsx	positionOrder LUB position	Mapa bezp. + DC (do DT_I4).
PositionOrderChange	results.xlsx	grid, positionOrder	Der.Col: GridPosition - FinalPositionOrder.
RankFastestLap	results.xlsx	rank (fast lap)	Mapa bezp. + DC (do DT_I4). NULL jeśli brak.
FastestLapTopSpeed	results.xlsx	fastestLapSpeed	Mapa bezp. + DC (do DT_DECIMAL). NULL jeśli brak.

Kontynuacja na następnej stronie


Tabela 8 – Kontynuacja z poprzedniej strony

Atrybut	Źródło CSV / Wy- miar	Kolumna	Transformacje i uwagi
AgeAtRace	Dim_Driver, Dim_Race	drivers.dob, ra- ces.date	LkUp Dim_Driver (dob). LkUp Dim_Race (date). Der.Col: Kalkulacja wieku. NULL jeśli dob NULL.


2.3 Narzędzia

Głównym narzędziem wykorzystanym do implementacji procesów ETL był SQL Server Integration Services (SSIS) wchodzący w skład Microsoft SQL Server. Pakiety SSIS zostały utworzone przy użyciu SQL Server Data Tools (SSDT) for Visual Studio. Dodatkowo do czyszczenia początkowych danych i zmiany formatu plików z danymi wykorzystano Python.


3 Implementacja Procesów ETL



Rysunek 1: Cały ETL.



Rysunek 2: ETL dla Fact_Result.



Rysunek 3: ETL dla Dim_Time.

SQLQuery1.sql - DE...GLE46P\Jantar (59))*

```
SELECT COUNT(*) FROM Dim_Circuit
SELECT COUNT(*) FROM Dim_Constructor
SELECT COUNT(*) FROM Dim_Driver
SELECT COUNT(*) FROM Dim_Race
SELECT COUNT(*) FROM Dim_Status
SELECT COUNT(*) FROM Dim_Weather
SELECT COUNT(*) FROM Dim_Time
SELECT COUNT(*) FROM Fact_Result
```

100 %



Results



Messages

	(No column name)
1	77

	(No column name)
1	212

	(No column name)
1	861

	(No column name)
1	1125

3.1 Ekstrakcja Danych (Extract)

Dane źródłowe w formacie XLSX były wczytywane przy użyciu komponentu Excel Source w SSIS. Kluczowe aspekty konfiguracji tego etapu to:

- Poprzednia konwersja plików .csv to .xlsx za pomocą skryptu Python, aby pominąć błędy w kodowaniu.
- Użycie skryptu Python do usunięcia "/"N" w zbiorze danych.
- Poprawna identyfikacja separatorów kolumn, kwalifikatorów tekstu oraz obsługa wierszy nagłówkowych.
- Wstępne mapowanie typów danych na poziomie źródła, z uwzględnieniem późniejszych konwersji.

3.2 Transformacja Danych (Transform)

Etap transformacji obejmował szereg operacji mających na celu oczyszczenie, integrację i przygotowanie danych do załadowania do tabel docelowych. Przykładowo:

1. **Konwersja Typów Danych:** Komponent Data Conversion był wykorzystany do konwersji danych.
2. **Obliczenia Pochodne:** Komponent Derived Column służył do tworzenia nowych kolumn na podstawie istniejących, np.:
 - Obliczenie wieku kierowcy w momencie wyścigu (AgeAtRace).
 - Obliczenie zmiany pozycji (PositionOrderChange).
3. **Agregacja Danych:**
 - **Dane pogodowe (Dim_Weather):** Minutowe dane pogodowe z pliku weather.xlsx były agregowane do poziomu pojedynczego wyścigu (po Year i RoundNumber) przy użyciu komponentu Aggregate. Obliczano wartości średnie, minimalne, maksymalne oraz sumy (np. dla opadów).
 - **Dane o pit-stopach:** Informacje o liczbie i łącznym czasie pit-stopów dla każdego kierowcy w wyścigu były agregowane z pliku pit_stops.xlsx i dołączane podczas ładowania tabeli faktów (np. poprzez wcześniejszą agregację do tabeli stagingowej i lookup).
4. **Kategoryzacja Danych Pogodowych:** Po agregacji, zagregowane wartości liczbowe dla danych pogodowych (np. temperatura, wilgotność, prędkość wiatru) były przekształcane na predefiniowane kategorie tekstowe (np. "Zimno", "Umiarkowanie", "Gorąco") przy użyciu wyrażeń warunkowych w komponencie Derived Column, zgodnie z założeniami projektu. Te kategorie zostały następnie załadowane do Dim_Weather. Transformacja odbyła się w skrypcie C#.
5. **Fuzzy Lookup:** Do statusów dołączono ogólną kategorię statusu np. 'Mechanical Failure', 'Race Outcome' itd.


3.3 Ładowanie Danych (Load)

Przetransformowane dane były ładowane do docelowych tabel w hurtowni SQL Server przy użyciu komponentu OLE DB Destination.

- Wykorzystano tryb szybkiego ładowania (Table or view - fast load).
- Zapewniono poprawne mapowanie kolumn z przepływu danych SSIS do kolumn tabel docelowych.
- Kolejność ładowania (najpierw wymiary, potem fakty) była zarządzana przez pakiet główny.

3.4 Event handler

W przypadku błędu, wszystkie dane są usuwane. Wcześniej podczas developmentu dodatkowo tabele były populowane, ponieważ wtedy występował błąd w metadanych SSIS.



Rysunek 5: Error handler.

3.5 Wyzwania i Rozwiązania

Podczas implementacji napotkano typowe wyzwania związane z procesami ETL:

- **Niezgodność Stron Kodowych:** Początkowe problemy z konfliktem stron kodowych (np. 65001 z Flat File Source vs 1250 domyślne dla OLE DB Destination) zostały rozwiązane poprzez zmianę typu plików na Excel.
- **Synchronizacja Metadanych:** Zmiany w strukturze przepływu danych (np. po dodaniu Data Conversion) wymagały odświeżenia metadanych w komponencie OLE DB Destination i ponownego zmapowania kolumn.
- **Błędy Konwersji Danych w Źródle:** Błędy typu "Text was truncated or one or more characters had no match in the target code page" pojawiające się w Excel Source wskazywały na niepoprawną konfigurację strony kodowej dla pliku źródłowego. Trzeba było zmienić ręcznie w advanced editor dla źródła typy kolumn.

3.6 Przyrostowe Zasilanie (Planowane)

Nie zaimplementowano z braku czasu. Można by uruchomić dla tabeli faktów, za każdym razem usuwając wszystkie wymiary i klucze do wymiarów w fakcie, zapisanie jaki najnowszy id? w fakcie już był, a potem załadowanie wszystkich wymiarów i wierszy o id powyżej ostatniego id faktu.

4 Podsumowanie i Wnioski z Etapu ETL

Proces ETL został pomyślnie zaimplementowany, umożliwiając zasilenie hurtowni danych Formuły 1 przetworzonymi i zintegrowanymi danymi. Kluczowe było właściwe zarządzanie typami danych i stronami kodowymi oraz logiczne rozplanowanie transformacji, w tym agregacji i kategoryzacji danych pogodowych. Zastosowanie SSIS pozwoliło na zbudowanie modularnego i zarządzalnego przepływu danych. Rozwiązane problemy z konwersją danych podkreślają znaczenie dokładnej analizy danych źródłowych i właściwej konfiguracji narzędzi ETL.

Kolejnym etapem będzie budowa kostki OLAP na bazie przygotowanej hurtowni danych oraz przeprowadzenie analiz wielowymiarowych.