

Projekt hurtowni danych do analizy wyników i czynników wpływających na osiągnięcia kierowców Formuły 1 w latach 1950-2023

Etap II: Proces ETL

Mikołaj Kubś, 272662

26 maja 2025

Spis treści

1 Wprowadzenie

Niniejszy dokument stanowi raport z realizacji drugiego etapu projektu hurtowni danych, koncentrującego się na procesie ETL (Extract, Transform, Load). Celem tego etapu było zasilenie zdefiniowanych w Etapie I tabel wymiarów i faktów danymi pochodzącymi z plików CSV, dotyczących wyników i czynników wpływających na osiągnięcia kierowców Formuły 1 w latach 1950-2023. Proces został zaimplementowany przy użyciu narzędzia SQL Server Integration Services (SSIS).

2 Architektura i Narzędzia Procesu ETL

2.1 Struktura Procesu ETL

Proces ETL został zorganizowany w ramach jednego projektu SSIS, zawierającego dedykowane pakiety dla ładowania poszczególnych tabel wymiarów oraz tabeli faktów. Dodatkowo, zaimplementowano pakiet główny (master package) koordynujący uruchamianie poszczególnych pakietów w odpowiedniej kolejności (najpierw wymiary, następnie fakty), aby zapewnić integralność referencyjną.

Struktura pakietów SSIS (przykładowa):

- `Load_Dim_Circuit.dtsx`
- `Load_Dim_Driver.dtsx`
- `Load_Dim_Constructor.dtsx`
- `Load_Dim_Race.dtsx`
- `Load_Dim_Time.dtsx`
- `Load_Dim_Status.dtsx`
- `Load_Dim_Weather.dtsx`
- `Load_Fact_Result.dtsx`

2.2 Mapa Logiczna ETL

2.3 Narzędzia

Głównym narzędziem wykorzystanym do implementacji procesów ETL był SQL Server Integration Services (SSIS) wchodzący w skład Microsoft SQL

Server. Pakiety SSIS zostały utworzone przy użyciu SQL Server Data Tools (SSDT) for Visual Studio.

3 Implementacja Procesów ETL

3.1 Ekstrakcja Danych (Extract)

Dane źródłowe w formacie XLSX były wczytywane przy użyciu komponentu `Excel Source` w SSIS. Kluczowe aspekty konfiguracji tego etapu to:

- Poprzednia konwersja plików .csv to .xlsx za pomocą skryptu Python, aby pominąć błędy w kodowaniu.
- Użycie skryptu Python do usunięcia "/N" w zbiorze danych.
- Poprawna identyfikacja separatorów kolumn, kwalifikatorów tekstu oraz obsługa wierszy nagłówkowych.
- Wstępne mapowanie typów danych na poziomie źródła, z uwzględnieniem późniejszych konwersji.

3.2 Transformacja Danych (Transform)

Etap transformacji obejmował szereg operacji mających na celu oczyszczenie, integrację i przygotowanie danych do załadowania do tabel docelowych. Przykładowo:

1. **Konwersja Typów Danych:** Komponent `Data Conversion` był wykorzystany do konwersji danych.
2. **Obliczenia Pochodne:** Komponent `Derived Column` służył do tworzenia nowych kolumn na podstawie istniejących, np.:
 - Obliczenie wieku kierowcy w momencie wyścigu (`AgeAtRace`).
 - Obliczenie zmiany pozycji (`PositionOrderChange`).
3. **Agregacja Danych:**
 - **Dane pogodowe (`Dim_Weather`):** Minutowe dane pogodowe z pliku `F1_Weather (2023-2018).csv` były agregowane do poziomu pojedynczego wyścigu (po `Year` i `RoundNumber`) przy użyciu komponentu `Aggregate`. Obliczano wartości średnie, minimalne, maksymalne oraz sumy (np. dla opadów).

- **Dane o pit-stopach:** Informacje o liczbie i łącznym czasie pit-stopów dla każdego kierowcy w wyścigu były agregowane z pliku `pit_stops.csv` i dołączane podczas ładowania tabeli faktów (np. poprzez wcześniejszą agregację do tabeli stagingowej i lookup).
4. **Kategoryzacja Danych Pogodowych:** Po agregacji, zagregowane wartości liczbowe dla danych pogodowych (np. temperatura, wilgotność, prędkość wiatru) były przekształcane na predefiniowane kategorie tekstowe (np. "Zimno", "Umiarkowanie", "Gorąco") przy użyciu wyrażeń warunkowych w komponencie `Derived Column`, zgodnie z założeniami projektu. Te kategorie zostały następnie załadowane do `Dim_Weather`. Transformacja odbyła się w skrypcie C.
 5. **Fuzzy Lookup:** Do statusów dołączono ogólną kategorię statusu np. 'Mechanical Failure', 'Race Outcome' itd.

3.3 Ładowanie Danych (Load)

Przetransformowane dane były ładowane do docelowych tabel w hurtowni SQL Server przy użyciu komponentu `OLE DB Destination`.

- Wykorzystano tryb szybkiego ładowania (`Table or view - fast load`).
- Zapewniono poprawne mapowanie kolumn z przepływu danych SSIS do kolumn tabel docelowych.
- Kolejność ładowania (najpierw wymiary, potem fakty) była zarządzana przez pakiet główny.

3.4 Wyzwania i Rozwiązania

Podczas implementacji napotkano typowe wyzwania związane z procesami ETL:

- **Niezgodność Stron Kodowych:** Początkowe problemy z konfliktem stron kodowych (np. 65001 z Flat File Source vs 1250 domyślne dla OLE DB Destination) zostały rozwiązane poprzez zmianę typu plików na Excel.
- **Synchronizacja Metadanych:** Zmiany w strukturze przepływu danych (np. po dodaniu `Data Conversion`) wymagały odświeżenia metadanych w komponencie `OLE DB Destination` i ponownego zmapowania kolumn.

- **Błędy Konwersji Danych w Źródle:** Błędy typu "Text was truncated or one or more characters had no match in the target code page" pojawiające się w **Excel Source** wskazywały na niepoprawną konfigurację strony kodowej dla pliku źródłowego. Trzeba było zmienić ręcznie w advanced editor dla źródła typy kolumn.

3.5 Przyrostowe Zasilanie (Planowane)

Nie zaimplementowano z braku czasu. Można by uruchomić dla tabeli faktów, za każdym razem usuwając wszystkie wymiary i klucze do wymiarów w fakcie, zapisanie jaki najnowszy id? w fakcie już był, a potem załadowanie wszystkich wymiarów i wierszy o id powyżej ostatniego id faktu.

4 Podsumowanie i Wnioski z Etapu ETL

Proces ETL został pomyślnie zaimplementowany, umożliwiając zasilanie hurtowni danych Formuły 1 przetworzonymi i zintegrowanymi danymi. Kluczowe było właściwe zarządzanie typami danych i stronami kodowymi oraz logiczne rozplanowanie transformacji, w tym agregacji i kategoryzacji danych pogodowych. Zastosowanie SSIS pozwoliło na zbudowanie modułarnego i zarządzalnego przepływu danych. Rozwiązane problemy z konwersją danych podkreślają znaczenie dokładnej analizy danych źródłowych i właściwej konfiguracji narzędzi ETL.

Kolejnym etapem będzie budowa kostki OLAP na bazie przygotowanej hurtowni danych oraz przeprowadzenie analiz wielowymiarowych.