

Projekt hurtowni danych do analizy wyników i czynników wpływających na osiągnięcia kierowców Formuły 1 w latach 1950-2023

Mikołaj Kubś, 272662

15 czerwca 2025

Spis treści

1	Wprowadzenie do projektu	5
2	Charakterystyka dziedziny problemowej, krótki opis obszaru analizy, problemy i potrzeby	5
2.1	Dziedzina problemowa	5
2.2	Krótki opis obszaru analizy	5
2.3	Problemy i potrzeby	5
3	Cel przedsięwzięcia (oczekiwania) oraz zakres analizy - badane aspekty	6
3.1	Cel przedsięwzięcia	6
3.2	Oczekiwania	6
3.3	Zakres analizy - badane aspekty	6
4	Źródła danych (lokalizacja, format, dostępność), wstępna analiza źródeł danych	7
4.1	Wstępna analiza źródeł	8
5	Profilowanie danych (analiza jakości danych oraz ich przydatności w projekcie)	9
5.1	Plik: <code>circuits.csv</code>	9
5.2	Plik: <code>constructors.csv</code>	9
5.3	Plik: <code>drivers.csv</code>	10
5.4	Plik: <code>lap_times.csv</code>	10
5.5	Plik: <code>pit_stops.csv</code>	11

5.6	Plik: <code>rac.es.csv</code>	11
5.7	Plik: <code>results.csv</code>	12
5.8	Plik: <code>status.csv</code>	12
5.9	Plik: <code>weather.csv</code>	13
6	Definicja typów encji/klas, związków, diagram klas	13
6.1	Tabela faktów: <code>Fact_Result</code>	14
6.2	Wymiary	15
6.3	Diagram klas (schemat gwiazdy)	16
7	Min. 10 wielowymiarowych zestawień	16
8	Implementacja bazy danych (konceptualny model danych - DDL)	18
9	Wnioski	20
9.1	Główne korzyści	21
9.2	Potencjalne wyzwania	21
10	Architektura i narzędzia procesu ETL	22
10.1	Struktura procesu ETL	22
10.2	Mapa logiczna ETL	22
10.2.1	Mapowanie atrybutów: <code>Dim_Driver</code>	22
10.2.2	Mapowanie atrybutów: <code>Dim_Constructor</code>	23
10.2.3	Mapowanie atrybutów: <code>Dim_Race</code>	23
10.2.4	Mapowanie atrybutów: <code>Dim_Circuit</code>	23
10.2.5	Mapowanie atrybutów: <code>Dim_Time</code>	24
10.2.6	Mapowanie Atrybutów: <code>Dim_Weather</code>	24
10.2.7	Mapowanie Atrybutów: <code>Dim_Status</code>	25
10.2.8	Mapowanie atrybutów: <code>Fact_Result</code>	25
10.3	Narzędzia	26
11	Implementacja procesów ETL	27
11.1	Ekstrakcja danych (Extract)	30
11.2	Transformacja danych (Transform)	30
11.3	Ładowanie danych (Load)	31
11.4	Event handler	31
11.5	Wyzwania i rozwiązania	31
12	Podsumowanie i wnioski z etapu ETL	32

13 Projekt kostki OLAP	32
13.1 Struktura kostki	32
13.2 Wymiary kostki	32
13.3 Hierarchie w wymiarach	33
13.4 KPI	33
14 Implementacja kostki OLAP	34
15 Zestawienia wielowymiarowe i analizy	36
15.1 10 najczęstszych przyczyn awarii mechanicznych europejskich konstruktorów w latach 1950-1960	37
15.2 10 najczęstszych przyczyn awarii mechanicznych europejskich konstruktorów w latach 2010-2020	37
15.3 Średnia bezwzględna zmiana kolejności pozycji na torach w Austrii, Belgii, Francji i Niemczech	38
15.4 Średnia pozycja na mecie w zależności od pozycji startowej w Grand Prix Wielkiej Brytanii w latach 1990-2009	39
15.5 Procent DNF i średnia pozycja na mecie według grup wiekowych	40
15.6 Procent zwycięstw i średnia prędkość najszybszego okrążenia według grup wiekowych	41
15.7 Procent ukończeń wyścigu według kategorii pogodowych	42
15.8 Top 5 konstruktorów według średniej liczby punktów	43
15.9 Procent zwycięstw na przestrzeni lat 2018-2024 dla 9 najlepszych kierowców w Europie	43
15.10 Średnia liczba pit stopów w zależności od występowania deszczu w latach 2018-2023	44
15.11 Średni czas wyścigu na torze Autodromo Nazionale di Monza według roku	45
15.12 Podium z pierwszej dziesiątki lub spoza pierwszej dziesiątki pól startowych według kategorii deszczu i wiatru	46
16 Dokumentacja kostki	47
16.1 Opis wymiarów i atrybutów	47
16.1.1 Dim_Driver (Kierowca)	47
16.1.2 Dim_Constructor (Konstruktor)	47
16.1.3 Dim_Race (Wyścig)	47
16.1.4 Dim_Circuit (Tor)	48
16.1.5 Dim_Time (Czas)	48
16.1.6 Dim_Weather (Pogoda)	49
16.1.7 Dim_Status (Status ukończenia)	49
16.1.8 Dim_DegenerateDetails (Wymiar zdegenerowany)	49

16.2 Miary	50
17 Wnioski z analizy danych	51

1 Wprowadzenie do projektu

Proces tworzenia hurtowni danych powinien być poprzedzony zrozumieniem „potrzeb biznesu” oraz rzeczywistości (dziedziny problemowej) reprezentowanej przez dostępne zasoby danych. Realizacja poniższego zadania ma uzmysłowić występujące problemy w określonym (wybranym) wycinku rzeczywistości, a następnie umożliwić zidentyfikowanie (określenie) potrzeb, celu i możliwości analiz biznesowych, by wspierać procesy decyzyjne (podejmowanie właściwych decyzji biznesowych).

2 Charakterystyka dziedziny problemowej, krótki opis obszaru analizy, problemy i potrzeby

2.1 Dziedzina problemowa

Dziedziną problemową są Mistrzostwa Świata Formuły 1 - najbardziej prestiżowa seria wyścigów samochodowych na świecie, charakteryzująca się zaawansowaną technologią, rywalizacją na najwyższym poziomie oraz bogatą historią.

2.2 Krótki opis obszaru analizy

Analiza obejmuje historyczne dane dotyczące wyników kierowców i zespołów (konstruktorów) Formuły 1, począwszy od inauguracyjnego sezonu 1950 aż do końca sezonu 2023. Badane będą zarówno indywidualne osiągnięcia (pozycje, punkty, czasy), jak i dynamika zespołowa, strategie wyścigowe (np. pit-stopy), wpływ charakterystyki torów oraz, dla wybranego okresu (2018-2023), wpływ warunków atmosferycznych na przebieg i rezultaty wyścigów.

2.3 Problemy i potrzeby

- **Zrozumienie czynników sukcesu:** Identyfikacja kluczowych elementów (np. pozycja startowa, niezawodność bolidu, skuteczność strategii, umiejętności kierowcy, osiągi zespołu) determinujących wyniki w F1.
- **Analiza trendów historycznych:** Obserwacja ewolucji sportu, okresów dominacji poszczególnych zespołów i kierowców, wpływu zmian technologicznych i regulaminowych na wyniki.
- **Ocena strategii wyścigowych:** Analiza skuteczności różnych strategii (np. liczba i moment pit-stopów) w zależności od toru, warunków pogodowych i sytuacji na torze.

- **Obiektywna ocena kierowców i zespołów:** Umożliwienie porównania osiągnięć kierowców, również w kontekście siły zespołu, dla którego startowali w różnych okresach.
- **Potrzeby analityczne dla fanów i ekspertów:** Dostarczenie narzędzia do głębszego zrozumienia sportu, weryfikacji hipotez, tworzenia rankingów i zaawansowanych porównań wykraczających poza standardowe tabele wyników.
- **Analiza wpływu czynników zewnętrznych:** Zbadanie, w jakim stopniu warunki pogodowe (temperatura, opady, wiatr) korelują z wynikami wyścigów, liczbą awarii, czy pojawianiem się nieoczekiwanych rezultatów ("niespodzianek").

3 Cel przedsięwzięcia (oczekiwania) oraz zakres analizy - badane aspekty

3.1 Cel przedsięwzięcia

Głównym celem przedsięwzięcia jest zaprojektowanie i implementacja funkcjonalnej hurtowni danych wraz z kostką OLAP, która umożliwi wielowymiarową analizę wyników wyścigów Formuły 1. Narzędzie to ma pozwolić na identyfikację wzorców, trendów oraz zależności między różnymi czynnikami (charakterystyka kierowcy, zespołu, toru, strategii, pogody) a osiągnięciami sportowymi.

3.2 Oczekiwania

Oczekuje się, że stworzona hurtownia danych pozwoli na efektywne i intuicyjne uzyskiwanie odpowiedzi na złożone pytania analityczne. Model danych powinien być zrozumiały dla użytkownika końcowego, umożliwiając elastyczne operacje analityczne takie jak drążenie danych (drill-down, roll-up) oraz krojenie i kostkowanie (slice and dice).

3.3 Zakres analizy - badane aspekty

- **Wyniki indywidualne i zespołowe:** Pozycje startowe (grid) i końcowe, zdobyte punkty, czasy ukończenia wyścigów, czasy poszczególnych okrążeń (w tym najszybsze okrążenie), status ukończenia wyścigu (np. ukończony, DNF, zdyskwalifikowany).

- **Kierowcy:** Dane demograficzne (narodowość, data urodzenia, wiek w momencie wyścigu), historia startów, przynależność zespołowa w poszczególnych wyścigach.
- **Zespoły (Konstruktorzy):** Narodowość, historia startów, sumaryczne wyniki w poszczególnych wyścigach i sezonach.
- **Wyścigi (Events):** Sezon (rok), numer rundy w sezonie, nazwa Grand Prix, data i godzina rozpoczęcia.
- **Tory wyścigowe:** Charakterystyka toru (nazwa, lokalizacja, kraj, długość, typ).
- **Strategia wyścigowa:** Liczba odbytych pit-stopów, okrążenia, na których miały miejsce, czas trwania postojów.
- **Warunki pogodowe (dla lat 2018-2023):** Agregowane dane dotyczące temperatury powietrza i toru, wilgotności, ciśnienia, występowania opadów, kierunku i siły wiatru podczas wyścigu.
- **Wpływ regulacji (pośrednio):** Analiza zmian w wynikach, strategiach czy dominacji zespołów na przestrzeni lat może pośrednio wskazywać na wpływ zmian regulaminowych, choć same regulacje nie będą modelowane jako bezpośredni wymiar.

4 Źródła danych (lokalizacja, format, dostępność), wstępna analiza źródeł danych

Tabela 1: Źródło danych: Formula 1 World Championship (1950-2023)

Plik	Format	Rekordy	Rozmiar	Opis
https://www.kaggle.com/datasets/rohanrao/formula-1-world-championship-1950-2020 (dane aktualizowane do 2023)				
circuits.csv	CSV	78	<0.1MB	Info o torach (ID, nazwa, kraj).
constructors.csv	CSV	212	<0.1MB	Info o konstr. (ID, nazwa).
constructor_results.csv	CSV	12625	0.2MB	Wyniki konstruktorów (punkty).
constructor_standings.csv	CSV	13391	0.3MB	Pozycja konstr. po wyścigu.
drivers.csv	CSV	861	0.1MB	Info o kierowcach (ID, nazwisko).
driver_standings.csv	CSV	34863	0.8MB	Pozycja kierowców po wyścigu.
lap_times.csv	CSV	589k	16.8MB	Czasy okrążeń.
pit_stops.csv	CSV	11371	0.4MB	Dane o pit-stopach.
qualifying.csv	CSV	10494	0.4MB	Wyniki kwalifikacji.
races.csv	CSV	1126	0.2MB	Dane o wyścigach (ID, rok, tor).
results.csv	CSV	26759	1.6MB	Szczegółowe wyniki kierowców.
sprint_results.csv	CSV	360	<0.1MB	Wyniki sprintów.
status.csv	CSV	139	<0.1MB	Opis statusu zakończenia.

Tabela 2: Źródło danych: Minute by Minute F1 Grand Prix Weather Data (2018-2023)

Plik	Format	Rekordy	Rozmiar	Opis
https://www.kaggle.com/datasets/quantumkaze/f1-weather-dataset-2018-2023				
F1 Weather (2023-2018) .csv	CSV	18214	1.1MB	Minutowe dane pogodowe dla wyścigów GP F1 (2018-2023). Kolumny: Time, AirTemp, Humidity, Pressure, Rainfall, TrackTemp, WindDirection, WindSpeed, Round Number, Year.

Uwaga dotycząca danych pogodowych: Dane z pliku `F1 Weather(2023-2018) .csv` są zbierane minuta po minucie. Do celów hurtowni danych, te szczegółowe dane będą agregowane (np. poprzez uśrednianie wartości temperatury, wilgotności, prędkości wiatru; określenie dominującego kierunku wiatru; sumowanie/oznaczanie wystąpienia opadów) do poziomu całego wyścigu, aby móc je powiązać z tabelą faktów wyników wyścigów.

4.1 Wstępna analiza źródeł

- **Pierwsze źródło (Formula 1 World Championship):** Jest to zbiór bardzo obszerny i szczegółowy, zawierający dane historyczne od 1950 roku. Kluczowe pliki dla budowy hurtowni to:
 - `results.csv`: Główne źródło dla tabeli faktów, zawierające wyniki poszczególnych kierowców w wyścigach.
 - `races.csv`: Dane o poszczególnych wyścigach (rok, runda, data, tor), kluczowe do łączenia z wynikami i danymi pogodowymi.
 - `drivers.csv`, `constructors.csv`, `circuits.csv`, `status.csv`: Podstawowe źródła dla odpowiednich wymiarów (Kierowcy, Konstruktorzy, Tory, Status Zakończenia).
 - `lap_times.csv`, `pit_stops.csv`: Dostarczają dodatkowych miar lub atrybutów, które mogą być włączone do tabeli faktów lub analizowane w bardziej szczegółowych kontekstach (np. średni czas pitstopu, najszybsze okrążenie).

Dane w tym zbiorze są generalnie dobrze zidentyfikowane przez klucze numeryczne (np. `raceId`, `driverId`, `constructorId`), co ułatwi proces łączenia tabel w procesie ETL.

- **Drugie źródło (Minute by Minute F1 Grand Prix Weather Data):** Ten zbiór dostarcza szczegółowych, minutowych danych pogodowych dla Grand Prix Formuły 1 w latach 2018-2023. Zawiera takie informacje jak temperatura powietrza i toru, wilgotność, ciśnienie, opady, kierunek i prędkość wiatru.

- **Kluczowe wyzwanie i podejście:** Ze względu na wysoką granulację czasową (minuta po minucie), dane te nie mogą być bezpośrednio połączone z tabelą faktów opisującą całościowy wynik kierowcy w wyścigu. Konieczna będzie **agregacja** tych danych do poziomu całego wyścigu (lub jego kluczowych faz). W procesie ETL obliczane będą wartości średnie, minimalne, maksymalne, sumaryczne (np. dla opadów) dla każdego wyścigu.
- **Łączenie po agregacji:** Zagregowane dane pogodowe dla danego wyścigu zostaną połączone z głównym zbiorem danych poprzez wspólne identyfikatory: rok (**Year**) i numer rundy (**Round Number**), które są obecne w obu zbiorach (w pierwszym zbiorze w pliku `races.csv`).

5 Profilowanie danych (analiza jakości danych oraz ich przydatności w projekcie)

Poniżej przedstawiono szczegółowe profilowanie danych dla każdego pliku CSV wykorzystywanego w projekcie. Analiza opiera się na raportach wygenerowanych przez bibliotekę ‘ydata-profiling’. Analizowane będą tylko przydatne atrybuty.

5.1 Plik: `circuits.csv`

Tabela 3: Profilowanie danych dla `circuits.csv`

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	<code>'circuitId'</code>	Numeric (Real)	Min: 1, Max: 80	Klucz główny. Unikalny, brak braków. Jakość wysoka.
2.	<code>'circuitRef'</code>	Text	Unikalne wartości	Tekstowy ID. Unikalny, brak braków. Jakość wysoka. Przydatny.
3.	<code>'name'</code>	Text	Unikalne wartości	Nazwa toru. Unikalny, brak braków. Jakość wysoka. Przydatny.
4.	<code>'location'</code>	Text	75 unikalnych (z 77)	Miasto. Brak braków. Jakość dobra. Przydatny.
5.	<code>'country'</code>	Categorical	35 unikalnych	Kraj. Brak braków. Jakość dobra. Kluczowy dla wymiaru geo.
6.	<code>'lat'</code>	Numeric (Real)	Min: -37.85, Max: 57.27	Szer. geogr. Unikalna, brak braków. Jakość wysoka. Przydatna.
7.	<code>'lng'</code>	Numeric (Real)	Min: -118.19, Max: 144.97	Dł. geogr. Unikalna, brak braków. Jakość wysoka. Przydatna.
8.	<code>'alt'</code>	Numeric (Real)	Min: -7, Max: 2227; 2.6% Zeros	Wysokość n.p.m. Brak braków. Jakość dobra.

5.2 Plik: `constructors.csv`

Tabela 4: Profilowanie danych dla `constructors.csv`

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'constructorId'	Numeric (Real)	Min: 1, Max: 215	Klucz główny. Unikalny, brak braków. Jakość wysoka.
2.	'constructorRef'	Text	Unikalne wartości	Tekstowy ID. Unikalny, brak braków. Jakość wysoka.
3.	'name'	Text	Unikalne wartości	Nazwa. Unikalny, brak braków. Jakość wysoka. Kluczowy atrybut.
4.	'nationality'	Categorical	24 unikalne	Narodowość. Brak braków. Jakość dobra. Ważny atrybut.

5.3 Plik: `drivers.csv`

Tabela 5: Profilowanie danych dla `drivers.csv`

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'driverId'	Numeric (Real)	Min: 1, Max: 862	Klucz główny. Unikalny, brak braków. Jakość wysoka.
2.	'driverRef'	Text	Unikalne wartości	Tekstowy ID. Unikalny, brak braków. Jakość wysoka.
3.	'number'	Numeric (Real)	Min: 2, Max: 99	Nr startowy. **93.1% braków!** Niska/średnia jakość.
4.	'code'	Text	97 unikalnych	Kod kierowcy. **87.9% braków!** Niska/średnia jakość.
5.	'forename'	Text	478 unikalnych	Imię. Brak braków. Jakość wysoka. Kluczowy.
6.	'surname'	Text	802 unikalne	Nazwisko. Brak braków. Jakość wysoka. Kluczowy.
7.	'dob'	DateTime	Min: 1896, Max: 2005	Data urodzenia. Brak braków. Jakość wysoka. Kluczowy.
8.	'nationality'	Categorical	43 unikalne	Narodowość. Brak braków. Jakość dobra. Ważny atrybut.

5.4 Plik: `lap_times.csv`

Tabela 6: Profilowanie danych dla `lap_times.csv`

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'raceId'	Numeric (Real)	Min: 1, Max: 1144	Klucz obcy. Brak braków. Jakość wysoka.
2.	'driverId'	Numeric (Real)	Min: 1, Max: 862	Klucz obcy. Brak braków. Jakość wysoka.
3.	'lap'	Numeric (Real)	Min: 1, Max: 87	Nr okrążenia. Brak braków. Jakość wysoka.

Ciąg dalszy na następnej stronie

Tabela 6 – ciąg dalszy

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
4.	'position'	Numeric (Real)	Min: 1, Max: 24	Pozycja na okrążeniu. Brak braków. Jakość wysoka.
5.	'time'	Text	np. "1:38.109"	Czas okr. (tekst). Brak braków. Wymaga parsowania. Jakość wysoka.
6.	'milliseconds'	Numeric (Real)	Min: 55404, Max: 7.5M	Czas okr. (ms). Brak braków. Jakość średnia. Kluczowa miara. Max wartość to anomalia.

5.5 Plik: pit_stops.csv

Tabela 7: Profilowanie danych dla pit_stops.csv

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'raceId'	Numeric (Real)	Min: 841, Max: 1144	Klucz obcy. Brak braków. Dane od raceId > 840. Jakość wysoka.
2.	'driverId'	Numeric (Real)	Min: 1, Max: 862	Klucz obcy. Brak braków. Jakość wysoka.
3.	'stop'	Numeric (Real)	Min: 1, Max: 70	Nr pit stopu. Brak braków. Max 70 to anomalia. Jakość ok.
4.	'lap'	Numeric (Real)	Min: 1, Max: 78	Okrążenie pit stopu. Brak braków. Jakość wysoka.
5.	'time'	DateTime	HH:MM:SS	Godzina pit stopu z dodatkową datą. Wymaga parsowania. Dobra jakość.
6.	'duration'	Text	np. "26.898"	Czas trwania (tekst). Brak braków. Wymaga parsowania. Jakość dobra.
7.	'milliseconds'	Numeric (Real)	Min: 12.9k, Max: 3M	Czas trwania (ms). Brak braków. Jakość wysoka. Max wartość (51min) to anomalia.

5.6 Plik: races.csv

Tabela 8: Profilowanie danych dla races.csv

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'raceId'	Numeric (Real)	Min: 1, Max: 1144	Klucz główny. Unikalny, brak braków. Jakość wysoka.
2.	'year'	Numeric (Real)	Min: 1950, Max: 2024	Rok. Brak braków. Jakość wysoka. Kluczowy.
3.	'round'	Numeric (Real)	Min: 1, Max: 24	Runda. Brak braków. Jakość wysoka. Kluczowy.
4.	'circuitId'	Numeric (Real)	Min: 1, Max: 80	Klucz obcy. Brak braków. Jakość wysoka. Kluczowy.
5.	'name'	Text	54 unikalne	Nazwa GP. Brak braków. Jakość wysoka.
6.	'date'	DateTime	Min: 1950, Max: 2024	Data wyścigu. Unikalna, brak braków. Jakość wysoka. Kluczowa.

Ciąg dalszy na następnej stronie

Tabela 8 – ciąg dalszy

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
7.	'time'	DateTime	HH:MM:SS; Braki 65.0%	Godzina startu. Błędnie jako DateTime. Dużo braków - dane tylko od 2005 roku. Wymaga parsowania. Może być kluczowy do pogody.

5.7 Plik: results.csv

Tabela 9: Profilowanie danych dla results.csv

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'resultId'	Numeric (Real)	Min: 1, Max: 26764	Klucz główny. Unikalny, brak braków. Jakość wysoka.
2.	'raceId'	Numeric (Real)	Min: 1, Max: 1144	Klucz obcy. Brak braków. Jakość wysoka.
3.	'driverId'	Numeric (Real)	Min: 1, Max: 862	Klucz obcy. Brak braków. Jakość wysoka.
4.	'constructorId'	Numeric (Real)	Min: 1, Max: 215	Klucz obcy. Brak braków. Jakość wysoka.
5.	'number'	Numeric (Real)	Min: 0, Max: 208; Braki <0.1%	Nr startowy. Bardzo małe braki. Jakość dobra.
6.	'grid'	Numeric (Real)	Min: 0, Max: 34; 6.1% to zera	Pozycja startowa. Brak braków. Jakość wysoka. Kluczowa miara. Dziwnie dużo 0.
7.	'position'	Numeric (Real)	Min: 1, Max: 33; Braki 40.9%	Pozycja końcowa. Dużo braków (DNF). 'positionOrder' lepsze.
9.	'positionOrder'	Numeric (Real)	Min: 1, Max: 39	Uporządkowana pozycja. Brak braków. Jakość wysoka. Lepsza do rankingu.
10.	'points'	Numeric (Real)	Min: 0, Max: 50; 69.5% to zera	Punkty. Brak braków. Jakość wysoka. Kluczowa miara.
11.	'laps'	Numeric (Real)	Min: 0, Max: 200; 9.5% Zeros	Ukończone okrążenia. Brak braków. Jakość wysoka. Miara.
12.	'time'	Text	np. "1:30:00", "+5s"; Braki 71.3%	Czas. Dużo braków. Wymaga parsowania. 'milliseconds' lepsze. Niska jakość.
13.	'milliseconds'	Numeric (Real)	Min: 526, Max: 15M; Braki 71.3%	Czas (ms). Dużo braków. Jakość wysoka (dla niepustych). Kluczowa miara.
14.	'fastestLap'	Numeric (Real)	Min: 1, Max: 85; Braki 69.2%	Nr najszybszego okrążenia. Dużo braków. Jakość średnia.
15.	'rank'	Numeric (Real)	Min: 0, Max: 24; Braki 68.2%	Ranking najszybszego okrążenia. Dużo braków. Jakość średnia.
16.	'fastestLapTime'	DateTime	MM:SS.mmm; Braki 69.2%	Czas najszybszego okrążenia. Błędnie jako DateTime. Wymaga parsowania. Dużo braków. Niska jakość.
17.	'fastestLapSpeed'	Numeric (Real)	Min: 89, Max: 257; Braki 69.2%	Prędkość najszybszego okrążenia. Dużo braków. Jakość średnia.
18.	'statusId'	Numeric (Real)	Min: 1, Max: 141	Klucz obcy do 'status.csv'. Brak braków. Jakość wysoka. Kluczowy.

5.8 Plik: status.csv

Tabela 10: Profilowanie danych dla `status.csv`

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'statusId'	Numeric (Real)	Min: 1, Max: 141	Klucz główny. Unikalny, brak braków. Jakość wysoka.
2.	'status'	Text	Unikalne wartości	Opis statusu. Unikalny, brak braków. Jakość wysoka. Kluczowy.

5.9 Plik: `weather.csv`

Tabela 11: Profilowanie danych dla `weather.csv`

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych i przydatności
1.	'Time'	Text	'timedelta'	Czas odniesienia. Brak braków. Wymaga parsowania - trzeba usunąć "0 days" z przodu. Jakość wysoka. Kluczowy.
2.	'AirTemp'	Numeric (Real)	Min: 8.9, Max: 37.2	Temperatura powietrza. Brak braków. Jakość wysoka. Kluczowa miara.
3.	'Humidity'	Numeric (Real)	Min: 5, Max: 97.5	Wilgotność. Brak braków. Jakość wysoka. Kluczowa miara.
4.	'Pressure'	Numeric (Real)	Min: 778.5, Max: 1023.5	Ciśnienie. Brak braków. Jakość wysoka. Miara.
5.	'Rainfall'	Boolean	True/False	Opady. Brak braków. Jakość wysoka. Kluczowa miara.
6.	'TrackTemp'	Numeric (Real)	Min: 13.8, Max: 67	Temp. toru. Brak braków. Jakość wysoka. Kluczowa miara.
7.	'WindDirection'	Numeric (Real)	Min: 0, Max: 359	Kier. wiatru. Brak braków. Jakość wysoka. Miara.
8.	'WindSpeed'	Numeric (Real)	Min: 0, Max: 10.1	Prędkość wiatru. Brak braków. Jakość wysoka. Kluczowa miara.
9.	'Round Number'	Numeric (Real)	Min: 1, Max: 22	Nr rundy. Brak braków. Jakość wysoka. Kluczowy do łączenia.
10.	'Year'	Numeric (Real)	Min: 2018, Max: 2023	Rok. Brak braków. Jakość wysoka. Kluczowy do łączenia.
Dodatkowa uwaga:				Raport wskazuje 3.2% zduplikowanych wierszy. Należy zbadać i usunąć przed agregacją.

6 Definicja typów encji/klas, związków, diagram klas

Projektowana hurtownia danych będzie oparta na schemacie gwiazdy, z centralną tabelą faktów `Fact_Result` oraz otaczającymi ją tabelami wymiarów.

6.1 Tabela faktów: Fact_Result

- **Opis:** Reprezentuje pojedynczy, całościowy wynik kierowcy w danym wyścigu Grand Prix. Ziarnistość tabeli to jeden rekord per kierowca per wyścig.
- **Klucze obce (referencje do wymiarów):**
 - RaceKey (FK do Dim_Race)
 - DriverKey (FK do Dim_Driver)
 - ConstructorKey (FK do Dim_Constructor)
 - CircuitKey (FK do Dim_Circuit)
 - DateKey (FK do Dim_Time - data wyścigu)
 - WeatherKey (FK do Dim_Weather, może być NULL dla wyścigów sprzed 2018)
 - StatusKey (FK do Dim_Status)
- **Miary (przykładowe):**
 - PointsScored (DECIMAL) - zdobyte punkty (addytywna)
 - LapsCompleted (INT) - liczba ukończonych okrążeń (addytywna)
 - NumberOfPitStops (INT, wyliczana z pit_stops.csv) - liczba pit-stopów (addytywna)
 - PitStopsTotalTimeMS (BIGINT, wyliczana z pit_stops.csv) - łączny czas pit-stopów w milisekundach (addytywna)
 - RaceTimeMS (BIGINT, nullable) - czas ukończenia wyścigu w milisekundach (póładdytywna)
 - GridPosition (INT) - pozycja startowa (nieaddytywna)
 - FinalPositionOrder (INT) - numeryczna pozycja na mecie (nieaddytywna)
 - PositionOrderChange (INT) - różnica między pozycją startową a finalną (nieaddytywna)
 - FastestLapTimeMS (BIGINT, nullable) - czas najszybszego okrążenia kierowcy w wyścigu (nieaddytywna)
 - RankFastestLap (INT, nullable) - ranking najszybszego okrążenia kierowcy w wyścigu (nieaddytywna)
 - FastestLapTopSpeedMS (BIGINT, nullable) - maksymalna szybkość podczas najszybszego okrążenia (nieaddytywna)
 - AgeAtRace (INT) - wiek kierowcy w momencie wyścigu (nieaddytywna)

6.2 Wymiary

1. Dim_Driver

- Klucze: DriverKey (PK, klucz zastępczy), DriverID_NK (klucz naturalny z `drivers.csv`), DriverRef
- Atrybuty: FirstName, LastName, FullName, DateOfBirth, Nationality, Continent
- Hierarchie: Continent → Nationality → DriverKey.

2. Dim_Constructor

- Klucze: ConstructorKey (PK), ConstructorID_NK, ConstructorRef
- Atrybuty: Name, Nationality, Continent
- Hierarchie: Continent → Nationality → ConstructorKey.

3. Dim_Race

- Klucze: RaceKey (PK), RaceID_NK
- Atrybuty: YearSeason, RoundNumberInSeason, RaceNameOfficial
- Hierarchie: YearSeason → RoundNumberInSeason → RaceKey.

4. Dim_Circuit

- Klucze: CircuitKey (PK), CircuitID_NK, CircuitRef
- Atrybuty: CircuitName, LocationCity, CountryName, Latitude, Longitude, Altitude
- Hierarchie: CountryName → LocationCity → CircuitName.

5. Dim_Time

- Klucze: DateKey (PK: YYYYMMDD)
- Atrybuty: FullDate (DATE), Year, Quarter, Month, MonthName, DayOfMonth, DayOfWeekName
- Hierarchie: Year → Quarter → Month → DayOfMonth

6. Dim_Weather


- Klucze: WeatherKey (PK)
- Atrybuty: AvgAirTempCelsius, MinAirTempCelsius, MaxAirTempCelsius, AvgTrackTempCelsius, AvgHumidityPercent, DidRainOccur (Boolean), AvgWindSpeedKmph, MaxWindSpeedKmph, AvgWindDirection

7. Dim_Status (opisuje sposób zakończenia wyścigu przez kierowcę)

- Klucze: StatusKey (PK)
- Atrybuty: StatusDescription (np. "Finished", "+1 Lap", "Engine", "Collision"), StatusCategory (np. "Finished", "Malfunction", "Accident")
- Hierarchie: StatusCategory → StatusDescription.

6.3 Diagram klas (schemat gwiazdy)

Centralna tabela faktów Fact_Result będzie połączona z wymienionymi powyżej tabelami wymiarów.



Rysunek 1: Proponowany schemat gwiazdy dla hurtowni danych F1.

7 Min. 10 wielowymiarowych zestawień

Poniżej przedstawiono przykładowe wielowymiarowe zestawienia, które będzie można utworzyć po wdrożeniu kostki OLAP:

1. **Wpływ pozycji startowej na wynik:** Średnia pozycja na mecie i procent zwycięstw dla każdej pozycji startowej (grid), z możliwością filtrowania wg toru i sezonu.

2. **Stabilność kierowców:** Średnie punkty na wyścig, liczba miejsc na podium i zwycięstw na sezon dla wybranych (najbardziej znanych) kierowców na przestrzeni ich kariery.
3. **"Gwiazdy w słabych zespołach":** Identyfikacja kierowców, którzy regularnie zdobywali punkty lub wysokie pozycje dla zespołów z końca stawki (np. porównanie wyników kierowcy ze średnią zespołu).
4. **Ewolucja strategii pit-stopów:** Średnia liczba pit-stopów i ich łącznego czasu na wyścig i ich wpływ na wynik, analizowana wg toru, sezonu i warunków pogodowych.
5. **Dominacja zespołów:** Procent wygranych wyścigów i zdobytych punktów przez poszczególne zespoły w sezonach.
6. **Trendy narodowościowe:** Liczba kierowców, zwycięzców i mistrzów świata z podziałem na narodowości i kontynenty, na przestrzeni dekad.
7. **Pogoda a niezawodność:** Korelacja między zagregowanymi warunkami pogodowymi (np. wysokie/niskie temperatury, opady deszczu) a liczbą nieukończonych wyścigów (DNF) z powodu awarii lub wypadków.
8. **Pogoda a nieoczekiwane wyniki:** Analiza, czy deszczowe lub zmienne warunki pogodowe częściej przynoszą nieoczekiwane wyniki (np. zwycięzcy spoza czołowych zespołów, kierowcy z dalszych pozycji na podium).
9. **Pojedynki zespołowe:** Porównanie wyników (punkty, pozycje w kwalifikacjach i wyścigach) kierowców startujących w tym samym zespole w danym sezonie.
10. **Charakterystyka torów a wyniki:** Jak zmieniały się czasy ukończenia torów z biegiem lat? Które torry generują najwięcej/najmniej zmian pozycji?
11. **Analiza DNF:** Najczęstsze przyczyny nieukończenia wyścigu (na podstawie Dim_Status) dla poszczególnych zespołów i na przestrzeni sezonów, z uwzględnieniem wpływu pogody.
12. **Wpływ wieku kierowcy na osiągnięcia:** Korelacja między wiekiem kierowcy a jego wynikami (np. średnia liczba punktów na sezon, częstotliwość błędów, szybkość na pojedynczym okrążeniu).

8 Implementacja bazy danych (konceptualny model danych - DDL)

Poniżej przedstawiono skrypt SQL tworzący strukturę tabel wymiarów i faktów zgodnie z zaproponowanym modelem. Klucze obce, więzy integralności i nawet indeksy są zdefiniowane.

```
1 CREATE TABLE Dim_Driver (
2     DriverKey INT PRIMARY KEY,
3     DriverID_NK INT UNIQUE,
4     DriverRef VARCHAR(255) UNIQUE,
5     FirstName VARCHAR(255),
6     LastName VARCHAR(255),
7     FullName VARCHAR(510),
8     DateOfBirth DATE,
9     Nationality VARCHAR(255),
10    Continent VARCHAR(255)
11 );
12
13 CREATE TABLE Dim_Constructor (
14     ConstructorKey INT PRIMARY KEY,
15     ConstructorID_NK INT UNIQUE,
16     ConstructorRef VARCHAR(255) UNIQUE,
17     Name VARCHAR(255),
18     Nationality VARCHAR(255),
19     Continent VARCHAR(255)
20 );
21
22 CREATE TABLE Dim_Race (
23     RaceKey INT PRIMARY KEY,
24     RaceID_NK INT UNIQUE,
25     YearSeason INT,
26     RoundNumberInSeason INT,
27     RaceNameOfficial VARCHAR(255)
28 );
29
30 CREATE TABLE Dim_Circuit (
31     CircuitKey INT PRIMARY KEY,
32     CircuitID_NK INT UNIQUE,
33     CircuitRef VARCHAR(255) UNIQUE,
34     CircuitName VARCHAR(255),
35     LocationCity VARCHAR(255),
36     CountryName VARCHAR(255),
```

```

37     Latitude DECIMAL(9,6),
38     Longitude DECIMAL(9,6),
39     Altitude INT
40 );
41
42 CREATE TABLE Dim_Time (
43     DateKey INT PRIMARY KEY,
44     FullDate DATE UNIQUE,
45     Year INT,
46     Quarter INT,
47     Month INT,
48     MonthName VARCHAR(50),
49     DayOfMonth INT,
50     DayOfWeekName VARCHAR(50),
51     WeekOfYear INT
52 );
53
54 CREATE TABLE Dim_Weather (
55     WeatherKey INT PRIMARY KEY,
56     AvgAirTempCelsius DECIMAL(5,2),
57     MinAirTempCelsius DECIMAL(5,2),
58     MaxAirTempCelsius DECIMAL(5,2),
59     AvgTrackTempCelsius DECIMAL(5,2),
60     AvgHumidityPercent DECIMAL(5,2),
61     DidRainOccur BIT, -- 0 lub 1
62     TotalRainfallMM DECIMAL(6,2),
63     AvgWindSpeedKmph DECIMAL(5,2),
64     MaxWindSpeedKmph DECIMAL(5,2),
65     DominantWindDirection VARCHAR(50), -- Np. N, NW, S (kategoria)
66 );
67
68 CREATE TABLE Dim_Status (
69     StatusKey INT PRIMARY KEY,
70     StatusID_NK INT UNIQUE,
71     StatusDescription VARCHAR(255),
72     StatusCategory VARCHAR(100) -- Np. Finished, Accident,
73     Failure
74 );
75
76 CREATE TABLE Fact_Result (
77     RaceKey INT,
78     DriverKey INT,
79     ConstructorKey INT,

```

```

79     CircuitKey INT,
80     DateKey INT,
81     WeatherKey INT NULL,
82     StatusKey INT,
83
84     -- Miary
85     PointsScored DECIMAL(5,1),
86     LapsCompleted INT,
87     NumberOfPitStops INT NULL,
88     PitStopsTotalTimeMS BIGINT NULL,
89     RaceTimeMS BIGINT NULL,
90     GridPosition INT,
91     FinalPositionOrder INT,
92     PositionOrderChange INT,          -- (GridPosition -
FinalPositionOrder)
93     FastestLapTimeMS BIGINT NULL,
94     RankFastestLap INT NULL,
95     FastestLapTopSpeed DECIMAL(6,2) NULL,
96     AgeAtRace DECIMAL(5,3) NULL,
97
98     FOREIGN KEY (RaceKey) REFERENCES Dim_Race(RaceKey),
99     FOREIGN KEY (DriverKey) REFERENCES Dim_Driver(DriverKey),
100    FOREIGN KEY (ConstructorKey) REFERENCES Dim_Constructor(
ConstructorKey),
101    FOREIGN KEY (CircuitKey) REFERENCES Dim_Circuit(CircuitKey),
102    FOREIGN KEY (DateKey) REFERENCES Dim_Time(DateKey),
103    FOREIGN KEY (WeatherKey) REFERENCES Dim_Weather_Aggregated(WeatherKey
),
104    FOREIGN KEY (StatusKey) REFERENCES Dim_Status(StatusKey)
105 );

```

Listing 1: Konceptualny DDL dla hurtowni danych F1

9 Wnioski

Proponowany projekt hurtowni danych dla wyników Formuły 1 w latach 1950-2023 ma na celu stworzenie kompleksowego narzędzia analitycznego. Wykorzystanie dwóch głównych źródeł danych - szczegółowych wyników historycznych oraz minutowych danych pogodowych (agregowanych do poziomu wyścigu) dla ostatnich sezonów - pozwoli na przeprowadzenie wielowymiarowych analiz, które mogą odkryć interesujące wzorce, trendy i zależności.

9.1 Główne korzyści

- Umożliwienie odpowiedzi na szeroki zakres pytań analitycznych dotyczących strategii, osiągnięć kierowców i zespołów oraz wpływu czynników zewnętrznych, w tym pogody.
- Dostarczenie spójnego i zintegrowanego zbioru danych, ułatwiającego analizy porównawcze na przestrzeni lat i między różnymi aspektami wyścigów.
- Możliwość wizualizacji i eksploracji danych F1 w sposób bardziej zaawansowany niż standardowe tabele wyników, wspierając podejmowanie decyzji i głębsze zrozumienie sportu.

9.2 Potencjalne wyzwania

- **Agregacja i integracja danych pogodowych:** Precyzyjne zdefiniowanie logiki agregacji minutowych danych pogodowych oraz zapewnienie poprawnego określenia zakresu czasowego wyścigu dla tej agregacji.
- **Jakość danych źródłowych:** Obsługa brakujących wartości (NULL), niespójności formatów (np. czasów) oraz potencjalnych wartości odstających w obu zbiorach danych.
- **Zakres danych pogodowych:** Analizy wykorzystujące szczegółowe dane pogodowe będą ograniczone do sezonów 2018-2023. Można by za pomocą API pozyskać brakujące dane (poza temperaturą nawierzchni). Ciekawą alternatywą byłoby też użycie prostej estymacji temperatury nawierzchni z danych pogodowych - mało danych treningowych, ale wysoce prawdopodobne jest to, że temperatura nawierzchni jest bardzo powiązana z np. temperaturą z ostatnich x godzin z coraz mniejszymi wagami, plus uwzględnienie wilgotności / deszczu.
- **Interpretacja historyczna i zmiany regulaminowe:** Uwzględnienie znaczących zmian w regulaminach F1 (np. systemy punktacji, aerodynamika, specyfikacje opon) przy interpretacji wyników i trendów z różnych epok sportu.
- **Obsługa stref czasowych:** Zapewnienie spójności w przetwarzaniu danych czasowych, szczególnie przy łączeniu 'timedelta' z danych pogodowych z czasem startu wyścigu.

10 Architektura i narzędzia procesu ETL

10.1 Struktura procesu ETL

Proces ETL został zorganizowany w ramach jednego projektu SSIS, zawierającego dedykowane pakiety dla ładowania poszczególnych tabel wymiarów oraz tabeli faktów. Dodatkowo, zaimplementowano pakiet główny (master package) koordynujący uruchamianie poszczególnych pakietów w odpowiedniej kolejności (najpierw wymiary, następnie fakty), aby zapewnić integralność referencyjną.

Struktura pakietów SSIS:

- _Dim_Circuit.dtsx
- _Dim_Driver.dtsx
- _Dim_Constructor.dtsx
- _Dim_Race.dtsx
- _Dim_Status.dtsx
- _Dim_Weather.dtsx
- _Fact_Result.dtsx
- _Dim_Time.dtsx

10.2 Mapa logiczna ETL

10.2.1 Mapowanie atrybutów: Dim_Driver

Tabela 12: Mapowanie ETL dla tabeli Dim_Driver

Atrybut	Źródła	Kolumna źródła	Transformacje i uwagi
DriverKey	-	-	SQL Server IDENTITY(1,1). Klucz zastępczy.
DriverID_NK	drivers.xlsx	driverId	Bezpośrednio. Klucz naturalny ze źródła.
FirstName	drivers.xlsx	forename	Bezpośrednio.
LastName	drivers.xlsx	surname	Bezpośrednio.
FullName	drivers.xlsx	forename, surname	Derived Column: forename + " " + surname Pełne imię i nazwisko
DateOfBirth	drivers.xlsx	dob	Bezpośrednio.

Kontynuacja na następnej stronie

Tabela 12 – Kontynuacja z poprzedniej strony

Atrybut	Źródła	Kolumna źródła	Transformacje i uwagi
CountryName	drivers.xlsx, Helper_Nationality	nationality	Lookup do Helper_NationalityCountries.
Continent	Helper_Nationality Helper_Continent	CountryName poprzednio obliczone	Lookup do Helper_CountryContinents z poprzednio obliczonego CountryName

10.2.2 Mapowanie atrybutów: Dim_Constructor

Tabela 13: Mapowanie ETL dla tabeli Dim_Constructor

Atrybut	Źródła	Kolumna źródła	Transformacje i uwagi
ConstructorKey	-	-	SQL Server IDENTITY(1,1). Klucz zastępczy.
ConstructorID_NK	constructors.xlsx	constructorId	Bezpośrednio. Klucz naturalny.
Name	constructors.xlsx	name	Bezpośrednio.
CountryName	constructors.xlsx Helper_Nationality	nationality	Lookup nationality do Helper_NationalityCountries.
Continent	Helper_Continent poprzednio obliczone CountryName	CountryName wcześniej obliczone	Lookup CountryName do Helper_CountryContinent

10.2.3 Mapowanie atrybutów: Dim_Race

Tabela 14: Mapowanie ETL dla tabeli Dim_Race

Atrybut	Źródła	Kolumna źródła	Transformacje i uwagi
RaceKey	-	-	SQL Server IDENTITY(1,1). Klucz zastępczy.
RaceID_NK	races.xlsx	raceId	Bezpośrednio. Klucz naturalny.
CircuitID_NK	races.xlsx	circuitId	Bezpośrednio. NK obwodu dla tego wyścigu.
YearSeason	races.xlsx	year	Bezpośrednio.
RoundNumberInSeason	races.xlsx	round	Bezpośrednio.
RaceNameOfficial	races.xlsx	name	Bezpośrednio.
Date	races.xlsx	date	Bezpośrednio. Używana do DateKey w F1.

10.2.4 Mapowanie atrybutów: Dim_Circuit

Tabela 15: Mapowanie ETL dla tabeli Dim_Circuit

Atrybut	Źródła	Kolumna źródła	Transformacje i uwagi
CircuitKey	-	-	SQL Server IDENTITY(1,1). Klucz zastępczy.
CircuitID_NK	circuits.xlsx	circuitId	Bezpośrednio. Klucz naturalny.
CircuitName	circuits.xlsx	name	Bezpośrednio.
LocationCity	circuits.xlsx	location	Bezpośrednio.
CountryName	circuits.xlsx	country	Bezpośrednio.

10.2.5 Mapowanie atrybutów: Dim_Time

Tabela 16: Mapowanie ETL dla tabeli Dim_Time

Atrybut	Źródła	Kolumna	Transformacje i uwagi
DateKey	Fact_Result	Distinct DateKey	Distinct z DateKey w Fact_Result. PK, YYYYMMDD INT.
FullDate	Dim_Time	DateKey wcześniej obliczone	Derived column: rok, miesiąc i dzień za pomocą modulo i dzielenia z DateKey.
Year	Dim_Time	FullDate wcześniej obliczone	Derived Column: DatePart YEAR z FullDate.
Quarter	Dim_Time	FullDate wcześniej obliczone	Derived Column: DatePart QUARTER z FullDate.
Month	Dim_Time	FullDate wcześniej obliczone	Derived Column: DatePart MONTH z FullDate.
MonthName	Dim_Time Helper_Months	Month wcześniej obliczone	Lookup na Helper_Months. Angielska nazwa.
DayOfMonth	Dim_Time	FullDate wcześniej obliczone	Derived Column: DatePart DAY z FullDate.
DayOfWeekName	Dim_Time Helper_Weekdays	Bazuje na FullDate	Derived Column: DatePart WEEKDAY - tego Lookup na Helper_Weekdays. Angielska nazwa.

10.2.6 Mapowanie Atrybutów: Dim_Weather

Tabela 17: Mapowanie ETL dla tabeli Dim_Weather

Atrybut	Źródła	Źródła	Transformacje i uwagi
WeatherKey	weather.xlsx	RoundNumber, Year	Derived Column: Year * 100 + RoundNumber.
Kontynuacja na następnej stronie			

Tabela 17 – Kontynuacja z poprzedniej strony

Atrybut	Źródła	Źródła	Transformacje i uwagi
DidRainOccur	weather.xlsx	Rainfall	Najpierw Derived Column RainfallInt 1/0 -> Agregacja max z RainfallInt -> "Rain Occurred"/"No Rain".
WindSpeedCategory	weather.xlsx	WindSpeed	Agregacja AVG -> logika CASE dla kate rii: "Light Breeze", "Calm"...
AirTempCategory	weather.xlsx	AirTemp	Agregacja AVG -> logika CASE dla kate rii: "Cold", "Warm"...
TrackTempCategory	weather.xlsx	TrackTemp	Agregacja AVG -> logika CASE dla kate rii: "Optimal Track", "Very Hot Track"...
HumidityCategory	weather.xlsx	Humidity	Agregacja AVG -> logika CASE dla kate rii: "Dry", "Humid"...
PressureCategory	weather.xlsx	Pressure	Agregacja AVG -> logika CASE dla kate rii: "Very Low", "Normal"...

10.2.7 Mapowanie Atrybutów: Dim_Status

Tabela 18: Mapowanie ETL dla tabeli Dim_Status

Atrybut	Źródła	Kolumna źródła	Transformacje i uwagi
StatusKey	-	-	SQL Server IDENTITY(1,1). Klucz zastę czy.
StatusID_NK	status.xlsx	statusId	Bezpośrednio.
StatusDescription	status.xlsx	status	Bezpośrednio.
StatusCategory	status.xlsx Helper_Status	status	Fuzzy Lookup na status w Hel per_StatusCategory -> BroadCategory. Kategoria np. Race Outcome, Mechanical Failure.

10.2.8 Mapowanie atrybutów: Fact_Result

Tabela 19: Mapowanie ETL dla tabeli Fact_Result

Atrybut	Źródło CSV / Wy miar	Kolumna	Transformacje i uwagi
RaceKey	results.xlsx, Dim_Race	RaceKey	Lookup z Dim_Race (results.raceId) -> Ra ceKey (i CircuitKey i Date i YearSeason i RoundNumberInSeason)

Kontynuacja na następnej stronie


Tabela 19 – Kontynuacja z poprzedniej strony

Atrybut	Źródło CSV / Wymiar	Kolumna	Transformacje i uwagi
DriverKey	results.xlsx, Dim_Driver	DriverKey	Lookup z Dim_Driver (results.driverId) -> DriverKey (i DateOfBirth).
ConstructorKey	results.xlsx, Dim_Constructor	ConstructorKey	Lookup z Dim_Constructor (results.constructorId) -> ConstructorKey.
CircuitKey	Dim_Race	CircuitKey	Poprzednio wyliczone przy Lookup do RaceKey
DateKey	Dim_Race	Date	Poprzednio wyliczone przy Lookup do RaceKey -> DateKey = YEAR * 10000 + MONTH * 100 + DAY.
WeatherKey	Dim_Race	YearSeason i RoundNumberInSeason	Kolumny wcześniej wyciągnięte z Dim_Race -> WeatherKey = YearSeason * 100 + RoundNumberInSeason
StatusKey	results.xlsx, Dim_Status	results.statusId	Lookup z Dim_Status (res.statusId) -> StatusKey (SK).
PointsScored	results.xlsx	points	Bezpośrednio.
LapsCompleted	results.xlsx	laps	Bezpośrednio.
NumberOfPitStops	pit_stops.xlsx	raceId, driverId	Agregacja (COUNT(stop) jako StopsCount). Merge Join (Left Outer).
RaceTimeMilliseconds	results.xlsx	milliseconds	Bezpośrednio
GridPosition	results.xlsx	grid	Bezpośrednio.
FinalPositionOrder	results.xlsx	positionOrder	Bezpośrednio.
PositionOrderChange	results.xlsx	grid, positionOrder	Derived Column: grid - positionOrder.
RankFastestLap	results.xlsx	rank	Bezpośrednio.
FastestLapTopSpeed	results.xlsx	fastestLapSpeed	Bezpośrednio + Data Conversion do DT_Numeric.
AgeAtRace	Dim_Driver, Dim_Race	drivers.DateOfBirth, races.Date	Poprzednio wyliczone przy Lookup do Dim_Driver i Dim_Race -> YearSeason - YEAR(DateOfBirth)


10.3 Narzędzia

Głównym narzędziem wykorzystanym do implementacji procesów ETL był SQL Server Integration Services (SSIS) wchodzący w skład Microsoft SQL Server. Pakiety SSIS zostały utworzone przy użyciu SQL Server Data Tools (SSDT) for Visual Studio. Dodatkowo do czyszczenia początkowych danych i zmiany formatu plików z danymi wykorzystano Python.


11 Implementacja procesów ETL



Rysunek 2: Cały ETL.



Rysunek 3: ETL dla Fact_Result.



Rysunek 4: ETL dla Dim_Time.

SQLQuery1.sql - DE...GLE46P\Jantar (59))*

```
SELECT COUNT(*) FROM Dim_Circuit
SELECT COUNT(*) FROM Dim_Constructor
SELECT COUNT(*) FROM Dim_Driver
SELECT COUNT(*) FROM Dim_Race
SELECT COUNT(*) FROM Dim_Status
SELECT COUNT(*) FROM Dim_Weather
SELECT COUNT(*) FROM Dim_Time
SELECT COUNT(*) FROM Fact_Result
```

100 %

Results Messages

	(No column name)	
1	77	
	(No column name)	
1	212	
	(No column name)	
1	861	
	(No column name)	
1	1125	29
	(No column name)	
1	139	

11.1 Ekstrakcja danych (Extract)

Dane źródłowe w formacie XLSX były wczytywane przy użyciu komponentu Excel Source w SSIS. Kluczowe aspekty konfiguracji tego etapu to:

- Poprzednia konwersja plików .csv to .xlsx za pomocą skryptu Python, aby pominąć błędy w kodowaniu.
- Użycie skryptu Python do usunięcia "/" w zbiorze danych.
- Poprawna identyfikacja separatorów kolumn, kwalifikatorów tekstu oraz obsługa wierszy nagłówkowych.
- Wstępne mapowanie typów danych na poziomie źródła, z uwzględnieniem późniejszych konwersji.

11.2 Transformacja danych (Transform)

Etap transformacji obejmował szereg operacji mających na celu oczyszczenie, integrację i przygotowanie danych do załadowania do tabel docelowych. Przykładowo:

1. **Konwersja Typów Danych:** Komponent Data Conversion był wykorzystany do konwersji danych.
2. **Obliczenia Pochodne:** Komponent Derived Column służył do tworzenia nowych kolumn na podstawie istniejących, np.:
 - Obliczenie wieku kierowcy w momencie wyścigu (AgeAtRace).
 - Obliczenie zmiany pozycji (PositionOrderChange).
3. **Agregacja Danych:**
 - **Dane pogodowe (Dim_Weather):** Minutowe dane pogodowe z pliku weather.xlsx były agregowane do poziomu pojedynczego wyścigu (po Year i RoundNumber) przy użyciu komponentu Aggregate. Obliczano wartości średnie, minimalne, maksymalne oraz sumy (np. dla opadów).
 - **Dane o pit-stopach:** Informacje o liczbie i łącznym czasie pit-stopów dla każdego kierowcy w wyścigu były agregowane z pliku pit_stops.xlsx i dołączane podczas ładowania tabeli faktów (np. poprzez wcześniejszą agregację do tabeli stagingowej i lookup).
4. **Kategoryzacja Danych Pogodowych:** Po agregacji, zagregowane wartości liczbowe dla danych pogodowych (np. temperatura, wilgotność, prędkość wiatru) były przekształcane na predefiniowane kategorie tekstowe (np.

"Zimno", "Umiarkowanie", "Gorąco") przy użyciu wyrażeń warunkowych w komponencie Derived Column, zgodnie z założeniami projektu. Te kategorie zostały następnie załadowane do Dim_Weather. Transformacja odbyła się w skrypcie C#.

5. **Fuzzy Lookup:** Do statusów dołączono ogólną kategorię statusu np. 'Mechanical Failure', 'Race Outcome' itd.


11.3 Ładowanie danych (Load)

Przetransformowane dane były ładowane do docelowych tabel w hurtowni SQL Server przy użyciu komponentu OLE DB Destination.

- Wykorzystano tryb szybkiego ładowania (Table or view - fast load).
- Zapewniono poprawne mapowanie kolumn z przepływu danych SSIS do kolumn tabel docelowych.
- Kolejność ładowania (najpierw wymiary, potem fakty) była zarządzana przez pakiet główny.

11.4 Event handler

W przypadku błędu, wszystkie dane są usuwane. Wcześniej podczas developmentu dodatkowo tabele były populowane, ponieważ wtedy występował błąd w metadanych SSIS.



Rysunek 6: Error handler.

11.5 Wyzwania i rozwiązania

Podczas implementacji napotkano typowe wyzwania związane z procesami ETL:

- **Niezgodność Stron Kodowych:** Początkowe problemy z konfliktem stron kodowych (np. 65001 z Flat File Source vs 1250 domyślne dla OLE DB Destination) zostały rozwiązane poprzez zmianę typu plików na Excel.

- **Synchronizacja Metadanych:** Zmiany w strukturze przepływu danych (np. po dodaniu Data Conversion) wymagały odświeżenia metadanych w komponencie OLE DB Destination i ponownego zmapowania kolumn.
- **Błędy Konwersji Danych w Źródle:** Błędy typu "Text was truncated or one or more characters had no match in the target code page" pojawiające się w Excel Source wskazywały na niepoprawną konfigurację strony kodowej dla pliku źródłowego. Trzeba było zmienić ręcznie w advanced editor dla źródła typy kolumn.

12 Podsumowanie i wnioski z etapu ETL

Proces ETL został pomyślnie zaimplementowany, umożliwiając zasilenie hurtowni danych Formuły 1 przetworzonymi i zintegrowanymi danymi. Kluczowe było właściwe zarządzanie typami danych i stronami kodowymi oraz logiczne rozplanowanie transformacji, w tym agregacji i kategoryzacji danych pogodowych. Zastosowanie SSIS pozwoliło na zbudowanie modularnego i zarządzalnego przepływu danych. Rozwiązane problemy z konwersją danych podkreślają znaczenie dokładnej analizy danych źródłowych i właściwej konfiguracji narzędzi ETL.

Kolejnym etapem będzie budowa kostki OLAP na bazie przygotowanej hurtowni danych oraz przeprowadzenie analiz wielowymiarowych.

13 Projekt kostki OLAP

13.1 Struktura kostki

Kostka OLAP, nazwana *FormulaCube*, została zbudowana w oparciu o tabelę faktów *Fact_Result* oraz powiązane z nią tabele wymiarów, które zostały zdefiniowane i zasilone w poprzednich etapach projektu. Model kostki został zaprojektowany tak, aby umożliwić analitykom intuicyjne i efektywne korzystanie z danych. Wykorzystano schemat gwiazdy, gdzie centralna tabela faktów jest połączona z wymiarami.

13.2 Wymiary kostki

Kostka wykorzystuje następujące wymiary, które pozwalają na analizę danych z różnych perspektyw:

- **Dim_Driver:** Informacje o kierowcach.
- **Dim_Constructor:** Informacje o zespołach konstruktorskich.

- **Dim_Race:** Szczegóły dotyczące poszczególnych wyścigów.
- **Dim_Circuit:** Informacje o torach wyścigowych.
- **Dim_Time:** Hierarchia czasowa oparta na dacie wyścigu.
- **Dim_Weather:** Skategoryzowane warunki pogodowe podczas wyścigu.
- **Dim_Status:** Informacje o statusie ukończenia wyścigu przez kierowcę.

Występuje dodatkowo zdegenerowany wymiar z atrybutami dotyczącymi wieku kierowcy, pozycji startowej i końcowej.

13.3 Hierarchie w wymiarach

W celu ułatwienia analizy typu drill-down/roll-up, zdefiniowano następujące hierarchie w wymiarach:

- **Dim_Time (Hierarchia Czasowa):**
 - Rok → Kwartał → Miesiąc → Dzień
- **Dim_Driver (Hierarchia Kierowcy):**
 - Kontynent → Kraj
- **Dim_Constructor (Hierarchia Konstruktora):**
 - Kontynent → Kraj
- **Dim_Circuit (Hierarchia Toru):**
 - Kontynent → Kraj → Miasto → Nazwa Toru
- **Dim_Status (Hierarchia Statusu):**
 - Kategoria Statusu → Opis Statusu

13.4 KPI

W ramach kostki zdefiniowano **Constructor Reliability (Niezawodność Konstruktora):**

- Wartość: 1 - DNF Percentage
- Cel: 80%

- Status: Ocena, czy konstruktor osiąga zakładany poziom niezawodności


Year	(Multiple Items)			
Row Labels	Constructor Reliability KPI	Constructor Reliability KPI Goal	Constructor Reliability KPI Status	Constructor Reliability KPI Trend
2000	58,98%	0,8	🔴	⬆️
2001	58,02%	0,8	🔴	⬇️
2002	55,52%	0,8	🔴	⬇️
2003	65,31%	0,8	🔴	⬆️
2004	71,94%	0,8	🔴	⬆️
2005	73,94%	0,8	🟡	⬆️
2006	67,93%	0,8	🔴	⬇️
2007	73,26%	0,8	🟡	⬆️
2008	76,36%	0,8	🟡	⬆️
2009	80,29%	0,8	🟢	⬆️
2010	74,78%	0,8	🟡	⬇️
2011	83,11%	0,8	🟢	⬆️
2012	82,29%	0,8	🟢	⬇️
2013	85,41%	0,8	🟢	⬆️
2014	80,84%	0,8	🟢	⬇️
2015	81,75%	0,8	🟢	⬆️
2016	83,98%	0,8	🟢	⬆️
2017				
1	65,00%	0,8	🔴	⬇️
2	72,14%	0,8	🟡	⬇️
3	77,50%	0,8	🟡	⬇️
4	81,67%	0,8	🟢	⬇️
2018	80,24%	0,8	🟢	⬆️
2019	86,19%	0,8	🟢	⬆️
2020	83,53%	0,8	🟢	⬇️
2021	87,27%	0,8	🟢	⬆️
2022	83,18%	0,8	🟢	⬇️
2023	85,68%	0,8	🟢	⬆️
2024	90,61%	0,8	🟢	⬆️
Grand Total	77,67%	0,8	🟡	➡️

Rysunek 7: Widok KPI w latach 2000-2024.


Jak widać, kiedyś ta niezawodność nie była spełniona, natomiast przez ostatnie dwie dekady jest prawie zawsze spełniany.

14 Implementacja kostki OLAP

Kostka OLAP została zaimplementowana przy użyciu SQL Server Analysis Services (SSAS) 2019. Poniżej przedstawiono przykładowy widok struktury kostki oraz relacji wymiarów w SSAS.



Rysunek 8: Widok struktury kostki.




Rysunek 9: Widok zakładki "Dimension Usage" w SQL Server Analysis Services.

15 Zestawienia wielowymiarowe i analizy


Poniżej zaprezentowano zestawienia i wizualizacje wygenerowane na podstawie danych z kostki OLAP. Ilustrują one możliwości analityczne stworzonego rozwiązania.

15.1 10 najczęstszych przyczyn awarii mechanicznych europejskich konstruktorów w latach 1950-1960



Wnioski: Problemy związane z silnikiem były zdecydowanie główną przyczyną awarii mechanicznych europejskich konstruktorów w latach 1950-1960. Problemy z układem przeniesienia napędu, skrzynią biegów oraz sprzęgłem były kolejnymi istotnymi, choć rzadszymi, przyczynami awarii.


15.2 10 najczęstszych przyczyn awarii mechanicznych europejskich konstruktorów w latach 2010-2020



Wnioski: Problemy związane z silnikiem pozostały najczęstszą przyczyną awarii mechanicznych europejskich konstruktorów w latach 2010-2020. Awarie skrzyni


biegów były drugą najczęstszą przyczyną. W porównaniu do okresu 1950-1960, "Power Unit" i "Hydraulics" pojawiły się jako istotne, odrębne kategorie awarii, odzwierciedlając postęp technologiczny i zmiany w konstrukcji samochodów. Problemy z hamulcami, zawieszeniem i układem elektrycznym również stanowiły znaczną część awarii mechanicznych.

15.3 Średnia bezwzględna zmiana kolejności pozycji na torach w Austrii, Belgii, Francji i Niemczech




Wnioski: Wyścigi odbywające się na torze Dijon we Francji charakteryzowały się najwyższą średnią zmianą kolejności pozycji, co wskazuje na bardziej nieprzewidywalne wyścigi ze znacznymi przetasowaniami w stawce. Tor Heusden-Zolder w Belgii również odnotował znacząco wysoką średnią zmianę pozycji. Z kolei tory takie jak Spielberg, Clermont-Ferrand, Magny Cours, Reims, Rouen i Nürburgring wykazywały średnio porównywalnie mniejsze zmiany w kolejności wyścigu, a najmniej zmian występuje na torze w Brukseli.

15.4 Średnia pozycja na mecie w zależności od pozycji startowej w Grand Prix Wielkiej Brytanii w latach 1990-2009




Wnioski: Ogólnie, wyższa pozycja startowa w Grand Prix Wielkiej Brytanii w latach 1990-2009 korelowała z wyższą średnią pozycją na mecie. Zależność ta nie była jednak idealnie liniowa, gdyż niektóre pozycje startowe (np. około 5.) osiągały lepsze wyniki niż pozycje bezpośrednio je poprzedzające, a niektóre dalsze pozycje startowe (np. około 19. i 24.) wykazywały szczególnie gorsze średnie wyniki na mecie.

15.5 Procent DNF i średnia pozycja na mecie według grup wiekowych




Wnioski: Młodszy kierowcy, szczególnie ci poniżej 20. roku życia, mieli tendencję do niższego odsetka DNF (nieukończeń wyścigu) i osiągania lepszych średnich pozycji na mecie. Kierowcy od 26. roku życia do powyżej 35. roku życia doświadczali najwyższych wskaźników DNF i najmniej korzystnych średnich pozycji na mecie. Ogólnie jest tendencja, że wraz ze wzrostem wieku kierowcy, wskaźniki DNF rosną, a średnie pozycje na mecie pogarszają się - jest ona najbardziej prawdziwa dla 3. grup wiekowych: under 20, 20-25 i 26-30.

15.6 Procent zwycięstw i średnia prędkość najszybszego okrążenia według grup wiekowych




Wnioski: Kierowcy w grupie wiekowej 31-35 lat osiągnęli najwyższy procent zwycięstw ze swoich pozycji startowych, a także notowali najwyższe średnie prędkości najszybszych okrążeń. Procenty zwycięstw były znacznie niższe dla młodszych grup wiekowych (poniżej 20 lat i 20-25 lat). Chociaż kierowcy powyżej 35. roku życia mieli drugą najwyższą średnią prędkość, ich procent zwycięstw był niższy niż w grupie wiekowej 26-30 lat. Jest to ciekawa różnica w porównaniu do poprzedniej analizy, gdzie najmłodsi kierowcy osiągnęli lepsze wyniki. Należy pamiętać, że było bardzo niewiele kierowców under 20, przez co mogło nastąpić przeszacowanie umiejętności.

15.7 Procent ukończeń wyścigu według kategorii pogodowych




Wnioski: We wszystkich wymienionych kategoriach pogodowych (kombinacje temperatury toru, deszczu i warunków wietrznych) zdecydowana większość startujących pomyślnie ukończyła wyścigi. Występują jednak różnice - największy procent DNF wystąpił dla najgorszych warunków pogodowych, czyli gorąca powierzchnia i deszcz. Generalnie sam deszcz lekko wpływa na zwiększenie procentu DNF. Nie wygląda na to, że gdy nie pada, temperatura track ma wielki wpływ na DNF - chociaż najmniej DNF odbyło się przy najlepszych możliwych warunkach pogodowych - brak wiatru, zimna nawierzchnia i brak deszczu.

15.8 Top 5 konstruktorów według średniej liczby punktów



Wnioski: Mercedes był najlepszym konstruktorem pod względem średniej liczby punktów, wyprzedzając Red Bulla, a następnie Ferrari. McLaren i Lotus F1 zajęły odpowiednio czwarte i piąte miejsce, ale ze znaczącą niższą średnią liczbą punktów w porównaniu do pierwszej trójki.


15.9 Procent zwycięstw na przestrzeni lat 2018-2024 dla 9 najlepszych kierowców w Europie



Wnioski: Procent zwycięstw Maxa Verstappena wykazywał znaczący trend wzrostowy od 2018 do 2023 roku, kulminując dominującym występem w 2023 roku. Lewis Hamilton wykazywał wysokie odsetki zwycięstw we wcześniejszych latach (2018-2020), ale w kolejnych latach odnotował spadek. Inni kierowcy mieli sporadyczne lub niższe odsetki zwycięstw, przy czym Verstappen wyraźnie wyrósł na


najbardziej utytułowanego zawodnika tej grupy w późniejszej części okresu. Dane za 2024 rok pokazują bardziej wyrównane wyniki dla kierowców, poza Maxem, który co prawda był słabszy niż w 2023, ale dalej najlepszy.

15.10 Średnia liczba pit stopów w zależności od występowania deszczu w latach 2018-2023




Wnioski: Występowanie deszczu konsekwentnie prowadziło do wyższej średniej liczby pit stopów w wyścigach w latach 2018-2023. W każdym obserwowanym roku wyścigi, na które wpłynął deszcz, charakteryzowały się średnio większą liczbą pit stopów w porównaniu do wyścigów bez niego. Co więcej, odnotowano niewielki trend wzrostowy średniej liczby pit stopów w warunkach deszczowych od 2018 do 2023 roku, osiągając szczyt w 2023 roku. Właśnie w 2023 liczba pit stopów była zdecydowanie najwyższa, gdy padał deszcz.

15.11 Średni czas wyścigu na torze Autodromo Nazionale di Monza według roku



Wnioski: Nastąpił radykalny spadek średnich czasów wyścigów na torze Autodromo Nazionale di Monza od 1950 roku do późnych lat 70. Po tym okresie gwałtownej poprawy prędkości lub wydajności wyścigów, średni czas wyścigu w dużej mierze ustabilizował się, wykazując jedynie niewielkie wahania do 2023 roku, z zauważalnym wzrostem w 2020 roku. Występowały też niewielkie wzrosty w 2008 i w 2000 roku. Z danych wcześniej analizowanych wynikałoby, że w 2023 roku deszcze wpłynęły mocno na pit stopy.

15.12 Podium z pierwszej dziesiątki lub spoza pierwszej dziesiątki pół startowych według kategorii deszczu i wiatru



Wnioski: Start z pierwszej dziesiątki pół startowych znacząco zwiększał prawdopodobieństwo ukończenia wyścigu na podium w większości warunków, szczególnie przy pogodzie bez silniejszego wiatru. Jednakże wystąpienie deszczu, szczególnie bez wiatru, zauważalnie zwiększało odsetek zawodników kończących na podium, którzy startowali spoza pierwszej dziesiątki pół startowych. Sugeruje to, że warunki deszczowe, zwłaszcza przy braku wiatru, tworzą bardziej nieprzewidywalne wyścigi, w których pozycja startowa jest mniej decydującym czynnikiem osiągnięcia podium. Największy procent podium spoza pierwszej dziesiątki występował jednak wtedy, kiedy wiatr był dość silny.

16 Dokumentacja kostki

16.1 Opis wymiarów i atrybutów

16.1.1 Dim_Driver (Kierowca)

- **Atrybuty:**
 - DriverKey (PK, Klucz Zastępczy)
 - DriverID_NK (Klucz Naturalny ze źródła)
 - FirstName (Imię)
 - LastName (Nazwisko)
 - FullName (Pełne Imię i Nazwisko) - używane w hierarchii
 - DateOfBirth (Data Urodzenia)
 - CountryName (Kraj pochodzenia) - używane w hierarchii
 - Continent (Kontynent pochodzenia) - używane w hierarchii
- **Hierarchie:** Kontynent → Kraj

16.1.2 Dim_Constructor (Konstruktor)

- **Atrybuty:**
 - ConstructorKey (PK, Klucz Zastępczy)
 - ConstructorID_NK (Klucz Naturalny ze źródła)
 - Name (Nazwa Konstruktora) - używane w hierarchii
 - CountryName (Kraj pochodzenia) - używane w hierarchii
 - Continent (Kontynent pochodzenia) - używane w hierarchii
- **Hierarchie:** Kontynent → Kraj

16.1.3 Dim_Race (Wyścig)

- **Atrybuty:**
 - RaceKey (PK, Klucz Zastępczy)
 - RaceID_NK (Klucz Naturalny ze źródła)
 - CircuitID_NK (Klucz Naturalny toru dla tego wyścigu)
 - YearSeason (Rok Sezonu)

- RoundNumberInSeason (Numer Rundy w Sezonie)
- RaceNameOfficial (Oficjalna Nazwa Wyścigu)
- Date (Data Wyścigu) - używana do połączenia z Dim_Time
- **Hierarchie:** Brak zdefiniowanych (możliwe: Rok Sezonu → Nazwa Wyścigu)

16.1.4 Dim_Circuit (Tor)

- **Atrybuty:**
 - CircuitKey (PK, Klucz Zastępczy)
 - CircuitID_NK (Klucz Naturalny ze źródła)
 - CircuitName (Nazwa Toru) - używane w hierarchii
 - LocationCity (Miasto) - używane w hierarchii
 - CountryName (Kraj) - używane w hierarchii
 - Continent (Kontynent) - używane w hierarchii
- **Hierarchie:** Kontynent → Kraj → Miasto → Nazwa Toru

16.1.5 Dim_Time (Czas)

- **Atrybuty:**
 - DateKey (PK, format YYYYMMDD)
 - FullDate (Pełna data, typ Date)
 - Year (Rok) - używane w hierarchii
 - Quarter (Kwartał) - używane w hierarchii
 - Month (Miesiąc numer) - używane w hierarchii
 - MonthName (Nazwa Miesiąca)
 - DayOfMonth (Dzień Miesiąca) - używane w hierarchii jako najniższy poziom
 - DayOfWeekName (Nazwa Dnia Tygodnia)
- **Hierarchie:** Rok → Kwartał → Miesiąc → Dzień (FullDate)

16.1.6 Dim_Weather (Pogoda)

- **Atrybuty:**
 - WeatherKey (PK, np. Rok * 100 + Runda)
 - DidRainOccur (Czy wystąpił deszcz: "Rain Occurred"/"No Rain")
 - WindSpeedCategory (Kategoria Prędkości Wiatru: np. "Light Breeze", "Calm")
 - AirTempCategory (Kategoria Temperatury Powietrza: np. "Cold", "Warm")
 - TrackTempCategory (Kategoria Temperatury Toru: np. "Optimal Track", "Very Hot Track")
 - HumidityCategory (Kategoria Wilgotności: np. "Dry", "Humid")
 - PressureCategory (Kategoria Ciśnienia: np. "Very Low", "Normal")
- **Hierarchie:** Brak zdefiniowanych (każdy atrybut jest osobną "mini-hierarchią")

16.1.7 Dim_Status (Status ukończenia)

- **Atrybuty:**
 - StatusKey (PK, Klucz Zastępczy)
 - StatusID_NK (Klucz Naturalny ze źródła)
 - StatusDescription (Opis Statusu) - używane w hierarchii
 - StatusCategory (Ogólna Kategoria Statusu, np. "Race Outcome", "Mechanical Failure") - używane w hierarchii
- **Hierarchie:** Kategoria Statusu → Opis Statusu

16.1.8 Dim_DegenerateDetails (Wymiar zdegenerowany)

- **Atrybuty:**
 - CompositeKey (PK, Klucz Zastępczy)
 - AgeAtRace (Wiek Kierowcy w momencie wyścigu)
 - AgeGroup (Grupa wiekowa, np. "Under 20", "20-25")
 - GridPosition (Pozycja Startowa)
 - FinalPositionOrder (Końcowa Pozycja w Wyścigu)

16.2 Miary

Miary pochodzące bezpośrednio z tabeli faktów

1. **Points Scored:** Liczba punktów zdobytych przez kierowcę w wyścigu.
2. **Laps Completed:** Liczba ukończonych okrążeń.
3. **Number of Pit Stops:** Sumaryczna liczba wykonanych pit stopów.
4. **Race Time Milliseconds:** Sumaryczny czas wyścigu w milisekundach (dla tych, co ukończyli i mają zarejestrowany czas).
5. **Grid Position:** Pozycja startowa kierowcy.
6. **Final Position Order:** Końcowa pozycja kierowcy w wyścigu.
7. **Position Order Change:** Zmiana pozycji (pozycja startowa - pozycja końcowa).
8. **Rank Fastest Lap:** Ranking najszybszego okrążenia kierowcy w danym wyścigu.
9. **Fastest Lap Top Speed:** Prędkość maksymalna osiągnięta podczas najszybszego okrążenia.
10. **Is Win:** Suma flag (0/1) wskazujących na zwycięstwo.
11. **Finished Race:** Suma flag (0/1) wskazujących na ukończenie wyścigu.
12. **Is Podium:** Suma flag (0/1) wskazujących na miejsce na podium.
13. **Is DNF:** Suma flag (0/1) wskazujących na nieukończenie wyścigu (Did Not Finish).
14. **Is Pole Position:** Suma flag (0/1) wskazujących na zdobycie pole position.
15. **Is Fastest Lap:** Suma flag (0/1) wskazujących na zdobycie najszybszego okrążenia.
16. **Podium From Outside Top 10 Grid:** Suma flag (0/1) wskazujących na podium ze startu spoza TOP 10.
17. **Podium From Inside Top 10 Grid:** Suma flag (0/1) wskazujących na podium ze startu z TOP 10.

Miary kalkulowane

1. **Race Time Formatted:** Sformatowany czas wyścigu dla czytelności.
2. **Absolute Position Order Change:** Bezwzględna wartość zmiany pozycji (start vs meta).
3. **Average PitStops Count:** Średnia liczba pit stopów na występ kierowcy, który miał odnotowane pit stopy.
4. **Average Absolute Position Order Change:** Średnia bezwzględna zmiana pozycji na start.
5. **Average Points:** Średnia liczba zdobytych punktów na start.
6. **Number of Wins:** Całkowita liczba zwycięstw. Jawne zdefiniowanie sumy miary bazowej IsWin.
7. **Average Finish Position:** Średnia pozycja na mecie dla kierowców, którzy ukończyli wyścig.
8. **Win Percentage from Grid:** Procent wygranych spośród wszystkich rozpoczętych wyścigów.
9. **Finish Percentage:** Procent ukończonych wyścigów spośród wszystkich startów.
10. **DNF Percentage:** Procent nieukończonych wyścigów (DNF) spośród wszystkich startów.
11. **Average Fastest Lap Top Speed:** Średnia maksymalna prędkość na najszybszym okrążeniu (dla tych, którzy je odnotowali).
12. **Average Race Time in Minutes:** Średni czas wyścigu w minutach.
13. **Age At Race:** Średni wiek kierowcy w momencie wyścigu.

17 Wnioski z analizy danych

Przeprowadzone analizy na kostce OLAP pozwoliły na wyciągnięcie kilku interesujących wniosków oraz zaobserwowanie zależności:

- Ewolucja awarii mechanicznych: Silnik konsekwentnie pozostaje główną przyczyną awarii na przestrzeni dekad (1950-60 vs 2010-20). Jednak pojawienie się kategorii "Power Unit" i "Hydraulics" w nowszym okresie, obok nadal istotnych problemów ze skrzynią biegów, hamulcami czy zawieszeniem, doskonale ilustruje wzrost złożoności technologicznej współczesnych bolidów i integrację systemów hybrydowych oraz zaawansowanych systemów pomocniczych.
- Nieprzewidywalność wyścigów a charakterystyka toru i pogoda: Tory takie jak Dijon czy Zolder, ze względu na swoją charakterystykę, generują bardziej dynamiczne i nieprzewidywalne wyścigi (więcej zmian pozycji). Jednocześnie, warunki deszczowe, albo silniejszy wiatr, znacząco zwiększają szansę na podium dla kierowców startujących spoza pierwszej dziesiątki.
- Związek wieku kierowcy z wynikami: Młodszy kierowcy (<20 lat) mają mniej DNF i lepsze średnie pozycje, co może być efektem tego, że do F1 w tak młodym wieku trafiają wybitne talenty, często od razu do czołowych zespołów (choć mała liczebność grupy może wpływać na te dane). Jednak szczytową formę pod względem procentu zwycięstw i prędkości najszybszych okrążeń osiągają kierowcy w wieku 31-35 lat, co wskazuje na idealne połączenie doświadczenia, dojrzałości taktycznej i wciąż wysokich zdolności fizycznych. Starsze grupy wiekowe (26+) generalnie częściej nie kończą wyścigów i mają gorsze średnie pozycje.
- Dominacja konstruktorów i kierowców: Analiza konstruktorów (Mercedes, Red Bull, Ferrari na czele) i procentu zwycięstw kierowców (dominacja Hamiltona, a potem Verstappena) wyraźnie pokazuje okresy dominacji poszczególnych zespołów i zawodników. Dane z 2024 sugerują potencjalne zaciśnięcie się czołówki, choć Verstappen nadal utrzymuje silną pozycję.
- Wpływ deszczu na strategię: Deszcz nie tylko zwiększa ryzyko DNF i nieprzewidywalność (podium spoza TOP10), ale także konsekwentnie prowadzi do większej liczby pit stopów. Ciekawy jest trend wzrostowy liczby pit stopów w deszczu w latach 2018-2023, co może świadczyć o ewolucji strategii lub częstszych neutralizacjach w takich warunkach.
- Postęp technologiczny a czasy wyścigów: Drastyczny spadek średnich czasów wyścigów na torze Monza do końca lat 70. XX wieku obrazuje skokowy postęp technologiczny w F1. Późniejsza stabilizacja czasów (z niewielkimi fluktuacjami, np. wzrost w 2020) może świadczyć o osiągnięciu pewnego plateau wydajnościowego w ramach obowiązujących regulacji, większym nacisku na bezpieczeństwo lub o tym, że sam tor nie przechodził modyfikacji znacząco skracaających czas okrążenia.

Stworzona kostka OLAP jest dobrym narzędziem do dalszej, pogłębionej eksploracji danych, umożliwiając zadawanie złożonych pytań i odkrywanie ukrytych wzorców.